

Sujets Avancés en Machine Learning

Lecture Notes

Zakari HACHEMI

Basé sur le cours de Christophe Denis - MMMEF
2025-2026

Table des matières

1	Introduction à l'Apprentissage Supervisé	1
1.1	Introduction	1
1.1.1	Objectif	1
1.1.2	Données Étiquetées (Labeled Data)	1
1.1.3	Pourquoi l'Apprentissage Supervisé ?	1
1.1.4	Fonctions de Prédiction	1
1.1.5	Perte et Risque (Loss and Risk)	2
1.1.6	Exemples de Fonctions de Perte	2
1.1.7	Prédicteur de Bayes	2
1.1.8	Risque en Excès (Excess Risk)	2
1.1.9	Caractère Aléatoire du Risque	2
1.2	Régression	2
1.2.1	Prédicteur de Bayes et risque en excès	3
1.2.2	Modèle de régression avec bruit	3
1.2.3	Régression Linéaire Gaussienne	4
1.2.4	Minimisation du Risque Empirique (ERM)	4
1.2.5	Surapprentissage (Overfitting) et Choix de Modèle	4
1.2.6	Décomposition Biais-Variance (Bias-Variance decomposition)	5
1.2.7	Estimateur des k-Plus Proches Voisins (k-NN)	5
1.2.8	Autres méthodes populaires	6
1.3	Classification	6
1.3.1	Prédicteur de Bayes	6
1.3.2	Classification Binaire	7
1.3.3	Régression Logistique	8
1.3.4	Modèle de Mélange Gaussien (GMM)	8
1.4	Analyse Générale du Classifieur Plug-in	11
1.4.1	Définition et Approche	11
1.4.2	Borne sur le Risque en Excès	11
1.4.3	Consistance	12
1.4.4	Analyse Détaillée du Cas Binaire	12
1.5	Minimisation du Risque Empirique (Empirical Risk Minimization)	14
1.5.1	Principe de l'ERM	14
1.5.2	Difficultés de l'ERM	14
1.5.3	Solution : Surrogate Convex	15
1.5.4	ERM avec Surrogate L_2	16
1.5.5	Zhang's Lemma et Consistance	16
2	Classification Under Demographic Parity Constraint	17
2.1	Notations	17
2.2	Définition de l'Équité (Fairness)	17
2.3	Classifieur Optimal sous Contrainte DP	18

2.4	Résolution du Problème Dual	18
2.5	Algorithme de Post-traitement pour la DP	23

Chapitre 1

Introduction à l'Apprentissage Supervisé

1.1 Introduction

1.1.1 Objectif

L'objectif est de construire une fonction de décision automatique basée sur des données étiquetées D_n , telle que $f(X)$ soit une prédiction précise de la sortie associée Y . Nous voulons que la prédiction $\hat{f}(X)$ soit la plus proche possible de Y .

1.1.2 Données Étiquetées (Labeled Data)

Définition 1.1 (Échantillon d'apprentissage). L'échantillon d'apprentissage (learning sample), noté D_n , est défini par :

$$D_n := \{(X_i, Y_i)\}_{i=1}^n \quad (1.1)$$

Il est composé de copies i.i.d. de la paire aléatoire (X, Y) . Lorsque la fonction de prédiction dépend de l'échantillon d'apprentissage, on utilise la notation $\hat{f}$ ou $\hat{f}_n$.

Remarque (Notations). Dans tout ce cours, n désignera la taille de l'échantillon d'apprentissage, d la dimension de l'espace d'entrée (features), $\mathcal{X} = \mathbb{R}^d$ l'espace des entrées et $\mathcal{Y}$ l'espace des sorties (labels).

1.1.3 Pourquoi l'Apprentissage Supervisé ?

La motivation réside dans le fait que, dans de nombreuses applications, la sortie réelle associée à une entrée X n'est pas disponible, et son acquisition peut être coûteuse ou chronophage.

1.1.4 Fonctions de Prédiction

Définition 1.2 (Fonction de prédiction). Une fonction de prédiction f est une fonction mesurable qui fait correspondre l'espace des caractéristiques (feature space) à l'espace de sortie :

$$f : \mathbb{R}^d \longrightarrow \mathcal{Y}, \quad x \mapsto f(x) \quad (1.2)$$

L'ensemble de toutes les fonctions de prédiction est noté $\mathcal{F}(\mathbb{R}^d, \mathcal{Y})$.

- **Régression** : L'espace de sortie est $\mathcal{Y} = \mathbb{R}$.

- **Classification** : L'espace de sortie est fini, typiquement $\mathcal{Y} = \{1, \dots, K\}$. En classification binaire, $\mathcal{Y} = \{0, 1\}$ ou $\mathcal{Y} = \{-1, +1\}$.

1.1.5 Perte et Risque (Loss and Risk)

Définition 1.3 (Fonction de perte et risque). Une fonction de perte (loss function) est une application :

$$L : \mathcal{Y} \times \mathcal{Y} \longrightarrow \mathbb{R}_+, \quad (y, y') \mapsto L(y, y') \quad (1.3)$$

Étant donné une fonction de perte L , le risque d'une fonction de prédiction f est défini comme :

$$R(f) = \mathbb{E}[L(f(X), Y)] \quad (1.4)$$

1.1.6 Exemples de Fonctions de Perte

Exemple 1.4 (Fonctions de perte courantes). • **Régression** : La perte quadratique $L(y, y') = (y - y')^2$. Elle pénalise fortement les grandes erreurs, ce qui est adapté aux problèmes d'estimation continue.

- **Classification** : La perte 0-1 définie par $L(y, y') = \mathbf{1}_{\{y \neq y'\}}$. Elle compte simplement le nombre d'erreurs de classification, sans distinction de magnitude.

1.1.7 Prédicteur de Bayes

Définition 1.5 (Prédicteur de Bayes). Le prédicteur de Bayes (prédicteur optimal) est défini par :

$$f^* \in \arg \min_{f \in \mathcal{F}} R(f) \quad (1.5)$$

Il satisfait $\forall f \in \mathcal{F}, R(f^*) \leq R(f)$.

1.1.8 Risque en Excès (Excess Risk)

Définition 1.6 (Risque en excès). Le risque en excès d'un prédicteur f est défini par :

$$\mathcal{E}(f) = R(f) - R(f^*) \quad (1.6)$$

La consistance d'un prédicteur dépendant des données $\hat{f}$ signifie que $\mathbb{E}[\mathcal{E}(\hat{f})] \xrightarrow{n \rightarrow \infty} 0$.

Remarque. Le risque en excès est toujours non-négatif : $\mathcal{E}(f) \geq 0$ pour tout f , car f^* minimise R par définition.

1.1.9 Caractère Aléatoire du Risque

Le risque d'un prédicteur dépendant des données $\hat{f}$ est une variable aléatoire car il dépend de D_n :

$$R(\hat{f}) = \mathbb{E}[L(\hat{f}(X), Y) | D_n] \quad (1.7)$$

1.2 Régression

En régression, $Y \in \mathbb{R}$ et $Y \in L^2$ ($\mathbb{E}[Y^2] < +\infty$). On utilise généralement la perte carrée.

1.2.1 Prédicteur de Bayes et risque en excès

Proposition 1.7 (Prédicteur de Bayes en régression). *Le risque est $R(f) = \mathbb{E}[(Y - f(X))^2]$. Le prédicteur de Bayes est :*

$$f^*(X) = \mathbb{E}[Y|X] \quad (1.8)$$

Pour tout f , le risque en excès est $\mathcal{E}(f) = \mathbb{E}[(f(X) - f^(X))^2]$.*

Démonstration. Montrons que $\mathcal{E}(f) = \mathbb{E}[(f(X) - f^*(X))^2]$. On a :

$$\begin{aligned} R(f) - R(f^*) &= \mathbb{E}[(Y - f(X))^2] - \mathbb{E}[(Y - f^*(X))^2] \\ &= \mathbb{E}[(Y - f(X))^2 - (Y - f^*(X))^2] \end{aligned}$$

En utilisant l'identité $a^2 - b^2 = (a - b)(a + b)$ avec $a = Y - f(X)$ et $b = Y - f^*(X)$:

$$= \mathbb{E}[(f^*(X) - f(X))(2Y - f^*(X) - f(X))]$$

Par la loi des espérances itérées, conditionnons par rapport à X :

$$= \mathbb{E}[\mathbb{E}[(f^*(X) - f(X))(2Y - f^*(X) - f(X)) | X]]$$

Puisque $f(X)$ et $f^*(X)$ sont mesurables par rapport à X :

$$\begin{aligned} &= \mathbb{E}[(f^*(X) - f(X)) \cdot \mathbb{E}[2Y - f^*(X) - f(X) | X]] \\ &= \mathbb{E}[(f^*(X) - f(X)) \cdot (2\mathbb{E}[Y|X] - f^*(X) - f(X))] \end{aligned}$$

Or $f^*(X) = \mathbb{E}[Y|X]$, donc :

$$\begin{aligned} &= \mathbb{E}[(f^*(X) - f(X)) \cdot (2f^*(X) - f^*(X) - f(X))] \\ &= \mathbb{E}[(f^*(X) - f(X))^2] \end{aligned}$$

□

1.2.2 Modèle de régression avec bruit

Proposition 1.8 (Décomposition avec bruit). *On peut écrire $Y = f^*(X) + \epsilon$, où $\epsilon = Y - f^*(X)$ satisfait $\mathbb{E}[\epsilon|X] = 0$.*

Démonstration. Posons $\epsilon = Y - f^*(X) = Y - \mathbb{E}[Y|X]$. Alors :

$$\mathbb{E}[\epsilon|X] = \mathbb{E}[Y - \mathbb{E}[Y|X]|X] = \mathbb{E}[Y|X] - \mathbb{E}[Y|X] = 0$$

□

Exemple 1.9 (Modèle de bruit gaussien).

On suppose que

$$Y = f^*(X) + \epsilon$$

avec $\epsilon \perp X$, satisfaisant

$$\mathbb{E}[\epsilon|X] = \mathbb{E}[\epsilon]$$

et

$$\epsilon \sim \mathcal{N}(0, \sigma^2).$$

Ce modèle est appelé **modèle de bruit gaussien homoscedastique**.

1.2.3 Régression Linéaire Gaussienne

Si l'on suppose $f^*(X) = \langle X, \theta^* \rangle$, on obtient le modèle de régression linéaire gaussienne :

$$Y = \langle X, \theta^* \rangle + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

1.2.4 Minimisation du Risque Empirique (ERM)

Définition 1.10 (Minimisation du risque empirique). Le principe de l'ERM consiste à minimiser le risque empirique défini sur un échantillon D_n :

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n (Y_i - f(X_i))^2 \quad (1.9)$$

Le minimiseur du risque empirique sur une classe de modèles $\mathcal{F}$ est :

$$\hat{f} \in \arg \min_{f \in \mathcal{F}} \hat{R}(f) \quad (1.10)$$

1.2.5 Surapprentissage (Overfitting) et Choix de Modèle

Restreindre la classe d'hypothèses permet d'éviter le surapprentissage (overfitting). Un modèle trop complexe peut interpoler parfaitement les données ($\hat{R}(\hat{f}) = 0$) mais avoir de mauvaises performances de généralisation.

Exemple 1.11 (Interpolateur parfait).

Considérons la fonction $\hat{f}$ définie par :

$$\hat{f}(x) = \begin{cases} Y_i & \text{si } x = X_i \text{ pour un } i \in \{1, \dots, n\} \\ 0 & \text{sinon} \end{cases}$$

Cette fonction satisfait $\hat{R}(\hat{f}) = 0$ (risque empirique nul), mais n'a aucun pouvoir de généralisation : elle prédit 0 pour toute nouvelle observation.




FIGURE 1.1 – Illustration du surapprentissage : $\hat{f}$ interpole parfaitement les données mais s'éloigne de $f^* = \mathbb{E}[Y|X]$.

Remarque (Prédicteur Oracle et prédicteur ERM). Introduisons :

$$\tilde{f} \in \arg \min_{f \in \mathcal{F}} R(f), \quad \hat{f} \in \arg \min_{f \in \mathcal{F}} \hat{R}(f). \quad (1.11)$$

L'oracle $\tilde{f}$ est le meilleur prédicteur *possible* dans la classe $\mathcal{F}$ (mais inaccessible car R est inconnu), tandis que $\hat{f}$ est le meilleur prédicteur *observable* basé sur les données.

On a alors la décomposition :

$$\mathcal{E}(\hat{f}) = R(\hat{f}) - R(f^*) = (R(\hat{f}) - R(\tilde{f})) + (R(\tilde{f}) - R(f^*)) \quad (1.12)$$

1.2.6 Décomposition Biais-Variance (Bias-Variance decomposition)

Théorème 1.12 (Décomposition biais-variance). *Le risque en excès peut être décomposé en :*

$$\mathcal{E}(\hat{f}) = \underbrace{(R(\hat{f}) - R(\tilde{f}))}_{\text{Estimation (variance)}} + \underbrace{(R(\tilde{f}) - R(f^*))}_{\text{Approximation (biais)}} \quad (1.13)$$

où $\tilde{f}$ est l'oracle de la classe de modèles.

Remarque. • Le terme de **variance** (estimation) dépend de n et tend vers 0 quand $n \rightarrow \infty$.

- Le terme de **biais** (approximation) est déterministe et dépend uniquement du choix de la classe $\mathcal{F}$.
- Un bon compromis biais-variance est essentiel pour une bonne généralisation.

1.2.7 Estimateur des k-Plus Proches Voisins (k-NN)

Définition 1.13 (Estimateur k-NN). Le prédicteur k-NN à un point x est la moyenne des sorties des k voisins les plus proches :

$$\hat{f}(x) = \frac{1}{k} \sum_{j=1}^k Y_{(j)}(x) \quad (1.14)$$


où $Y_{(1)}(x), \dots, Y_{(k)}(x)$ sont les sorties correspondant aux k plus proches voisins de x dans D_n .

Exemple 1.14 (Illustration : Points de données dans $\mathbb{R}^2$).

Considérons un ensemble de points dans $\mathbb{R}^2$. Soit $X_i = (x_i^1, x_i^2)$ des vecteurs pour $i = 1, \dots, n$ avec $n = 5$. L'échantillon d'apprentissage est noté :

$$\mathcal{D}_5 = \{(X_1, Y_1), \dots, (X_5, Y_5)\}$$

Fixons le paramètre $k = 3$.



Les estimateurs $\hat{f}$ aux points x et x' sont calculés en moyennant les valeurs Y des $k = 3$ plus proches voisins :

$$\hat{f}(x) = \frac{1}{3}(Y_3 + Y_4 + Y_5) \quad (1.15)$$

$$\hat{f}(x') = \frac{1}{3}(Y_1 + Y_2 + Y_5) \quad (1.16)$$

Le prédicteur $\hat{f}(x)$ effectue donc une moyenne locale des labels des voisins les plus proches. En classification, cela reviendrait à un vote majoritaire parmi les voisins.

Proposition 1.15 (Taux de convergence k-NN). *Sous des hypothèses de régularité (Lip-schitz), si $k \rightarrow \infty$ et $k/n \rightarrow 0$, le risque en excès suit le taux :*

$$\mathbb{E}[\mathcal{E}(\hat{f})] \leq Cn^{-\frac{2}{2+d}} \quad (1.17)$$

Remarque. Ce taux souffre de la **malédiction de la dimensionnalité** : quand d augmente, le taux de convergence se dégrade considérablement.

1.2.8 Autres méthodes populaires

Parmi les autres méthodes de régression/classification supervisée, on peut citer :

- **Random Forests** : Agrégation d'arbres de décision
- **Boosting** (AdaBoost, Gradient Boosting) : Construction séquentielle de modèles faibles
- **Support Vector Machines (SVM)** : Maximisation de la marge
- **Réseaux de neurones** : Modèles à couches multiples

1.3 Classification

En classification multiclasse, $Y \in \{1, \dots, K\}$. Le risque de mauvaise classification est $R(f) = \mathbb{P}(f(X) \neq Y)$.

1.3.1 Prédicteur de Bayes

Définition 1.16 (Probabilités a posteriori). On définit les probabilités a posteriori :

$$P_k(x) := \mathbb{P}(Y = k | X = x) \quad (1.18)$$

Proposition 1.17 (Prédicteur de Bayes en classification). *Le prédicteur de Bayes est :*

$$f^*(x) \in \arg \max_{k \in \{1, \dots, K\}} P_k(x) \quad (1.19)$$

Démonstration. Pour tout classifieur f , on a :

$$\begin{aligned} \mathbb{P}(f(X) = Y) &= \mathbb{E}[\mathbf{1}_{\{f(X)=Y\}}] = \mathbb{E}[\mathbb{E}[\mathbf{1}_{\{f(X)=Y\}}|X]] \\ &= \mathbb{E} \left[\sum_{k=1}^K \mathbf{1}_{\{f(X)=k\}} \mathbb{P}(Y = k|X) \right] \\ &= \mathbb{E} \left[\sum_{k=1}^K \mathbf{1}_{\{f(X)=k\}} P_k(X) \right] \end{aligned}$$

Pour X fixé, $f(X) \in \{1, \dots, K\}$ donc un seul terme de la somme est non nul :

$$\sum_{k=1}^K \mathbf{1}_{\{f(X)=k\}} P_k(X) = P_{f(X)}(X)$$

Cette quantité est maximisée quand $f(X)$ choisit le k qui maximise $P_k(X)$, c'est-à-dire quand $f = f^*$. Donc $\mathbb{P}(f^*(X) = Y) \geq \mathbb{P}(f(X) = Y)$ pour tout f , i.e., $R(f^*) \leq R(f)$. $\square$

1.3.2 Classification Binaire

Si $Y \in \{0, 1\}$, on définit la fonction de régression $\eta(X) := \mathbb{P}(Y = 1|X) = \mathbb{E}[Y|X]$. Le classifieur de Bayes devient :

$$f^*(x) = \mathbf{1}_{\{\eta(x) \geq 1/2\}} \quad (1.20)$$

Proposition 1.18 (Risque en excès en classification binaire). *Le risque en excès s'exprime par :*

$$\mathcal{E}(f) = \mathbb{E}[|2\eta(X) - 1| \mathbf{1}_{\{f(X) \neq f^*(X)\}}] \quad (1.21)$$

Démonstration. Procédons par disjonction de cas. Pour x fixé, calculons $\mathbb{P}(f(x) \neq Y|X = x) - \mathbb{P}(f^*(x) \neq Y|X = x)$.

Cas 1 : $f(x) = f^*(x)$. Alors la différence est nulle.

Cas 2 : $f(x) \neq f^*(x)$ et $\eta(x) \geq 1/2$ (donc $f^*(x) = 1$, $f(x) = 0$).

$$\begin{aligned} \mathbb{P}(f(x) \neq Y|X = x) - \mathbb{P}(f^*(x) \neq Y|X = x) &= \mathbb{P}(Y = 1|X = x) - \mathbb{P}(Y = 0|X = x) \\ &= \eta(x) - (1 - \eta(x)) = 2\eta(x) - 1 \end{aligned}$$

Cas 3 : $f(x) \neq f^*(x)$ et $\eta(x) < 1/2$ (donc $f^*(x) = 0$, $f(x) = 1$).

$$\begin{aligned} \mathbb{P}(f(x) \neq Y|X = x) - \mathbb{P}(f^*(x) \neq Y|X = x) &= \mathbb{P}(Y = 0|X = x) - \mathbb{P}(Y = 1|X = x) \\ &= (1 - \eta(x)) - \eta(x) = 1 - 2\eta(x) \end{aligned}$$

Dans les deux cas où $f(x) \neq f^*(x)$, la différence vaut $|2\eta(x) - 1|$. D'où :

$$\mathcal{E}(f) = \mathbb{E}[|2\eta(X) - 1| \mathbf{1}_{\{f(X) \neq f^*(X)\}}]$$

$\square$

1.3.3 Régression Logistique

Définition 1.19 (Régression logistique). En régression logistique, on paramètre la fonction de régression $\eta(X)$ via une fonction sigmoïde :

$$\eta(X) = \sigma(h^*(X)) = \frac{1}{1 + \exp(-h^*(X))} \quad (1.22)$$

où typiquement $h^*(X) = \langle X, \theta^* \rangle$ pour un certain vecteur de paramètres $\theta^* \in \mathbb{R}^d$.

Remarque. La régression logistique est un modèle **discriminatif** : on modélise directement $\mathbb{P}(Y|X)$ sans passer par la distribution jointe.

1.3.4 Modèle de Mélange Gaussien (GMM)

Définition 1.20 (Modèle de mélange gaussien). Dans ce modèle, les classes ont des probabilités a priori $\pi_k = \mathbb{P}(Y = k)$ et les caractéristiques suivent une loi normale par classe :

$$X|Y = k \sim \mathcal{N}_d(\mu_k, \Sigma_k) \quad (1.23)$$

Proposition 1.21 (Prédicteur de Bayes pour GMM). *Le prédicteur de Bayes est :*

$$g^*(x) \in \arg \max_{k \in \{1, \dots, K\}} \pi_k \varphi_d(x; \mu_k, \Sigma_k) \quad (1.24)$$

où φ_d désigne la densité de la loi normale multivariée.

Démonstration. Par la règle de Bayes :

$$\mathbb{P}(Y = k|X = x) = \frac{\mathbb{P}(X = x|Y = k) \cdot \mathbb{P}(Y = k)}{\mathbb{P}(X = x)} = \frac{\varphi_d(x; \mu_k, \Sigma_k) \cdot \pi_k}{\varphi_X(x)}$$

où la densité marginale de X est donnée par :

$$\varphi_X(x) = \sum_{j=1}^K \pi_j \varphi_d(x; \mu_j, \Sigma_j)$$

Ainsi, le classifieur de Bayes $f^*(x)$ maximise le numérateur :

$$f^*(x) \in \arg \max_{k \in \{1, \dots, K\}} \frac{\pi_k \varphi_d(x; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \varphi_d(x; \mu_j, \Sigma_j)}$$

Ce qui revient à maximiser $\pi_k \varphi_d(x; \mu_k, \Sigma_k)$. □

Remarque. Le GMM est un modèle **génératif** : on modélise la distribution jointe $\mathbb{P}(X, Y) = \mathbb{P}(X|Y)\mathbb{P}(Y)$.

Approche Plug-in et Analyse Discriminante de Fisher

Dans la pratique, les paramètres $(\pi_k)_k, (\mu_k)_k, (\Sigma_k)_k$ sont inconnus. Nous ne pouvons pas calculer directement f^* . Nous devons estimer f^* par $\hat{f}$ à partir de l'échantillon d'apprentissage D_n .

Définition 1.22 (Plug-in approach). L'approche "plug-in" consiste à considérer des estimateurs $\hat{\pi}_k, \hat{\mu}_k, \hat{\Sigma}_k$ des paramètres inconnus, calculés sur D_n , et à les substituer dans l'expression du prédicteur de Bayes.

On construit ainsi le prédicteur :

$$\hat{f}(x) \in \arg \max_{k \in \{1, \dots, K\}} \frac{\hat{\pi}_k \hat{\varphi}_k(x)}{\sum_{j=1}^K \hat{\pi}_j \hat{\varphi}_j(x)} \quad (1.25)$$

où $\hat{\varphi}_k$ est la densité de $\mathcal{N}_d(\hat{\mu}_k, \hat{\Sigma}_k)$.

Remarque (LDA vs QDA). Distinguer deux cas :

- **Cas 1** : $\Sigma_k = \Sigma$ pour tout k . Dans ce cas, on parle de **Linear Discriminant Analysis (LDA)**. Les frontières de décision sont linéaires.
- **Cas 2** : $\Sigma_k \neq \Sigma_{k'}$ pour $k \neq k'$. Dans ce cas, on parle de **Quadratic Discriminant Analysis (QDA)**. Les frontières de décision sont quadratiques.

Exemple 1.23 (Modèle Bernoulli-Gaussien).

Illustrons ces concepts avec un exemple concret et calculable explicitement. Considérons le cas binaire ($Y \in \{0, 1\}$) unidimensionnel ($d = 1$). Supposons que :

$$Y \sim \text{Bern}(1/2) \quad (\pi_0 = \pi_1 = 1/2)$$

et que conditionnellement à $Y = y$, X suit une loi normale :

$$X|Y = y \sim \mathcal{N}(\mu_y, \sigma^2)$$

avec $\mu_1 > \mu_0$ (et même variance σ^2).

On a par la formule de Bayes :

$$\mathbb{P}(Y = y|X = x) = \frac{\exp\left(-\frac{(x-\mu_y)^2}{2\sigma^2}\right)}{\exp\left(-\frac{(x-\mu_1)^2}{2\sigma^2}\right) + \exp\left(-\frac{(x-\mu_0)^2}{2\sigma^2}\right)}$$

(car les termes $1/(\sigma\sqrt{2\pi})$ et les probabilités a priori $1/2$ se simplifient au numérateur et au dénominateur).

Le classifieur de Bayes est défini par :

$$f^*(x) = \mathbf{1} \{ \mathbb{P}(Y = 1|X = x) \geq \mathbb{P}(Y = 0|X = x) \}$$

Ainsi :

$$\begin{aligned} \mathbb{P}(Y = 1|X = x) \geq \mathbb{P}(Y = 0|X = x) &\iff \mathbb{P}(Y = 1|X = x) \geq 1 - \mathbb{P}(Y = 1|X = x) \\ &\iff \mathbb{P}(Y = 1|X = x) \geq \frac{1}{2} \\ &\iff \frac{1}{2} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma^2}\right) \geq \frac{1}{2} \exp\left(-\frac{(x-\mu_0)^2}{2\sigma^2}\right) \\ &\iff -\frac{(x-\mu_1)^2}{2\sigma^2} \geq -\frac{(x-\mu_0)^2}{2\sigma^2} \\ &\iff (x-\mu_1)^2 \leq (x-\mu_0)^2 \\ &\iff x^2 - 2x\mu_1 + \mu_1^2 \leq x^2 - 2x\mu_0 + \mu_0^2 \\ &\iff -2x\mu_1 + \mu_1^2 \leq -2x\mu_0 + \mu_0^2 \\ &\iff 2x\mu_1 - 2x\mu_0 \geq \mu_1^2 - \mu_0^2 \\ &\iff 2x(\mu_1 - \mu_0) \geq \mu_1^2 - \mu_0^2 \\ &\iff x(\mu_1 - \mu_0) \geq \frac{\mu_1^2 - \mu_0^2}{2} \\ &\iff x \geq \frac{\mu_1 + \mu_0}{2} \quad (\text{car } \mu_1 - \mu_0 > 0) \end{aligned}$$

Comme $\mu_1 > \mu_0$, le point milieu est $(\mu_0 + \mu_1)/2$. La condition équivaut à $x \geq \frac{\mu_0 + \mu_1}{2}$.

Interprétation : Puisque les variances sont identiques, la frontière de décision optimale se situe exactement au milieu du segment reliant les deux moyennes. Le modèle choisit la classe dont la moyenne est la plus proche de l'observation x .

Remarque (Généralisation à $\mathbb{R}^d$). Ce résultat se généralise en dimension d . Si $\Sigma_0 = \Sigma_1 = \Sigma = I_d$ (identité), la frontière de décision est un hyperplan affine défini par :

$$f^*(x) = \mathbf{1} \left\{ x^\top (\mu_1 - \mu_0) \geq \frac{1}{2} (\|\mu_1\|^2 - \|\mu_0\|^2) \right\}$$

Exercice 1.24 (Calcul du Risque de Bayes). Exprimer le risque de Bayes $R(f^*)$ pour cet exemple en fonction de la fonction de répartition Φ de la loi normale standard.

Correction : Par définition du risque, on a :

$$\begin{aligned} R(f^*) &= \mathbb{P}(f^*(X) \neq Y) \\ &= \mathbb{P}(Y = 1, f^*(X) = 0) + \mathbb{P}(Y = 0, f^*(X) = 1) \\ &= \mathbb{P}(Y = 1) \mathbb{P}(f^*(X) = 0 | Y = 1) + \mathbb{P}(Y = 0) \mathbb{P}(f^*(X) = 1 | Y = 0) \end{aligned}$$

Comme $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$, on obtient :

$$\begin{aligned} \mathbb{P}(f^*(X) = 0 | Y = 1) &= \mathbb{P} \left(X < \frac{\mu_1 + \mu_0}{2} \middle| Y = 1 \right) \\ &= \mathbb{P} \left(\frac{X - \mu_1}{\sigma} < \frac{\frac{\mu_1 + \mu_0}{2} - \mu_1}{\sigma} \middle| Y = 1 \right) \\ &= \mathbb{P} \left(Z < \frac{\mu_0 - \mu_1}{2\sigma} \right) \quad \text{où } Z \sim \mathcal{N}(0, 1) \\ &= \Phi \left(\frac{\mu_0 - \mu_1}{2\sigma} \right) \end{aligned}$$

où Φ est la fonction de répartition (c.d.f.) de la loi $\mathcal{N}(0, 1)$.

De même, par symétrie :

$$\mathbb{P}(f^*(X) = 1 | Y = 0) = \mathbb{P} \left(X \geq \frac{\mu_1 + \mu_0}{2} \middle| Y = 0 \right) = \Phi \left(\frac{\mu_0 - \mu_1}{2\sigma} \right)$$

Ainsi, le risque de Bayes est :

$$R(f^*) = \Phi \left(\frac{\mu_0 - \mu_1}{2\sigma} \right) = \Phi \left(-\frac{\mu_1 - \mu_0}{2\sigma} \right)$$

Or, on sait que $\forall z \in \mathbb{R}, \Phi(z) + \Phi(-z) = 1$. D'où :

$$R(f^*) = 1 - \Phi \left(\frac{\mu_1 - \mu_0}{2\sigma} \right)$$

Exercice 1.25 (Généralisation à $\mathbb{R}^d$). Généraliser l'expression du risque de Bayes obtenue ci-dessus au cas multidimensionnel où $\mu_1, \mu_0 \in \mathbb{R}^d$ et $\Sigma = I_d$.

Correction : Dans le cas $\Sigma = I_d$, la frontière de décision est l'hyperplan médiateur du segment $[\mu_0, \mu_1]$. Le problème est invariant par rotation et dépend uniquement de la distance entre les moyennes projetée sur le vecteur discriminant $w = \mu_1 - \mu_0$. Le problème se ramène à un cas unidimensionnel le long de l'axe défini par $\mu_1 - \mu_0$. La distance effective entre les deux centres est $\|\mu_1 - \mu_0\|$. Par analogie avec le cas 1D où la distance était $|\mu_1 - \mu_0|$, le risque de Bayes devient :

$$R(f^*) = 1 - \Phi \left(\frac{\|\mu_1 - \mu_0\|}{2\sigma} \right)$$

1.4 Analyse Générale du Classifieur Plug-in

Cette section formalise l'approche du "Plug-in Classifier" pour construire un classifieur à partir des données.

1.4.1 Définition et Approche

Supposons que la distribution conjointe (X, Y) soit inconnue. Le classifieur de Bayes est donné par :

$$f^*(x) \in \arg \max_{k \in \{1, \dots, K\}} P_k(x)$$

où $P_k(x) = \mathbb{P}(Y = k | X = x)$.

Le **Classifieur Plug-in** $\hat{f}$ est défini en remplaçant les probabilités réelles P_k par des estimateurs $\hat{P}_k$ construits à partir des données :

$$\hat{f}(x) \in \arg \max_{k \in \{1, \dots, K\}} \hat{P}_k(x)$$

où $\hat{P}_k$ est un estimateur de P_k .

1.4.2 Borne sur le Risque en Excès

Nous avons le résultat fondamental suivant qui lie la performance du classifieur plug-in à la qualité de l'estimation des probabilités conditionnelles.

Théorème 1.26 (Borne du classifieur Plug-in). *Le risque en excès du classifieur plug-in est borné par l'erreur d'estimation L^1 des probabilités conditionnelles :*

$$R(\hat{f}) - R(f^*) \leq \sum_{k=1}^K \mathbb{E} \left[|\hat{P}_k(X) - P_k(X)| \right]$$

Démonstration. Considérons la différence des risques conditionnels en un point x . On sait que (voir section précédente) :

$$\mathbb{P}(f^*(X) \neq Y | X = x) - \mathbb{P}(f(X) \neq Y | X = x) = P_{f^*(x)}(x) - P_{f(x)}(x)$$

Cependant, ceci est négatif car f^* est optimal. Utilisons plutôt la notation du risque en excès. On a :

$$R(\hat{f}) - R(f^*) = \mathbb{E} \left[P_{f^*(X)}(X) - P_{\hat{f}(X)}(X) \right]$$

En effet, minimiser le risque revient à maximiser la probabilité de la bonne classe. Pour un x donné, notons $k^* = f^*(x)$ et $\hat{k} = \hat{f}(x)$. Si $k^* = \hat{k}$, la différence est nulle. Sur l'événement $\{f^*(x) \neq \hat{f}(x)\}$, nous avons :

$$\begin{aligned} P_{f^*(x)}(x) - P_{\hat{f}(x)}(x) &= P_{f^*(x)}(x) - \hat{P}_{f^*(x)}(x) + \hat{P}_{f^*(x)}(x) - P_{\hat{f}(x)}(x) \\ &= \left(P_{f^*(x)}(x) - \hat{P}_{f^*(x)}(x) \right) + \left(\hat{P}_{f^*(x)}(x) - \hat{P}_{\hat{f}(x)}(x) \right) + \left(\hat{P}_{\hat{f}(x)}(x) - P_{\hat{f}(x)}(x) \right) \end{aligned}$$

Par définition de $\hat{f}$, $\hat{f}(x)$ maximise $\hat{P}_k(x)$, donc :

$$\hat{P}_{\hat{f}(x)}(x) \geq \hat{P}_{f^*(x)}(x) \implies \hat{P}_{f^*(x)}(x) - \hat{P}_{\hat{f}(x)}(x) \leq 0$$

Ainsi :

$$\begin{aligned} P_{f^*(x)}(x) - P_{\hat{f}(x)}(x) &\leq P_{f^*(x)}(x) - \hat{P}_{f^*(x)}(x) + \hat{P}_{\hat{f}(x)}(x) - P_{\hat{f}(x)}(x) \\ &\leq |P_{f^*(x)}(x) - \hat{P}_{f^*(x)}(x)| + |\hat{P}_{\hat{f}(x)}(x) - P_{\hat{f}(x)}(x)| \\ &\leq \sum_{k=1}^K |P_k(x) - \hat{P}_k(x)| \end{aligned}$$

En prenant l'espérance, on obtient le résultat :

$$\mathbb{E}[R(\hat{f}) - R(f^*)] \leq \sum_{k=1}^K \mathbb{E}[|\hat{P}_k(X) - P_k(X)|]$$

□

1.4.3 Consistance

Corollaire 1.27 (Consistance). *Si les estimateurs $\hat{P}_k$ sont consistants (i.e., convergent vers P_k en probabilité ou p.s.), alors le classifieur plug-in associé $\hat{f}$ est **consistant**, c'est-à-dire :*

$$R(\hat{f}) \rightarrow R(f^*) \quad \text{quand } n \rightarrow \infty$$

Remarque (Cas Binaire). Dans le cas binaire où $Y \in \{0, 1\}$, on denote souvent $\eta(x) = \mathbb{P}(Y = 1|X = x)$. Le classifieur de Bayes est $f^*(x) = \mathbf{1}\{\eta(x) \geq 1/2\}$. Le classifieur plug-in est $\hat{f}(x) = \mathbf{1}\{\hat{\eta}(x) \geq 1/2\}$.

1.4.4 Analyse Détaillée du Cas Binaire

Approfondissons le cas où $\mathcal{Y} = \{0, 1\}$. Soit $\hat{\eta}$ un estimateur de la fonction de régression η . Nous avons le résultat suivant pour l'excès de risque :

Proposition 1.28 (Excès de risque en classification binaire).

$$\mathbb{E}[R(\hat{f}) - R(f^*)] = \mathbb{E} \left[|2\eta(X) - 1| \cdot \mathbf{1}_{\{\hat{f}(X) \neq f^*(X)\}} \right]$$

Démonstration. Sur l'événement $\{\hat{f}(X) \neq f^*(X)\}$, on commet une erreur. Sans perte de généralité, supposons pour un x donné que $f^*(x) = 1$. Cela implique que $\eta(x) \geq 1/2$. Si $\hat{f}(x) \neq f^*(x)$, alors $\hat{f}(x) = 0$, ce qui implique $\hat{\eta}(x) < 1/2$. Dans ce cas, la différence des probabilités conditionnelles est :

$$P_{f^*(x)}(x) - P_{\hat{f}(x)}(x) = \eta(x) - (1 - \eta(x)) = 2\eta(x) - 1 = |2\eta(x) - 1|$$


De même, si $f^*(x) = 0$ (donc $\eta(x) < 1/2$) et $\hat{f}(x) = 1$ (donc $\hat{\eta}(x) \geq 1/2$), la différence est :

$$P_{f^*(x)}(x) - P_{\hat{f}(x)}(x) = (1 - \eta(x)) - \eta(x) = 1 - 2\eta(x) = |2\eta(x) - 1|$$

D'où le résultat en prenant l'espérance. □

Cette situation peut être visualisée comme suit. L'erreur se produit lorsque $\eta(x)$ et $\hat{\eta}(x)$ sont de part et d'autre du seuil $1/2$.

Sur l'événement $\{\hat{f}(x) \neq f^*(x)\}$



Sur l'événement $\{\hat{f}(x) \neq f^*(x)\}$, nous avons donc :

$$|\hat{\eta}(x) - \eta(x)| \geq |\eta(x) - 1/2|$$

Cela implique (en utilisant l'expression précédente de l'excès de risque) :

$$\mathbb{E}[R(\hat{f}) - R(f^*)] = 2\mathbb{E}\left[\left|\eta(X) - \frac{1}{2}\right| \mathbf{1}_{\{\hat{f}(X) \neq f^*(X)\}}\right]$$

En utilisant l'inégalité démontrée ci-dessus sur l'événement erreur, nous pouvons majorer ce terme :

$$\mathbb{E}[R(\hat{f}) - R(f^*)] \leq 2\mathbb{E}\left[|\hat{\eta}(X) - \eta(X)| \mathbf{1}_{\{\hat{f}(X) \neq f^*(X)\}}\right] \leq 2\mathbb{E}[|\hat{\eta}(X) - \eta(X)|]$$

Ainsi, la performance du classifieur plug-in est directement contrôlée par la qualité d'estimation L^1 de la fonction de régression η .

Définition 1.29 (Estimateur des k-Plus Proches Voisins). Soit $D_n = \{(X_i, Y_i)\}_{i=1}^n$ l'échantillon d'apprentissage et $k \geq 1$ un entier. Pour tout $x \in \mathbb{R}^d$, considérons les données réordonnées selon la distance euclidienne $d(x, y) = \|x - y\|$, notées $X_{(1)}(x), \dots, X_{(n)}(x)$, telles que :

$$\|X_{(1)}(x) - x\| \leq \|X_{(2)}(x) - x\| \leq \dots \leq \|X_{(n)}(x) - x\|$$

Soit $Y_{(i)}(x)$ l'étiquette associée à $X_{(i)}(x)$. L'estimateur de la probabilité conditionnelle $P_j(x) = \mathbb{P}(Y = j | X = x)$ est donné par la proportion de voisins de classe j parmi les k plus proches :


$$\hat{P}_j(x) = \frac{1}{k} \sum_{i=1}^k \mathbf{1}_{\{Y_{(i)}(x)=j\}}$$

Le classifieur des k-NN est alors défini par le principe "Plug-in" :

$$\hat{f}_{kNN}(x) \in \arg \max_{j \in \{1, \dots, K\}} \hat{P}_j(x)$$

Exemple 1.30 (Illustration k-NN ($k = 3$ en $\mathbb{R}^2$)).

La figure suivante illustre le principe de décision pour $k = 3$ dans un problème à deux classes (ronds et carrés).



Pour le point x , la majorité des 3 voisins sont des ronds $\Rightarrow$ Classe "Rond". Pour le point x' , la majorité des 3 voisins sont des carrés $\Rightarrow$ Classe "Carré".

1.5 Minimisation du Risque Empirique (Empirical Risk Minimization)

Le classifieur de Bayes f^* est caractérisé par :

$$f^* \in \arg \min_f R(f)$$

où $R(f) = \mathbb{P}(f(X) \neq Y)$ est le risque théorique.

1.5.1 Principe de l'ERM

En pratique, le risque $R(f)$ est inconnu car la distribution (X, Y) n'est pas accessible. On dispose uniquement d'un échantillon d'apprentissage $D_n = \{(X_i, Y_i)\}_{i=1}^n$.

Définition 1.31 (Risque Empirique). Soit $\mathcal{F}$ une classe de prédicteurs (modèle). Le risque empirique d'un prédicteur $f \in \mathcal{F}$ est défini par :

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{f(X_i) \neq Y_i\}}$$

L'estimateur par minimisation du risque empirique (ERM) est :

$$\hat{f} \in \arg \min_{f \in \mathcal{F}} \hat{R}(f) = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{f(X_i) \neq Y_i\}}$$

$\hat{f}$ est appelé **empirical risk estimator**.

1.5.2 Difficultés de l'ERM

Remarque (Deux problèmes majeurs). L'optimisation directe de l'ERM pose deux difficultés :

1. **La perte 0-1 n'est pas convexe.** La fonction indicatrice $\mathbf{1}_{\{f(x) \neq y\}}$ n'est pas une fonction convexe, ce qui rend l'optimisation difficile.
2. **L'ensemble des classifieurs n'est pas convexe.** L'espace $\mathcal{F}$ des classifieurs possibles n'a généralement pas de structure convexe.

1.5.3 Solution : Surrogate Convex

Pour éviter ces deux problèmes, on considère une **relaxation convexe** (convex surrogate) du problème initial.

Fonctions de Score

Plutôt que de considérer directement un ensemble de classifieurs $f : \mathbb{R}^d \rightarrow \{1, \dots, K\}$, on considère un ensemble de **fonctions de score** :

$$h : \mathbb{R}^d \rightarrow \mathbb{R}$$

L'avantage est que l'ensemble des fonctions de score est un espace vectoriel : toute combinaison linéaire de fonctions de score est encore une fonction de score.

Remarque (Convexité). Si $\lambda \in [0, 1]$ et h, h' sont deux fonctions de score, alors $\lambda h + (1 - \lambda)h'$ est également une fonction de score. En revanche, si f, f' sont deux classifieurs, $\lambda f + \mu f'$ n'est **pas** un classifieur (la somme de deux fonctions à valeurs dans $\{0, 1\}$ n'est pas à valeurs dans $\{0, 1\}$).

Surrogate Loss Convexe

On remplace également la perte 0-1 par une perte convexe (**surrogate loss**). Un exemple classique est la perte quadratique (L_2 loss) :

$$\ell(y, y') = (y - y')^2$$

Définition 1.32 (Encodage One-Hot). Pour la classification multiclass avec K classes, on encode les étiquettes $y \in \{1, \dots, K\}$ comme des vecteurs $Z_k \in \{-1, +1\}^K$ définis par :

$$Z_k = 2\mathbf{1}_{\{Y=k\}} - 1, \quad k \in \{1, \dots, K\}$$

Autrement dit, $Z_k \in \{-1, +1\}$ et le vecteur complet est :

$$Z = (Z_1, \dots, Z_K)^\top = (2\mathbf{1}_{\{Y=1\}} - 1, \dots, 2\mathbf{1}_{\{Y=K\}} - 1)^\top$$

Vecteur de Fonctions de Score

Considérons un vecteur de fonctions de score $\vec{h} = (h_1, \dots, h_K)$ où chaque $h_k : \mathbb{R}^d \rightarrow \mathbb{R}$ est une fonction de score.

Pour un vecteur $\vec{h}$ donné, on peut considérer son **classifieur associé** :

$$f_{\vec{h}}(x) \in \arg \max_{k \in \{1, \dots, K\}} h_k(x)$$

Risque L_2

Pour un vecteur $\vec{h}$ de fonctions de score, on définit son risque L_2 associé :

$$R_2(\vec{h}) = \sum_{k=1}^K \mathbb{E} \left[(Z_k - h_k(X))^2 \right]$$

Si on considère le risque empirique associé :

$$\hat{R}_2(\vec{h}) = \frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K (Z_k^i - h_k(X_i))^2$$

avec $Z_k^i = 2\mathbf{1}_{\{Y_i=k\}} - 1$.

On choisit un modèle $\mathcal{H}$ (un ensemble de vecteurs de fonctions de score).

1.5.4 ERM avec Surrogate L_2

L'estimateur par minimisation du risque empirique (ERM) est :

$$\hat{\vec{h}} \in \arg \min_{\vec{h} \in \mathcal{H}} \hat{R}_2(\vec{h})$$

C'est la **convexification de l'ERM en classification**.

Remarque (Minimiseur du risque L_2). Le minimiseur du risque L_2 est :

$$\vec{h}^* \in \arg \min_{\vec{h}} R_2(\vec{h})$$

On peut calculer explicitement :

$$h_k^*(x) = \mathbb{E}[Z_k | X = x] = 2\mathbb{E}[\mathbf{1}_{\{Y=k\}} | X = x] - 1 = 2P_k(x) - 1 \quad \forall k$$

Le classifieur associé au minimiseur est :

$$\begin{aligned} f_{\vec{h}^*}(x) &\in \arg \max_k h_k^*(x) \\ &= \arg \max_k (2P_k(x) - 1) \\ &= \arg \max_k P_k(x) \\ &= f^*(x) \quad \text{p.s.} \end{aligned}$$

1.5.5 Zhang's Lemma et Consistance

Théorème 1.33 (Zhang's Lemma (2004) - Pour la perte L_2). *Pour toute fonction de score $\vec{h}$ et son classifieur associé $f_{\vec{h}}$, on a :*

$$R(f_{\vec{h}}) - R(f^*) \leq \frac{1}{\sqrt{2}} \left(R_2(\vec{h}) - R_2(\vec{h}^*) \right)^{1/2}$$

Corollaire 1.34 (Consistance via le risque surrogate). *Si $\hat{\vec{h}}$ est consistant par rapport au risque R_2 (i.e., $R_2(\hat{\vec{h}}) \rightarrow R_2(\vec{h}^*)$ quand $n \rightarrow \infty$), alors le classifieur associé $f_{\hat{\vec{h}}}$ est consistant par rapport au risque R :*

$$R(f_{\hat{\vec{h}}}) \rightarrow R(f^*) \quad \text{quand } n \rightarrow \infty$$

Ce résultat justifie l'utilisation de la perte L_2 comme surrogate convexe de la perte 0-1 en classification.

Chapitre 2

Classification Under Demographic Parity Constraint

2.1 Notations

Considérons les notations suivantes pour ce chapitre :

- Une observation est un triplet (X, S, Y) .
- $X \in \mathbb{R}^d$ représente les caractéristiques (features).
- $S \in \{-1, 1\}$ est l'attribut sensible (sensitive attribute).
- $Y \in \{0, 1\}$ est la sortie (label).

Un prédicteur (ou classifieur) f est une fonction de (X, S) telle que $f(X, S) \in \{0, 1\}$.

Nous considérons le risque de mauvaise classification (*misclassification risk*) :

$$R(f) = \mathbb{P}(f(X, S) \neq Y) \quad (2.1)$$

comme mesure de performance.

Dans ce cas, le prédicteur optimal (ou Classifieur de Bayes) qui satisfait :

$$f^* \in \arg \min_f R(f) \quad (2.2)$$

est défini par :

$$f^*(X, S) = \mathbf{1}\{\eta(X, S) \geq 1/2\} \quad (2.3)$$

où $\eta(X, S) = \mathbb{P}(Y = 1|X, S)$.

2.2 Définition de l'Équité (Fairness)

Nous considérons la contrainte de Parité Démographique (Demographic Parity constraint ou DP-constraint). Nous disons qu'un prédicteur f satisfait la contrainte DP si :

$$\forall s \in \{-1, 1\}, \quad \mathbb{P}(f(X, S) = 1|S = s) = \mathbb{P}(f(X, S) = 1) \quad (2.4)$$

Ceci équivaut aux propriétés suivantes :

$$\begin{aligned} f(X, S) \perp\!\!\!\perp S &\iff \mathbb{P}(f(X, S) = 1|S = 1) = \mathbb{P}(f(X, S) = 1|S = -1) \\ &\iff \sum_{s \in \{-1, 1\}} s \cdot \mathbb{P}(f(X, S) = 1|S = s) = 0 \end{aligned}$$

2.3 Classifieur Optimal sous Contrainte DP

Nous considérons f_{fair}^* défini comme :

$$f_{fair}^* \in \arg \min_{f \text{ satisfaisant DP}} R(f) \quad (2.5)$$

Ceci est équivalent à résoudre le problème d'optimisation sous contrainte :

$$f_{fair}^* \in \arg \min_f R(f) \quad (2.6)$$

t.q. $\sum_{s \in \{-1,1\}} s \cdot \mathbb{P}(f(X,S)=1|S=s)=0$

Le Lagrangien associé s'écrit comme suit :

$$\mathcal{L}(f, \lambda) = R(f) + \lambda \sum_{s \in \{-1,1\}} s \mathbb{P}(f(X, S) = 1 | S = s) \quad (2.7)$$

En introduisant la notation $\mathbb{P}(\cdot | S = s) := \mathbb{P}_{X|S=s}(\cdot)$, on a :

$$\mathcal{L}(f, \lambda) = R(f) + \lambda \sum_{s \in \{-1,1\}} s \mathbb{P}_{X|S=s}(f(X, S) = 1) \quad (2.8)$$

Pour résoudre le problème d'optimisation :

$$f_{fair}^* \in \arg \min_{f \text{ satisfaisant DP}} R(f) \quad (2.9)$$

nous devons résoudre le problème d'optimisation suivant (problème primal) :

$$\min_f \max_{\lambda} \mathcal{L}(f, \lambda) \quad (2.10)$$

En général, nous résolvons le problème dual :

$$\max_{\lambda} \min_f \mathcal{L}(f, \lambda) \quad (*)$$

Nous avons toujours la propriété suivante (*principe de dualité faible*) :

$$\min_f \max_{\lambda} \mathcal{L}(f, \lambda) \geq \max_{\lambda} \min_f \mathcal{L}(f, \lambda) \quad (2.11)$$

Nous résolvons le problème (*) et montrons que :

$$\min_f \max_{\lambda} \mathcal{L}(f, \lambda) = \max_{\lambda} \min_f \mathcal{L}(f, \lambda) \quad (2.12)$$

C'est-à-dire qu'il n'y a pas de saut de dualité (*no duality gap*, ou dualité forte).

2.4 Résolution du Problème Dual

Le but est d'obtenir une expression analytique (*closed form expression*) du prédicteur optimal f_{fair}^* .

Première étape : Minimisation par rapport à f

Pour tout $\lambda \in \mathbb{R}$ fixé, nous cherchons à résoudre :

$$\min_f \mathcal{L}(f, \lambda) \quad (2.13)$$

Rappelons l'expression du Lagrangien :

$$\mathcal{L}(f, \lambda) = R(f) + \lambda \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f(X, S) = 1) \quad (2.14)$$

Le risque s'écrit comme une espérance :

$$\begin{aligned} R(f) &= \mathbb{P}(f(X, S) \neq Y) \\ &= \mathbb{E}[\mathbf{1}\{f(X, S) \neq Y\}] \end{aligned}$$

En conditionnant par rapport à Y , on obtient :

$$R(f) = \mathbb{E}[\mathbf{1}\{f(X, S) \neq Y\} \mathbf{1}\{Y = 0\}] + \mathbb{E}[\mathbf{1}\{f(X, S) \neq Y\} \mathbf{1}\{Y = 1\}]$$

Pour tout $y \in \{0, 1\}$, en utilisant la loi des espérances itérées par rapport à (X, S) :

$$\begin{aligned} \mathbb{E}[\mathbf{1}\{f(X, S) \neq y\} \mathbf{1}\{Y = y\}] &= \mathbb{E}[\mathbb{E}[\mathbf{1}\{f(X, S) \neq y\} \mathbf{1}\{Y = y\} | X, S]] \\ &= \mathbb{E}[\mathbf{1}\{f(X, S) \neq y\} \mathbb{E}[\mathbf{1}\{Y = y\} | X, S]] \\ &= \mathbb{E}[\mathbf{1}\{f(X, S) \neq y\} \mathbb{P}(Y = y | X, S)] \end{aligned}$$

En notant $\eta(X, S) = \mathbb{P}(Y = 1 | X, S)$, on a $\mathbb{P}(Y = 0 | X, S) = 1 - \eta(X, S)$. Ainsi, le risque devient :

$$R(f) = \mathbb{E}[\mathbf{1}\{f(X, S) \neq 0\}(1 - \eta(X, S))] + \mathbb{E}[\mathbf{1}\{f(X, S) \neq 1\}\eta(X, S)]$$

Puisque $f(X, S) \in \{0, 1\}$, nous avons les identités suivantes :

$$\begin{aligned} \mathbf{1}\{f(X, S) \neq 0\} &= \mathbf{1}\{f(X, S) = 1\} = f(X, S) \\ \mathbf{1}\{f(X, S) \neq 1\} &= \mathbf{1}\{f(X, S) = 0\} = 1 - f(X, S) \end{aligned}$$

En substituant ces identités dans l'expression du risque, on obtient :

$$\begin{aligned} R(f) &= \mathbb{E}[f(X, S)(1 - \eta(X, S))] + \mathbb{E}[(1 - f(X, S))\eta(X, S)] \\ &= \mathbb{E}[f(X, S)(1 - 2\eta(X, S))] + \mathbb{E}[\eta(X, S)] \end{aligned}$$

De plus, par la loi des espérances itérées :

$$\begin{aligned} \mathbb{E}[\eta(X, S)] &= \mathbb{E}[\mathbb{P}(Y = 1 | X, S)] \\ &= \mathbb{E}[\mathbb{E}[\mathbf{1}\{Y = 1\} | X, S]] \\ &= \mathbb{E}[\mathbf{1}\{Y = 1\}] \\ &= \mathbb{E}[Y] \end{aligned}$$

car $Y \in \{0, 1\}$, donc $\mathbb{E}[Y | X, S] = \mathbb{P}(Y = 1 | X, S) = \eta(X, S)$. Ainsi :

$$R(f) = \mathbb{E}[Y] + \mathbb{E}[f(X, S)(1 - 2\eta(X, S))] \quad (2.15)$$

Notons $\pi_s = \mathbb{P}(S = s)$. Nous pouvons décomposer l'espérance sur S :

$$\begin{aligned} R(f) &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{P}(S = s) \mathbb{E}_{X|S=s}[f(X, S)(1 - 2\eta(X, S))] \\ &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \pi_s \mathbb{E}_{X|S=s}[f(X, S)(1 - 2\eta(X, S))] \end{aligned}$$

Reprenons le Lagrangien :

$$\begin{aligned}
\mathcal{L}(f, \lambda) &= R(f) + \lambda \sum_{s \in \{-1, 1\}} s \mathbb{E}_{X|S=s} [f(X, S)] \\
&= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \pi_s \mathbb{E}_{X|S=s} [f(X, S)(1 - 2\eta(X, S))] + \sum_{s \in \{-1, 1\}} \lambda s \mathbb{E}_{X|S=s} [f(X, S)] \\
&= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\pi_s f(X, S)(1 - 2\eta(X, S)) + \lambda s f(X, S)] \\
&= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [(\pi_s(1 - 2\eta(X, S)) + \lambda s) f(X, S)]
\end{aligned}$$

Ainsi, chercher $f_\lambda^* \in \arg \min_f \mathcal{L}(f, \lambda)$ revient à minimiser point par point le terme sous l'espérance. Puisque $f(X, S) \in \{0, 1\}$, pour minimiser une expression de la forme $A \cdot f(X, S)$, nous choisissons :

$$f(X, S) = 1 \iff A < 0$$

Ici, $A = \pi_s(1 - 2\eta(X, S)) + \lambda s$. Nous avons donc :

$$\begin{aligned}
f_\lambda^*(X, S) = 1 &\iff \pi_s(1 - 2\eta(X, S)) + \lambda s < 0 \\
&\iff 1 - 2\eta(X, S) < -\frac{\lambda s}{\pi_s} \\
&\iff 2\eta(X, S) > 1 + \frac{\lambda s}{\pi_s} \\
&\iff \eta(X, S) > \frac{1}{2} + \frac{\lambda s}{2\pi_s}
\end{aligned}$$

Le prédicteur optimal pour un λ fixé est donc :

$$f_\lambda^*(X, S) = \mathbf{1} \left\{ \eta(X, S) > \frac{1}{2} + \frac{\lambda s}{2\pi_s} \right\} \quad (2.16)$$

Deuxième étape : Maximisation par rapport à λ

Nous cherchons maintenant à résoudre :

$$\max_{\lambda \in \mathbb{R}} \mathcal{L}(f_\lambda^*, \lambda) \quad (2.17)$$

Soit λ^* la solution :

$$\lambda^* \in \arg \max_{\lambda \in \mathbb{R}} \mathcal{L}(f_\lambda^*, \lambda) \quad (2.18)$$

En réinjectant l'expression de f_λ^* dans le Lagrangien, on obtient pour tout $\lambda \in \mathbb{R}$:

$$\begin{aligned}
\mathcal{L}(f_\lambda^*, \lambda) &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [(\pi_s(1 - 2\eta(X, S)) + \lambda s) f_\lambda^*(X, S)] \\
&= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\min(\pi_s(1 - 2\eta(X, S)) + \lambda s, 0)]
\end{aligned} \quad (2.19)$$

Nous observons que :

$$\lambda^* \in \arg \max_{\lambda \in \mathbb{R}} \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\min(\pi_s(1 - 2\eta(X, S)) + \lambda s, 0)]$$

Ceci est équivalent à :

$$\lambda^* \in \arg \min_{\lambda \in \mathbb{R}} \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\max(\pi_s(2\eta(X, S) - 1) - \lambda s, 0)] \quad (2.20)$$

en utilisant l'identité $\max(A) = -\min(-A)$.

La fonction $\lambda \mapsto \max(\pi_s(2\eta(X, S) - 1) - \lambda s, 0)$ est convexe. Par conséquent, la fonction objectif :

$$\lambda \mapsto \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\max(\pi_s(2\eta(X, S) - 1) - \lambda s, 0)]$$

est convexe.

De plus, la fonction

$$\mathcal{H}(\lambda) = \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\max(\pi_s(2\eta(X, S) - 1) - \lambda s, 0)] \quad (2.21)$$

est coercive, c'est-à-dire que $\lim_{|\lambda| \rightarrow +\infty} \mathcal{H}(\lambda) = +\infty$.

Exemple 2.1 (Exercice : Coercivité et bornes sur λ^*).

Énoncé : Montrer que la fonction $\lambda \mapsto \mathcal{H}(\lambda)$ est coercive et que le paramètre optimal vérifie $\lambda^* \in [-1, 1]$.

Correction :

1. **Coercivité de $\mathcal{H}(\lambda)$**

Rappelons que $\mathcal{H}(\lambda) = \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [(\pi_s(2\eta(X, S) - 1) - \lambda s)_+]$.

Étudions le comportement quand $\lambda \rightarrow +\infty$:

- Pour $s = 1$, le terme sous l'espérance est $(\pi_1(2\eta - 1) - \lambda)_+$. Puisque $2\eta - 1 \leq 1$ et $\pi_1 \leq 1$, on a $\pi_1(2\eta - 1) - \lambda \leq 1 - \lambda$. Pour $\lambda > 1$, ce terme est négatif, donc la partie positive est nulle.
- Pour $s = -1$, le terme est $(\pi_{-1}(2\eta - 1) + \lambda)_+$. Pour λ assez grand, $\pi_{-1}(2\eta - 1) + \lambda > 0$ presque sûrement. Le terme se comporte comme λ .

Ainsi, $\lim_{\lambda \rightarrow +\infty} \mathcal{H}(\lambda) = +\infty$. Un raisonnement symétrique s'applique pour $\lambda \rightarrow -\infty$ (le terme $s = 1$ domine). La fonction est donc coercive.

2. **Bornes sur λ^***

Montrons que pour tout $\lambda \geq 1$, $\mathcal{H}(\lambda) \geq \mathcal{H}(1)$ (et par symétrie pour $\lambda \leq -1$).

Soit $\lambda \geq 1$.

- Si $s = 1$: Comme vu précédemment, $\pi_1(2\eta - 1) - \lambda \leq \pi_1 - \lambda \leq 1 - 1 = 0$. Donc la contribution est nulle.
- Si $s = -1$: Le terme est $(\pi_{-1}(2\eta - 1) + \lambda)_+$. Or $2\eta - 1 \geq -1$, donc $\pi_{-1}(2\eta - 1) \geq -\pi_{-1}$. Ainsi $\pi_{-1}(2\eta - 1) + \lambda \geq -\pi_{-1} + \lambda$. Comme $\lambda \geq 1$ et $\pi_{-1} \leq 1$, ce terme est positif. La partie positive est donc simplement $\pi_{-1}(2\eta - 1) + \lambda$.

Ainsi, sur l'intervalle $[1, +\infty[$, $\mathcal{H}(\lambda) = \mathbb{E}_{X|S=-1} [\pi_{-1}(2\eta(X, S) - 1)] + \lambda$. C'est une fonction affine strictement croissante de λ .

Soit maintenant $\lambda \leq -1$.

- Si $s = -1$: Le terme est $(\pi_{-1}(2\eta - 1) + \lambda)_+$. Comme $\pi_{-1}(2\eta - 1) \leq \pi_{-1} \leq 1$ et $\lambda \leq -1$, la somme est négative. La contribution est nulle.
- Si $s = 1$: Le terme est $(\pi_1(2\eta - 1) - \lambda)_+$. Or $\pi_1(2\eta - 1) \geq -\pi_1$ et $-\lambda \geq 1$. Donc $\pi_1(2\eta - 1) - \lambda \geq 1 - \pi_1 \geq 0$. La partie positive est donc $\pi_1(2\eta - 1) - \lambda$.

Ainsi, sur l'intervalle $] -\infty, -1]$, $\mathcal{H}(\lambda) = \mathbb{E}_{X|S=1} [\pi_1(2\eta(X, S) - 1)] - \lambda$. C'est une fonction affine strictement décroissante de λ .

On en déduit que pour tout $|\lambda| > 1$, $\mathcal{H}(\lambda) > \min(\mathcal{H}(1), \mathcal{H}(-1))$. Par conséquent, le minimum global λ^* doit se trouver dans l'intervalle $[-1, 1]$.

Remarque (Autre approche pour dériver le prédicteur équitable optimal). Nous avons établi que

pour tout $\lambda \in \mathbb{R}$, le minimiseur du lagrangien est donné par :

$$f_\lambda \in \arg \min_f \mathcal{L}(f, \lambda) \quad \text{et} \quad f_\lambda(X, S) = \mathbf{1}_{\{\eta(X, S) \geq \frac{1}{2} + \frac{\lambda s}{2\pi_s}\}}$$

Nous cherchons maintenant λ^* tel que f_{λ^*} satisfasse la contrainte de Parité Démographique (DP). C'est-à-dire que nous devons trouver λ^* tel que :

$$\mathbb{P}(f_{\lambda^*}(X, S) = 1 | S = 1) = \mathbb{P}(f_{\lambda^*}(X, S) = 1 | S = -1)$$

Notons par $F_s(t)$ la fonction de queue (ou survie) de $\eta(X, S)$ sachant $S = s$:

$$F_s(t) = \mathbb{P}(\eta(X, S) > t | S = s)$$

La condition $f_{\lambda^*}(X, s) = 1$ est équivalente à $\eta(X, s) \geq \frac{1}{2} + \frac{\lambda^* s}{2\pi_s}$.

Si nous supposons que la distribution de $\eta(X, S)$ sachant $S = s$ est continue (pour éviter les problèmes aux bornes des indicatrices), alors :

$$\mathbb{P}(f_{\lambda^*}(X, S) = 1 | S = s) = F_s\left(\frac{1}{2} + \frac{\lambda^* s}{2\pi_s}\right)$$

Nous devons donc résoudre l'équation suivante en λ :

$$F_1\left(\frac{1}{2} + \frac{\lambda}{2\pi_1}\right) = F_{-1}\left(\frac{1}{2} - \frac{\lambda}{2\pi_{-1}}\right)$$

Remarquons que :

- Le terme de gauche, $\lambda \mapsto F_1\left(\frac{1}{2} + \frac{\lambda}{2\pi_1}\right)$, est décroissant (car F_1 est décroissante et λ apparaît avec un signe +).
- Le terme de droite, $\lambda \mapsto F_{-1}\left(\frac{1}{2} - \frac{\lambda}{2\pi_{-1}}\right)$, est croissant (car F_{-1} est décroissante et λ apparaît avec un signe -).

Si l'on suppose de plus que les applications $t \mapsto F_s(t)$ sont continues, alors les deux membres de l'équation sont continus. L'existence et l'unicité de la solution (sous certaines conditions de support strictes) peuvent alors être étudiées via ces propriétés de monotonie, nous assurant de trouver le λ^* optimal.

Ceci implique que le minimiseur λ^* existe et $\lambda^* \in [-1, 1]$.

Pour terminer la dérivation de f_{fair}^* , nous devons considérer l'hypothèse suivante :

$$t \mapsto \mathbb{P}_{X|S=s}(\eta(X, S) \leq t) \quad \text{est continue.} \quad (2.22)$$

Ceci implique que $\forall x \in \mathbb{R}, \mathbb{P}_{X|S=s}(\eta(X, S) = x) = 0$.

Sous cette hypothèse, nous avons que $\lambda \mapsto \mathcal{H}(\lambda)$ est différentiable (par rapport à λ).

Si nous considérons $h_s(\lambda) = \pi_s(2\eta(X, S) - 1) - \lambda s$, alors :


$$\begin{aligned} \mathbb{E}_{X|S=s}[\max(h_s(\lambda), 0)] &= \mathbb{E}_{X|S=s}[h_s(\lambda)\mathbf{1}\{h_s(\lambda) > 0\}] \\ &\quad + \mathbb{E}_{X|S=s}[0 \cdot \mathbf{1}\{h_s(\lambda) < 0\}] \\ &\quad + \mathbb{E}_{X|S=s}[h_s(\lambda)\mathbf{1}\{h_s(\lambda) = 0\}] \end{aligned}$$

Or, $h_s(\lambda) = 0 \iff \pi_s(2\eta(X, S) - 1) - \lambda s = 0 \iff \eta(X, S) = \frac{1}{2} + \frac{\lambda s}{2\pi_s}$. D'après notre hypothèse de continuité, la probabilité de cet événement est nulle. Ainsi, le dernier terme est nul et le deuxième terme est nul car on multiplie par 0. Pour le premier terme, $h_s(\lambda)$ est dérivable par rapport à λ avec $\frac{\partial h_s(\lambda)}{\partial \lambda} = -s$.

On en déduit que $\lambda \mapsto \mathcal{H}(\lambda)$ est différentiable et sa dérivée est donnée par :

$$\frac{\partial \mathcal{H}}{\partial \lambda}(\lambda) = \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} \left[\frac{\partial h_s(\lambda)}{\partial \lambda} \mathbf{1}\{h_s(\lambda) > 0\} \right] = \sum_{s \in \{-1, 1\}} -s \cdot \mathbb{P}_{X|S=s}(h_s(\lambda) > 0) \quad (2.23)$$

Illustration de la convexité de la fonction associée à chaque s :



De plus, nous avons :

$$\begin{aligned}\mathbb{E}_{X|S=s}[\mathbf{1}\{h_s(\lambda) > 0\}] &= \mathbb{P}_{X|S=s}(h_s(\lambda) > 0) \\ &= \mathbb{P}_{X|S=s}\left(\eta(X, S) > \frac{1}{2} + \frac{\lambda s}{2\pi_s}\right) \\ &= \mathbb{P}_{X|S=s}(f_{\lambda}^*(X, S) = 1)\end{aligned}$$

Ainsi, pour tout $\lambda \in \mathbb{R}$:

$$\frac{\partial \mathcal{H}}{\partial \lambda}(\lambda) = - \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f_{\lambda}^*(X, S) = 1) \quad (2.24)$$

Puisque λ^* est un minimum de $\mathcal{H}$ (fonction convexe différentiable et coercive sur $\mathbb{R}$), nous avons :

$$\frac{\partial \mathcal{H}}{\partial \lambda}(\lambda^*) = 0 \iff \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f_{\lambda^*}^*(X, S) = 1) = 0 \quad (2.25)$$

2.5 Algorithme de Post-traitement pour la DP

Contexte et Objectifs

Rappelons que le prédicteur optimal équitale est donné par :

$$f_{\lambda^*}^*(X, S) = \mathbf{1}_{\{\eta(X, S) \geq \frac{1}{2} + \frac{\lambda^* s}{2\pi_s}\}}$$

avec $\lambda^* \in \arg \min_{\lambda} \mathcal{H}(\lambda)$. Sous l'hypothèse de continuité, on a $f_{\lambda^*}^* = f_{fair}^*$.

En pratique, nous ne connaissons pas la distribution sous-jacente. Nous disposons d'un échantillon d'apprentissage :

$$D_n = \{(X_i, S_i, Y_i), i = 1, \dots, n\}$$

Nous voulons construire un prédicteur empirique $\hat{f}$ tel que :

$$\hat{f} \approx f_{\lambda^*}^*$$

Nous exigeons deux propriétés pour $\hat{f}$:

1. $\hat{f}$ satisfait la contrainte de Parité Démographique (DP).
2. $R(\hat{f}) \approx R(f_{\lambda^*}^*)$.

Dans la suite, nous introduisons l'**injustice** (unfairness) d'un prédicteur f , définie par :

$$\mathcal{U}(f) = \left| \sum_{s \in \{-1, 1\}} s \mathbb{P}(f(X, S) = 1 | S = s) \right| \quad (2.26)$$

Un prédicteur f est dit équitale (fair) si et seulement si $\mathcal{U}(f) = 0$. Pour un prédicteur empirique $\hat{f}$, nous voulons $\mathcal{U}(\hat{f}) \approx 0$.

Stratégie d'Estimation

À partir de l'échantillon d'apprentissage D_n , nous pouvons utiliser une approche "plug-in" :

- Nous pouvons estimer la fonction de régression $\eta(X, S)$ par un estimateur $\hat{\eta}(X, S)$ (par exemple, obtenu par régression logistique, forêts aléatoires, réseaux de neurones, etc.).
- Nous pouvons estimer les proportions $\pi_s = \mathbb{P}(S = s)$ par les fréquences empiriques :

$$\hat{\pi}_s = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{S_i=s\}} \xrightarrow{n \rightarrow +\infty} \pi_s \quad (\text{p.s.})$$

- Nous devons estimer le paramètre optimal λ^* par un $\hat{\lambda}$.

Le prédicteur estimé sera alors de la forme :

$$\hat{f}_{\hat{\lambda}}(X, S) = \mathbf{1}_{\left\{\hat{\eta}(X, S) \geq \frac{1}{2} + \frac{\hat{\lambda}_s}{2\pi_s}\right\}} \quad (2.27)$$

où $\hat{\lambda}$ est choisi pour minimiser l'injustice empirique (ou maximiser l'équité).