

Sujets Avancés en Machine Learning

Lecture Notes

Zakari HACHEMI

Basé sur le cours de Christophe Denis - MMMEF
2025-2026

Table des matières

1	Introduction à l'Apprentissage Supervisé	1
1.1	Introduction	1
1.1.1	Objectif	1
1.1.2	Données Étiquetées (Labeled Data)	1
1.1.3	Pourquoi l'Apprentissage Supervisé ?	1
1.1.4	Fonctions de Prédiction	1
1.1.5	Perte et Risque (Loss and Risk)	2
1.1.6	Exemples de Fonctions de Perte	2
1.1.7	Prédicteur de Bayes	2
1.1.8	Risque en Excès (Excess Risk)	2
1.1.9	Caractère Aléatoire du Risque	2
1.2	Régression	2
1.2.1	Prédicteur de Bayes et risque en excès	3
1.2.2	Modèle de régression avec bruit	3
1.2.3	Régression Linéaire Gaussienne	4
1.2.4	Minimisation du Risque Empirique (ERM)	4
1.2.5	Surapprentissage (Overfitting) et Choix de Modèle	4
1.2.6	Décomposition Biais-Variance (Bias-Variance decomposition)	5
1.2.7	Estimateur des k-Plus Proches Voisins (k-NN)	5
1.2.8	Autres méthodes populaires	6
1.3	Classification	6
1.3.1	Prédicteur de Bayes	7
1.3.2	Classification Binaire	7
1.3.3	Régression Logistique	8
1.3.4	Modèle de Mélange Gaussien (GMM)	8
1.3.5	Analyse Générale du Classifieur Plug-in	11
1.3.6	Minimisation du Risque Empirique (Empirical Risk Minimization en clas- sification)	14
1.4	Limites de l'ERM et Transition vers l'Équité	16
2	Équité Algorithmique (Algorithmic Fairness)	17
2.1	Fondements de l'équité (Fairness)	17
2.1.1	Origines des discriminations algorithmiques	17
2.1.2	Awareness vs Unawareness	17
2.1.3	L'Illusion de l'Unawareness (Discrimination Indirecte)	17
2.1.4	Équité individuelle vs Équité de groupe	18
2.1.5	Théorème de l'impossibilité	18
2.2	Autres métriques et taxonomie des méthodes	18
2.2.1	Grandes familles d'approches	18
2.3	Classification sous Post-Processing et contrainte DP	19
2.3.1	Notations du Problème Initial	19

2.3.2	Définition de l'Équité (Fairness)	19
2.3.3	Classifieur Optimal sous Contrainte DP	19
2.3.4	Résolution du Problème Dual	20
2.3.5	Algorithme de Post-traitement pour la DP	25
2.3.6	Algorithmique et Sous-gradients	29
2.3.7	Consistance du Risque de Classification	31
2.4	Classification sous In-Processing	33
2.4.1	Minimisation du Risque Empirique (ERM) Équitable	34
2.4.2	Garanties de l'In-Processing	34
2.4.3	Algorithmique : Convexification	34
2.5	La Régression Équitable (Fair Regression)	35
2.5.1	Formulation du Problème	35
2.5.2	Première Approche : La Discrétisation	35
2.5.3	Approche par transport optimal : Distance de Wasserstein	35
2.5.4	Caractérisation du Prédicteur Équitable Optimal	36
2.5.5	Procédure de Plug-in finale	36

Chapitre 1

Introduction à l'Apprentissage Supervisé

1.1 Introduction

1.1.1 Objectif

L'objectif est de construire une fonction de décision automatique basée sur des données étiquetées D_n , telle que $f(X)$ soit une prédiction précise de la sortie associée Y . Nous voulons que la prédiction $\hat{f}(X)$ soit la plus proche possible de Y .

1.1.2 Données Étiquetées (Labeled Data)

Définition 1.1 (Échantillon d'apprentissage). L'échantillon d'apprentissage (learning sample), noté D_n , est défini par :

$$D_n := \{(X_i, Y_i)\}_{i=1}^n \quad (1.1)$$

Il est composé de copies i.i.d. de la paire aléatoire (X, Y) . Lorsque la fonction de prédiction dépend de l'échantillon d'apprentissage, on utilise la notation $\hat{f}$ ou $\hat{f}_n$.

Remarque (Notations). Dans tout ce cours, n désignera la taille de l'échantillon d'apprentissage, d la dimension de l'espace d'entrée (features), $\mathcal{X} = \mathbb{R}^d$ l'espace des entrées et $\mathcal{Y}$ l'espace des sorties (labels).

1.1.3 Pourquoi l'Apprentissage Supervisé ?

La motivation réside dans le fait que, dans de nombreuses applications, la sortie réelle associée à une entrée X n'est pas disponible, et son acquisition peut être coûteuse ou chronophage.

1.1.4 Fonctions de Prédiction

Définition 1.2 (Fonction de prédiction). Une fonction de prédiction f est une fonction mesurable qui fait correspondre l'espace des caractéristiques (feature space) à l'espace de sortie :

$$f : \mathbb{R}^d \longrightarrow \mathcal{Y}, \quad x \mapsto f(x) \quad (1.2)$$

L'ensemble de toutes les fonctions de prédiction est noté $\mathcal{F}(\mathbb{R}^d, \mathcal{Y})$.

- **Régression** : L'espace de sortie est $\mathcal{Y} = \mathbb{R}$.

- **Classification** : L'espace de sortie est fini, typiquement $\mathcal{Y} = \{1, \dots, K\}$. En classification binaire, $\mathcal{Y} = \{0, 1\}$ ou $\mathcal{Y} = \{-1, +1\}$.

1.1.5 Perte et Risque (Loss and Risk)

Définition 1.3 (Fonction de perte et risque). Une fonction de perte (loss function) est une application :

$$L : \mathcal{Y} \times \mathcal{Y} \longrightarrow \mathbb{R}_+, \quad (y, y') \mapsto L(y, y') \quad (1.3)$$

Étant donné une fonction de perte L , le risque d'une fonction de prédiction f est défini comme :

$$R(f) = \mathbb{E}[L(f(X), Y)] \quad (1.4)$$

1.1.6 Exemples de Fonctions de Perte

Exemple 1.4 (Fonctions de perte courantes). • **Régression** : La perte quadratique $L(y, y') = (y - y')^2$. Elle pénalise fortement les grandes erreurs, ce qui est adapté aux problèmes d'estimation continue.

- **Classification** : La perte 0-1 définie par $L(y, y') = \mathbf{1}_{\{y \neq y'\}}$. Elle compte simplement le nombre d'erreurs de classification, sans distinction de magnitude.

1.1.7 Prédicteur de Bayes

Définition 1.5 (Prédicteur de Bayes). Le prédicteur de Bayes (prédicteur optimal) est défini par :

$$f^* \in \arg \min_{f \in \mathcal{F}} R(f) \quad (1.5)$$

Il satisfait $\forall f \in \mathcal{F}, R(f^*) \leq R(f)$.

1.1.8 Risque en Excès (Excess Risk)

Définition 1.6 (Risque en excès). Le risque en excès d'un prédicteur f est défini par :

$$\mathcal{E}(f) = R(f) - R(f^*) \quad (1.6)$$

La consistance d'un prédicteur dépendant des données $\hat{f}$ signifie que $\mathbb{E}[\mathcal{E}(\hat{f})] \xrightarrow{n \rightarrow \infty} 0$.

Remarque. Le risque en excès est toujours non-négatif : $\mathcal{E}(f) \geq 0$ pour tout f , car f^* minimise R par définition.

1.1.9 Caractère Aléatoire du Risque

Le risque d'un prédicteur dépendant des données $\hat{f}$ est une variable aléatoire car il dépend de D_n :

$$R(\hat{f}) = \mathbb{E}[L(\hat{f}(X), Y) | D_n] \quad (1.7)$$

1.2 Régression

En régression, $Y \in \mathbb{R}$ et $Y \in L^2$ ($\mathbb{E}[Y^2] < +\infty$). On utilise généralement la perte carrée.

1.2.1 Prédicteur de Bayes et risque en excès

Proposition 1.7 (Prédicteur de Bayes en régression). *Le risque est $R(f) = \mathbb{E}[(Y - f(X))^2]$. Le prédicteur de Bayes est :*

$$f^*(X) = \mathbb{E}[Y|X] \quad (1.8)$$

Pour tout f , le risque en excès est $\mathcal{E}(f) = \mathbb{E}[(f(X) - f^(X))^2]$.*

Démonstration. Montrons que $\mathcal{E}(f) = \mathbb{E}[(f(X) - f^*(X))^2]$. On a :

$$\begin{aligned} R(f) - R(f^*) &= \mathbb{E}[(Y - f(X))^2] - \mathbb{E}[(Y - f^*(X))^2] \\ &= \mathbb{E}[(Y - f(X))^2 - (Y - f^*(X))^2] \end{aligned}$$

En utilisant l'identité $a^2 - b^2 = (a - b)(a + b)$ avec $a = Y - f(X)$ et $b = Y - f^*(X)$:

$$= \mathbb{E}[(f^*(X) - f(X))(2Y - f^*(X) - f(X))]$$

Par la loi des espérances itérées, conditionnons par rapport à X :

$$= \mathbb{E}[\mathbb{E}[(f^*(X) - f(X))(2Y - f^*(X) - f(X)) | X]]$$

Puisque $f(X)$ et $f^*(X)$ sont mesurables par rapport à X :

$$\begin{aligned} &= \mathbb{E}[(f^*(X) - f(X)) \cdot \mathbb{E}[2Y - f^*(X) - f(X) | X]] \\ &= \mathbb{E}[(f^*(X) - f(X)) \cdot (2\mathbb{E}[Y|X] - f^*(X) - f(X))] \end{aligned}$$

Or $f^*(X) = \mathbb{E}[Y|X]$, donc :

$$\begin{aligned} &= \mathbb{E}[(f^*(X) - f(X)) \cdot (2f^*(X) - f^*(X) - f(X))] \\ &= \mathbb{E}[(f^*(X) - f(X))^2] \end{aligned}$$

□

1.2.2 Modèle de régression avec bruit

Proposition 1.8 (Décomposition avec bruit). *On peut écrire $Y = f^*(X) + \epsilon$, où $\epsilon = Y - f^*(X)$ satisfait $\mathbb{E}[\epsilon|X] = 0$.*

Démonstration. Posons $\epsilon = Y - f^*(X) = Y - \mathbb{E}[Y|X]$. Alors :

$$\mathbb{E}[\epsilon|X] = \mathbb{E}[Y - \mathbb{E}[Y|X]|X] = \mathbb{E}[Y|X] - \mathbb{E}[Y|X] = 0$$

□

Exemple 1.9 (Modèle de bruit gaussien).

On suppose que

$$Y = f^*(X) + \epsilon$$

avec $\epsilon \perp X$, satisfaisant

$$\mathbb{E}[\epsilon|X] = \mathbb{E}[\epsilon]$$

et

$$\epsilon \sim \mathcal{N}(0, \sigma^2).$$

Ce modèle est appelé **modèle de bruit gaussien homoscedastique**.

1.2.3 Régression Linéaire Gaussienne

Si l'on suppose $f^*(X) = \langle X, \theta^* \rangle$, on obtient le modèle de régression linéaire gaussienne :

$$Y = \langle X, \theta^* \rangle + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

1.2.4 Minimisation du Risque Empirique (ERM)

Définition 1.10 (Minimisation du risque empirique). Le principe de l'ERM consiste à minimiser le risque empirique défini sur un échantillon D_n :

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n (Y_i - f(X_i))^2 \quad (1.9)$$

Le minimiseur du risque empirique sur une classe de modèles $\mathcal{F}$ est :

$$\hat{f} \in \arg \min_{f \in \mathcal{F}} \hat{R}(f) \quad (1.10)$$

1.2.5 Surapprentissage (Overfitting) et Choix de Modèle

Restreindre la classe d'hypothèses permet d'éviter le surapprentissage (overfitting). Un modèle trop complexe peut interpoler parfaitement les données ($\hat{R}(\hat{f}) = 0$) mais avoir de mauvaises performances de généralisation.

Exemple 1.11 (Interpolateur parfait).

Considérons la fonction $\hat{f}$ définie par :

$$\hat{f}(x) = \begin{cases} Y_i & \text{si } x = X_i \text{ pour un } i \in \{1, \dots, n\} \\ 0 & \text{sinon} \end{cases}$$

Cette fonction satisfait $\hat{R}(\hat{f}) = 0$ (risque empirique nul), mais n'a aucun pouvoir de généralisation : elle prédit 0 pour toute nouvelle observation.




FIGURE 1.1 – Illustration du surapprentissage : $\hat{f}$ interpole parfaitement les données mais s'éloigne de $f^* = \mathbb{E}[Y|X]$.

Remarque (Prédicteur Oracle et prédicteur ERM). Introduisons :

$$\tilde{f} \in \arg \min_{f \in \mathcal{F}} R(f), \quad \hat{f} \in \arg \min_{f \in \mathcal{F}} \hat{R}(f). \quad (1.11)$$

L'oracle $\tilde{f}$ est le meilleur prédicteur *possible* dans la classe $\mathcal{F}$ (mais inaccessible car R est inconnu), tandis que $\hat{f}$ est le meilleur prédicteur *observable* basé sur les données.

On a alors la décomposition :

$$\mathcal{E}(\hat{f}) = R(\hat{f}) - R(f^*) = (R(\hat{f}) - R(\tilde{f})) + (R(\tilde{f}) - R(f^*)) \quad (1.12)$$

1.2.6 Décomposition Biais-Variance (Bias-Variance decomposition)

Théorème 1.12 (Décomposition biais-variance). *Le risque en excès peut être décomposé en :*

$$\mathcal{E}(\hat{f}) = \underbrace{(R(\hat{f}) - R(\tilde{f}))}_{\text{Estimation (variance)}} + \underbrace{(R(\tilde{f}) - R(f^*))}_{\text{Approximation (biais)}} \quad (1.13)$$

où $\tilde{f}$ est l'oracle de la classe de modèles.

Remarque. • Le terme de **variance** (estimation) dépend de n et tend vers 0 quand $n \rightarrow \infty$.

- Le terme de **biais** (approximation) est déterministe et dépend uniquement du choix de la classe $\mathcal{F}$.
- Un bon compromis biais-variance est essentiel pour une bonne généralisation.

1.2.7 Estimateur des k-Plus Proches Voisins (k-NN)

Définition 1.13 (Estimateur k-NN). Le prédicteur k-NN à un point x est la moyenne des sorties des k voisins les plus proches :

$$\hat{f}(x) = \frac{1}{k} \sum_{j=1}^k Y_{(j)}(x) \quad (1.14)$$


où $Y_{(1)}(x), \dots, Y_{(k)}(x)$ sont les sorties correspondant aux k plus proches voisins de x dans D_n .

Exemple 1.14 (Illustration : Points de données dans $\mathbb{R}^2$).

Considérons un ensemble de points dans $\mathbb{R}^2$. Soit $X_i = (X_i^1, X_i^2)$ des vecteurs pour $i = 1, \dots, n$ avec $n = 5$. L'échantillon d'apprentissage est noté :

$$\mathcal{D}_5 = \{(X_1, Y_1), \dots, (X_5, Y_5)\}$$

Fixons le paramètre $k = 3$.



Les estimateurs $\hat{f}$ aux points x et x' sont calculés en moyennant les valeurs Y des $k = 3$ plus proches voisins :

$$\hat{f}(x) = \frac{1}{3}(Y_3 + Y_4 + Y_5) \quad (1.15)$$

$$\hat{f}(x') = \frac{1}{3}(Y_1 + Y_2 + Y_5) \quad (1.16)$$

Le prédicteur $\hat{f}(x)$ effectue donc une moyenne locale des labels des voisins les plus proches. En classification, cela reviendrait à un vote majoritaire parmi les voisins (voir section Classification).

Proposition 1.15 (Taux de convergence k-NN). *Sous des hypothèses de régularité (Lip-schitz), si $k \rightarrow \infty$ et $k/n \rightarrow 0$, le risque en excès suit le taux :*

$$\mathbb{E}[\mathcal{E}(\hat{f})] \leq Cn^{-\frac{2}{2+d}} \quad (1.17)$$

Remarque. Ce taux souffre de la **malédiction de la dimensionnalité** : quand d augmente, le taux de convergence se dégrade considérablement.

1.2.8 Autres méthodes populaires

Parmi les autres méthodes de régression/classification supervisée, on peut citer :

- **Random Forests** : Agrégation d'arbres de décision
- **Boosting** (AdaBoost, Gradient Boosting) : Construction séquentielle de modèles faibles
- **Support Vector Machines (SVM)** : Maximisation de la marge
- **Réseaux de neurones** : Modèles à couches multiples

1.3 Classification

En classification multiclasse, $Y \in \{1, \dots, K\}$. Le risque de mauvaise classification est $R(f) = \mathbb{P}(f(X) \neq Y)$.

1.3.1 Prédicteur de Bayes

Définition 1.16 (Probabilités a posteriori). On définit les probabilités a posteriori :

$$P_k(x) := \mathbb{P}(Y = k|X = x) \quad (1.18)$$

Proposition 1.17 (Prédicteur de Bayes en classification). *Le prédicteur de Bayes est :*

$$f^*(x) \in \arg \max_{k \in \{1, \dots, K\}} P_k(x) \quad (1.19)$$

Démonstration. Pour tout classifieur f , on a :

$$\begin{aligned} \mathbb{P}(f(X) = Y) &= \mathbb{E}[\mathbf{1}_{\{f(X)=Y\}}] = \mathbb{E}[\mathbb{E}[\mathbf{1}_{\{f(X)=Y\}}|X]] \\ &= \mathbb{E} \left[\sum_{k=1}^K \mathbf{1}_{\{f(X)=k\}} \mathbb{P}(Y = k|X) \right] \\ &= \mathbb{E} \left[\sum_{k=1}^K \mathbf{1}_{\{f(X)=k\}} P_k(X) \right] \end{aligned}$$

Pour X fixé, $f(X) \in \{1, \dots, K\}$ donc un seul terme de la somme est non nul :

$$\sum_{k=1}^K \mathbf{1}_{\{f(X)=k\}} P_k(X) = P_{f(X)}(X)$$

Cette quantité est maximisée quand $f(X)$ choisit le k qui maximise $P_k(X)$, c'est-à-dire quand $f = f^*$. Donc $\mathbb{P}(f^*(X) = Y) \geq \mathbb{P}(f(X) = Y)$ pour tout f , i.e., $R(f^*) \leq R(f)$. $\square$

1.3.2 Classification Binaire

Si $Y \in \{0, 1\}$, on définit la fonction de régression $\eta(X) := \mathbb{P}(Y = 1|X) = \mathbb{E}[Y|X]$. Le classifieur de Bayes devient :

$$f^*(x) = \mathbf{1}_{\{\eta(x) \geq 1/2\}} \quad (1.20)$$

Proposition 1.18 (Risque en excès en classification binaire). *Le risque en excès s'exprime par :*

$$\mathcal{E}(f) = \mathbb{E}[|2\eta(X) - 1| \mathbf{1}_{\{f(X) \neq f^*(X)\}}] \quad (1.21)$$

Démonstration. Procédons par disjonction de cas. Pour x fixé, calculons $\mathbb{P}(f(x) \neq Y|X = x) - \mathbb{P}(f^*(x) \neq Y|X = x)$.

Cas 1 : $f(x) = f^*(x)$. Alors la différence est nulle.

Cas 2 : $f(x) \neq f^*(x)$ et $\eta(x) \geq 1/2$ (donc $f^*(x) = 1$, $f(x) = 0$).

$$\begin{aligned} \mathbb{P}(f(x) \neq Y|X = x) - \mathbb{P}(f^*(x) \neq Y|X = x) &= \mathbb{P}(Y = 1|X = x) - \mathbb{P}(Y = 0|X = x) \\ &= \eta(x) - (1 - \eta(x)) = 2\eta(x) - 1 \end{aligned}$$

Cas 3 : $f(x) \neq f^*(x)$ et $\eta(x) < 1/2$ (donc $f^*(x) = 0$, $f(x) = 1$).

$$\begin{aligned} \mathbb{P}(f(x) \neq Y|X = x) - \mathbb{P}(f^*(x) \neq Y|X = x) &= \mathbb{P}(Y = 0|X = x) - \mathbb{P}(Y = 1|X = x) \\ &= (1 - \eta(x)) - \eta(x) = 1 - 2\eta(x) \end{aligned}$$

Dans les deux cas où $f(x) \neq f^*(x)$, la différence vaut $|2\eta(x) - 1|$. D'où :

$$\mathcal{E}(f) = \mathbb{E}[|2\eta(X) - 1| \mathbf{1}_{\{f(X) \neq f^*(X)\}}]$$

$\square$

1.3.3 Régression Logistique

Définition 1.19 (Régression logistique). En régression logistique, on paramètre la fonction de régression $\eta(X)$ via une fonction sigmoïde :

$$\eta(X) = \sigma(h^*(X)) = \frac{1}{1 + \exp(-h^*(X))} \quad (1.22)$$

où typiquement $h^*(X) = \langle X, \theta^* \rangle$ pour un certain vecteur de paramètres $\theta^* \in \mathbb{R}^d$.

Remarque. La régression logistique est un modèle **discriminatif** : on modélise directement $\mathbb{P}(Y|X)$ sans passer par la distribution jointe.

1.3.4 Modèle de Mélange Gaussien (GMM)

Définition 1.20 (Modèle de mélange gaussien). Dans ce modèle, les classes ont des probabilités a priori $\pi_k = \mathbb{P}(Y = k)$ et les caractéristiques suivent une loi normale par classe :

$$X|Y = k \sim \mathcal{N}_d(\mu_k, \Sigma_k) \quad (1.23)$$

Proposition 1.21 (Prédicteur de Bayes pour GMM). *Le prédicteur de Bayes est :*

$$g^*(x) \in \arg \max_{k \in \{1, \dots, K\}} \pi_k \varphi_d(x; \mu_k, \Sigma_k) \quad (1.24)$$

où φ_d désigne la densité de la loi normale multivariée.

Démonstration. Par la règle de Bayes :

$$\mathbb{P}(Y = k|X = x) = \frac{\mathbb{P}(X = x|Y = k) \cdot \mathbb{P}(Y = k)}{\mathbb{P}(X = x)} = \frac{\varphi_d(x; \mu_k, \Sigma_k) \cdot \pi_k}{\varphi_X(x)}$$

où la densité marginale de X est donnée par :

$$\varphi_X(x) = \sum_{j=1}^K \pi_j \varphi_d(x; \mu_j, \Sigma_j)$$

Ainsi, le classifieur de Bayes $f^*(x)$ maximise le numérateur :

$$f^*(x) \in \arg \max_{k \in \{1, \dots, K\}} \frac{\pi_k \varphi_d(x; \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \varphi_d(x; \mu_j, \Sigma_j)}$$

Ce qui revient à maximiser $\pi_k \varphi_d(x; \mu_k, \Sigma_k)$. □

Remarque. Le GMM est un modèle **génératif** : on modélise la distribution jointe $\mathbb{P}(X, Y) = \mathbb{P}(X|Y)\mathbb{P}(Y)$.

Approche Plug-in et Analyse Discriminante de Fisher

Dans la pratique, les paramètres $(\pi_k)_k, (\mu_k)_k, (\Sigma_k)_k$ sont inconnus. Nous ne pouvons pas calculer directement f^* . Nous devons estimer f^* par $\hat{f}$ à partir de l'échantillon d'apprentissage D_n .

L'approche "plug-in" consiste à considérer des estimateurs $\hat{\pi}_k, \hat{\mu}_k, \hat{\Sigma}_k$ des paramètres inconnus, calculés sur D_n , et à les substituer dans l'expression du prédicteur de Bayes (cette approche générale sera formellement détaillée dans la section 1.3.5).

On construit ainsi le prédicteur :

$$\hat{f}(x) \in \arg \max_{k \in \{1, \dots, K\}} \frac{\hat{\pi}_k \hat{\varphi}_k(x)}{\sum_{j=1}^K \hat{\pi}_j \hat{\varphi}_j(x)} \quad (1.25)$$

où $\hat{\varphi}_k$ est la densité de $\mathcal{N}_d(\hat{\mu}_k, \hat{\Sigma}_k)$.

Remarque (LDA vs QDA). Distinguer deux cas :

- **Cas 1** : $\Sigma_k = \Sigma$ pour tout k . Dans ce cas, on parle de **Linear Discriminant Analysis (LDA)**. Les frontières de décision sont linéaires.
- **Cas 2** : $\Sigma_k \neq \Sigma_{k'}$ pour $k \neq k'$. Dans ce cas, on parle de **Quadratic Discriminant Analysis (QDA)**. Les frontières de décision sont quadratiques.

Exemple 1.22 (Modèle Bernoulli-Gaussien).

Illustrons ces concepts avec un exemple concret et calculable explicitement. Considérons le cas binaire ($Y \in \{0, 1\}$) unidimensionnel ($d = 1$). Supposons que :

$$Y \sim \text{Bern}(1/2) \quad (\pi_0 = \pi_1 = 1/2)$$

et que conditionnellement à $Y = y$, X suit une loi normale :

$$X|Y = y \sim \mathcal{N}(\mu_y, \sigma^2)$$

avec $\mu_1 > \mu_0$ (et même variance σ^2).

On a par la formule de Bayes :

$$\mathbb{P}(Y = y|X = x) = \frac{\exp\left(-\frac{(x-\mu_y)^2}{2\sigma^2}\right)}{\exp\left(-\frac{(x-\mu_1)^2}{2\sigma^2}\right) + \exp\left(-\frac{(x-\mu_0)^2}{2\sigma^2}\right)}$$

(car les termes $1/(\sigma\sqrt{2\pi})$ et les probabilités a priori $1/2$ se simplifient au numérateur et au dénominateur).

Le classifieur de Bayes est défini par :

$$f^*(x) = \mathbf{1} \{ \mathbb{P}(Y = 1|X = x) \geq \mathbb{P}(Y = 0|X = x) \}$$

Ainsi :

$$\begin{aligned} \mathbb{P}(Y = 1|X = x) \geq \mathbb{P}(Y = 0|X = x) &\iff \mathbb{P}(Y = 1|X = x) \geq 1 - \mathbb{P}(Y = 1|X = x) \\ &\iff \mathbb{P}(Y = 1|X = x) \geq \frac{1}{2} \\ &\iff \frac{1}{2} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma^2}\right) \geq \frac{1}{2} \exp\left(-\frac{(x-\mu_0)^2}{2\sigma^2}\right) \\ &\iff -\frac{(x-\mu_1)^2}{2\sigma^2} \geq -\frac{(x-\mu_0)^2}{2\sigma^2} \\ &\iff (x-\mu_1)^2 \leq (x-\mu_0)^2 \\ &\iff x^2 - 2x\mu_1 + \mu_1^2 \leq x^2 - 2x\mu_0 + \mu_0^2 \\ &\iff -2x\mu_1 + \mu_1^2 \leq -2x\mu_0 + \mu_0^2 \\ &\iff 2x\mu_1 - 2x\mu_0 \geq \mu_1^2 - \mu_0^2 \\ &\iff 2x(\mu_1 - \mu_0) \geq \mu_1^2 - \mu_0^2 \\ &\iff x(\mu_1 - \mu_0) \geq \frac{\mu_1^2 - \mu_0^2}{2} \\ &\iff x \geq \frac{\mu_1 + \mu_0}{2} \quad (\text{car } \mu_1 - \mu_0 > 0) \end{aligned}$$

Comme $\mu_1 > \mu_0$, le point milieu est $(\mu_0 + \mu_1)/2$. La condition équivaut à $x \geq \frac{\mu_0 + \mu_1}{2}$.

Interprétation : Puisque les variances sont identiques, la frontière de décision optimale se situe exactement au milieu du segment reliant les deux moyennes. Le modèle choisit la classe dont la moyenne est la plus proche de l'observation x .

Remarque (Généralisation à $\mathbb{R}^d$). Ce résultat se généralise en dimension d . Si $\Sigma_0 = \Sigma_1 = \Sigma = I_d$ (identité), la frontière de décision est un hyperplan affine défini par :

$$f^*(x) = \mathbf{1} \left\{ x^\top (\mu_1 - \mu_0) \geq \frac{1}{2} (\|\mu_1\|^2 - \|\mu_0\|^2) \right\}$$

Exercice 1.23 (Calcul du Risque de Bayes). Exprimer le risque de Bayes $R(f^*)$ pour cet exemple en fonction de la fonction de répartition Φ de la loi normale standard.

Correction : Par définition du risque, on a :

$$\begin{aligned} R(f^*) &= \mathbb{P}(f^*(X) \neq Y) \\ &= \mathbb{P}(Y = 1, f^*(X) = 0) + \mathbb{P}(Y = 0, f^*(X) = 1) \\ &= \mathbb{P}(Y = 1) \mathbb{P}(f^*(X) = 0 | Y = 1) + \mathbb{P}(Y = 0) \mathbb{P}(f^*(X) = 1 | Y = 0) \end{aligned}$$

Comme $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$, on obtient :

$$\begin{aligned} \mathbb{P}(f^*(X) = 0 | Y = 1) &= \mathbb{P} \left(X < \frac{\mu_1 + \mu_0}{2} \middle| Y = 1 \right) \\ &= \mathbb{P} \left(\frac{X - \mu_1}{\sigma} < \frac{\frac{\mu_1 + \mu_0}{2} - \mu_1}{\sigma} \middle| Y = 1 \right) \\ &= \mathbb{P} \left(Z < \frac{\mu_0 - \mu_1}{2\sigma} \right) \quad \text{où } Z \sim \mathcal{N}(0, 1) \\ &= \Phi \left(\frac{\mu_0 - \mu_1}{2\sigma} \right) \end{aligned}$$

où Φ est la fonction de répartition (c.d.f.) de la loi $\mathcal{N}(0, 1)$.

De même, par symétrie :

$$\mathbb{P}(f^*(X) = 1 | Y = 0) = \mathbb{P} \left(X \geq \frac{\mu_1 + \mu_0}{2} \middle| Y = 0 \right) = \Phi \left(\frac{\mu_0 - \mu_1}{2\sigma} \right)$$

Ainsi, le risque de Bayes est :

$$R(f^*) = \Phi \left(\frac{\mu_0 - \mu_1}{2\sigma} \right) = \Phi \left(-\frac{\mu_1 - \mu_0}{2\sigma} \right)$$

Or, on sait que $\forall z \in \mathbb{R}, \Phi(z) + \Phi(-z) = 1$. D'où :

$$R(f^*) = 1 - \Phi \left(\frac{\mu_1 - \mu_0}{2\sigma} \right)$$

Exercice 1.24 (Généralisation à $\mathbb{R}^d$). Généraliser l'expression du risque de Bayes obtenue ci-dessus au cas multidimensionnel où $\mu_1, \mu_0 \in \mathbb{R}^d$ et $\Sigma = I_d$.

Correction : Dans le cas $\Sigma = I_d$, la frontière de décision est l'hyperplan médiateur du segment $[\mu_0, \mu_1]$. Le problème est invariant par rotation et dépend uniquement de la distance entre les moyennes projetée sur le vecteur discriminant $w = \mu_1 - \mu_0$. Le problème se ramène à un cas unidimensionnel le long de l'axe défini par $\mu_1 - \mu_0$. La distance effective entre les deux centres est $\|\mu_1 - \mu_0\|$. Par analogie avec le cas 1D où la distance était $|\mu_1 - \mu_0|$, le risque de Bayes devient :

$$R(f^*) = 1 - \Phi \left(\frac{\|\mu_1 - \mu_0\|}{2\sigma} \right)$$

1.3.5 Analyse Générale du Classifieur Plug-in

Cette sous-section formalise l'approche du "Plug-in Classifier" pour construire un classifieur à partir des données.

Définition et Approche

Supposons que la distribution conjointe (X, Y) soit inconnue. Le classifieur de Bayes est donné par :

$$f^*(x) \in \arg \max_{k \in \{1, \dots, K\}} P_k(x)$$

où $P_k(x) = \mathbb{P}(Y = k | X = x)$.

Définition 1.25 (Classifieur Plug-in). Le **Classifieur Plug-in** $\hat{f}$ est défini en remplaçant les probabilités réelles P_k (ou plus généralement tout paramètre inconnu du problème) par des estimateurs $\hat{P}_k$ construits à partir des données :

$$\hat{f}(x) \in \arg \max_{k \in \{1, \dots, K\}} \hat{P}_k(x)$$

où $\hat{P}_k$ est un estimateur de P_k .

Borne sur le Risque en Excès

Nous avons le résultat fondamental suivant qui lie la performance du classifieur plug-in à la qualité de l'estimation des probabilités conditionnelles.

Théorème 1.26 (Borne du classifieur Plug-in). *Le risque en excès du classifieur plug-in est borné par l'erreur d'estimation L^1 des probabilités conditionnelles :*

$$R(\hat{f}) - R(f^*) \leq \sum_{k=1}^K \mathbb{E} [|\hat{P}_k(X) - P_k(X)|]$$

Démonstration. Considérons la différence des risques conditionnels en un point x . On sait que (voir section précédente) :

$$\mathbb{P}(f^*(X) \neq Y | X = x) - \mathbb{P}(\hat{f}(X) \neq Y | X = x) = P_{f^*(x)}(x) - P_{\hat{f}(x)}(x)$$

Cependant, ceci est négatif car f^* est optimal. Utilisons plutôt la notation du risque en excès. On a :

$$R(\hat{f}) - R(f^*) = \mathbb{E} [P_{f^*(X)}(X) - P_{\hat{f}(X)}(X)]$$

En effet, minimiser le risque revient à maximiser la probabilité de la bonne classe. Pour un x donné, notons $k^* = f^*(x)$ et $\hat{k} = \hat{f}(x)$. Si $k^* = \hat{k}$, la différence est nulle. Sur l'événement $\{f^*(x) \neq \hat{f}(x)\}$, nous avons :

$$\begin{aligned} P_{f^*(x)}(x) - P_{\hat{f}(x)}(x) &= P_{f^*(x)}(x) - \hat{P}_{f^*(x)}(x) + \hat{P}_{f^*(x)}(x) - P_{\hat{f}(x)}(x) \\ &= \left(P_{f^*(x)}(x) - \hat{P}_{f^*(x)}(x) \right) + \left(\hat{P}_{f^*(x)}(x) - \hat{P}_{\hat{f}(x)}(x) \right) + \left(\hat{P}_{\hat{f}(x)}(x) - P_{\hat{f}(x)}(x) \right) \end{aligned}$$

Par définition de $\hat{f}$, $\hat{f}(x)$ maximise $\hat{P}_k(x)$, donc :

$$\hat{P}_{\hat{f}(x)}(x) \geq \hat{P}_{f^*(x)}(x) \implies \hat{P}_{f^*(x)}(x) - \hat{P}_{\hat{f}(x)}(x) \leq 0$$

Ainsi :

$$\begin{aligned} P_{f^*(x)}(x) - P_{\hat{f}(x)}(x) &\leq P_{f^*(x)}(x) - \hat{P}_{f^*(x)}(x) + \hat{P}_{\hat{f}(x)}(x) - P_{\hat{f}(x)}(x) \\ &\leq |P_{f^*(x)}(x) - \hat{P}_{f^*(x)}(x)| + |\hat{P}_{\hat{f}(x)}(x) - P_{\hat{f}(x)}(x)| \\ &\leq \sum_{k=1}^K |P_k(x) - \hat{P}_k(x)| \end{aligned}$$

En prenant l'espérance, on obtient le résultat :

$$\mathbb{E}[R(\hat{f}) - R(f^*)] \leq \sum_{k=1}^K \mathbb{E}[|\hat{P}_k(X) - P_k(X)|]$$

□

Consistance

Corollaire 1.27 (Consistance). *Si les estimateurs $\hat{P}_k$ sont consistants (i.e., convergent vers P_k en probabilité ou p.s.), alors le classifieur plug-in associé $\hat{f}$ est **consistant**, c'est-à-dire :*

$$R(\hat{f}) \rightarrow R(f^*) \quad \text{quand } n \rightarrow \infty$$

Remarque (Cas Binaire). Dans le cas binaire où $Y \in \{0, 1\}$, on denote souvent $\eta(x) = \mathbb{P}(Y = 1|X = x)$. Le classifieur de Bayes est $f^*(x) = \mathbf{1}\{\eta(x) \geq 1/2\}$. Le classifieur plug-in est $\hat{f}(x) = \mathbf{1}\{\hat{\eta}(x) \geq 1/2\}$.

Analyse Détaillée du Cas Binaire

Approfondissons le cas où $\mathcal{Y} = \{0, 1\}$. Soit $\hat{\eta}$ un estimateur de la fonction de régression η . Nous avons le résultat suivant pour l'excès de risque :

Proposition 1.28 (Excès de risque en classification binaire).

$$\mathbb{E}[R(\hat{f}) - R(f^*)] = \mathbb{E} \left[|2\eta(X) - 1| \cdot \mathbf{1}_{\{\hat{f}(X) \neq f^*(X)\}} \right]$$

Démonstration. Sur l'événement $\{\hat{f}(X) \neq f^*(X)\}$, on commet une erreur. Sans perte de généralité, supposons pour un x donné que $f^*(x) = 1$. Cela implique que $\eta(x) \geq 1/2$. Si $\hat{f}(x) \neq f^*(x)$, alors $\hat{f}(x) = 0$, ce qui implique $\hat{\eta}(x) < 1/2$. Dans ce cas, la différence des probabilités conditionnelles est :

$$P_{f^*(x)}(x) - P_{\hat{f}(x)}(x) = \eta(x) - (1 - \eta(x)) = 2\eta(x) - 1 = |2\eta(x) - 1|$$


De même, si $f^*(x) = 0$ (donc $\eta(x) < 1/2$) et $\hat{f}(x) = 1$ (donc $\hat{\eta}(x) \geq 1/2$), la différence est :

$$P_{f^*(x)}(x) - P_{\hat{f}(x)}(x) = (1 - \eta(x)) - \eta(x) = 1 - 2\eta(x) = |2\eta(x) - 1|$$

D'où le résultat en prenant l'espérance. □

Cette situation peut être visualisée comme suit. L'erreur se produit lorsque $\eta(x)$ et $\hat{\eta}(x)$ sont de part et d'autre du seuil $1/2$.

Sur l'événement $\{\hat{f}(x) \neq f^*(x)\}$



Sur l'événement $\{\hat{f}(x) \neq f^*(x)\}$, nous avons donc :

$$|\hat{\eta}(x) - \eta(x)| \geq |\eta(x) - 1/2|$$

Cela implique (en utilisant l'expression précédente de l'excès de risque) :

$$\mathbb{E}[R(\hat{f}) - R(f^*)] = 2\mathbb{E}\left[\left|\eta(X) - \frac{1}{2}\right| \mathbf{1}_{\{\hat{f}(X) \neq f^*(X)\}}\right]$$

En utilisant l'inégalité démontrée ci-dessus sur l'événement erreur, nous pouvons majorer ce terme :

$$\mathbb{E}[R(\hat{f}) - R(f^*)] \leq 2\mathbb{E}\left[|\hat{\eta}(X) - \eta(X)| \mathbf{1}_{\{\hat{f}(X) \neq f^*(X)\}}\right] \leq 2\mathbb{E}[|\hat{\eta}(X) - \eta(X)|]$$

Ainsi, la performance du classifieur plug-in est directement contrôlée par la qualité d'estimation L^1 de la fonction de régression η .

Définition 1.29 (Estimateur des k-Plus Proches Voisins (k-NN) en classification). L'estimateur k-NN a été défini en régression (voir Théorème 1.13). En classification, le principe est similaire. Soit $D_n = \{(X_i, Y_i)\}_{i=1}^n$ l'échantillon d'apprentissage et $k \geq 1$ un entier. Pour tout $x \in \mathbb{R}^d$, considérons les données réordonnées selon la distance euclidienne $d(x, X_i) = \|x - X_i\|$, notées $X_{(1)}(x), \dots, X_{(n)}(x)$. Soit $Y_{(i)}(x)$ l'étiquette associée à $X_{(i)}(x)$. L'estimateur de la probabilité conditionnelle $P_j(x) = \mathbb{P}(Y = j | X = x)$ est donné par la proportion de voisins de classe j parmi les k plus proches :


$$\hat{P}_j(x) = \frac{1}{k} \sum_{i=1}^k \mathbf{1}_{\{Y_{(i)}(x)=j\}}$$

Le classifieur des k-NN est alors défini par le principe "Plug-in" (vote majoritaire) :

$$\hat{f}_{kNN}(x) \in \arg \max_{j \in \{1, \dots, K\}} \hat{P}_j(x)$$

Exemple 1.30 (Illustration k-NN ($k = 3$ en $\mathbb{R}^2$)).

La figure suivante illustre le principe de décision pour $k = 3$ dans un problème à deux classes (ronds et carrés).



Pour le point x , la majorité des 3 voisins sont des ronds $\Rightarrow$ Classe "Rond". Pour le point x' , la majorité des 3 voisins sont des carrés $\Rightarrow$ Classe "Carré".

1.3.6 Minimisation du Risque Empirique (Empirical Risk Minimization en classification)

Le classifieur de Bayes f^* est caractérisé par :

$$f^* \in \arg \min_f R(f)$$

où $R(f) = \mathbb{P}(f(X) \neq Y)$ est le risque théorique.

Principe de l'ERM

En pratique, le risque $R(f)$ est inconnu car la distribution (X, Y) n'est pas accessible. On dispose uniquement d'un échantillon d'apprentissage $D_n = \{(X_i, Y_i)\}_{i=1}^n$.

Définition 1.31 (Risque Empirique). Soit $\mathcal{F}$ une classe de prédicteurs (modèle). Le risque empirique d'un prédicteur $f \in \mathcal{F}$ est défini par :

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{f(X_i) \neq Y_i\}}$$

L'estimateur par minimisation du risque empirique (ERM) est :

$$\hat{f} \in \arg \min_{f \in \mathcal{F}} \hat{R}(f) = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{f(X_i) \neq Y_i\}}$$

$\hat{f}$ est appelé **empirical risk estimator**.

Difficultés de l'ERM

Remarque (Deux problèmes majeurs). L'optimisation directe de l'ERM pose deux difficultés :

1. **La perte 0-1 n'est pas convexe.** La fonction indicatrice $\mathbf{1}_{\{f(x) \neq y\}}$ n'est pas une fonction convexe, ce qui rend l'optimisation difficile.
2. **L'ensemble des classifieurs n'est pas convexe.** L'espace $\mathcal{F}$ des classifieurs possibles n'a généralement pas de structure convexe.

Solution : Surrogate Convex

Pour éviter ces deux problèmes, on considère une **relaxation convexe** (convex surrogate) du problème initial.

Fonctions de Score Plutôt que de considérer directement un ensemble de classifieurs $f : \mathbb{R}^d \rightarrow \{1, \dots, K\}$, on considère un ensemble de **fonctions de score** :

$$h : \mathbb{R}^d \rightarrow \mathbb{R}$$

L'avantage est que l'ensemble des fonctions de score est un espace vectoriel : toute combinaison linéaire de fonctions de score est encore une fonction de score.

Remarque (Convexité). Si $\lambda \in [0, 1]$ et h, h' sont deux fonctions de score, alors $\lambda h + (1 - \lambda)h'$ est également une fonction de score. En revanche, si f, f' sont deux classifieurs, $\lambda f + \mu f'$ n'est **pas** un classifieur (la somme de deux fonctions à valeurs dans $\{0, 1\}$ n'est pas à valeurs dans $\{0, 1\}$).

Surrogate Loss Convexe On remplace également la perte 0-1 par une perte convexe (**surrogate loss**). Un exemple classique est la perte quadratique (L_2 loss) :

$$\ell(y, y') = (y - y')^2$$

Définition 1.32 (Encodage One-Hot). Pour la classification multiclasse avec K classes, on encode les étiquettes $y \in \{1, \dots, K\}$ comme des vecteurs $Z_k \in \{-1, +1\}^K$ définis par :

$$Z_k = 2\mathbf{1}_{\{Y=k\}} - 1, \quad k \in \{1, \dots, K\}$$

Autrement dit, $Z_k \in \{-1, +1\}$ et le vecteur complet est :

$$Z = (Z_1, \dots, Z_K)^\top = (2\mathbf{1}_{\{Y=1\}} - 1, \dots, 2\mathbf{1}_{\{Y=K\}} - 1)^\top$$

Vecteur de Fonctions de Score Considérons un vecteur de fonctions de score $\vec{h} = (h_1, \dots, h_K)$ où chaque $h_k : \mathbb{R}^d \rightarrow \mathbb{R}$ est une fonction de score.

Pour un vecteur $\vec{h}$ donné, on peut considérer son **classifieur associé** :

$$f_{\vec{h}}(x) \in \arg \max_{k \in \{1, \dots, K\}} h_k(x)$$

Risque L_2 Pour un vecteur $\vec{h}$ de fonctions de score, on définit son risque L_2 associé :

$$R_2(\vec{h}) = \sum_{k=1}^K \mathbb{E} \left[(Z_k - h_k(X))^2 \right]$$

Si on considère le risque empirique associé :

$$\hat{R}_2(\vec{h}) = \frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K (Z_k^i - h_k(X_i))^2$$

avec $Z_k^i = 2\mathbf{1}_{\{Y_i=k\}} - 1$.

On choisit un modèle $\mathcal{H}$ (un ensemble de vecteurs de fonctions de score).

ERM avec Surrogate L_2

L'estimateur par minimisation du risque empirique (ERM) est :

$$\hat{\vec{h}} \in \arg \min_{\vec{h} \in \mathcal{H}} \hat{R}_2(\vec{h})$$

C'est la **convexification de l'ERM en classification**.

Remarque (Minimiseur du risque L_2). Le minimiseur du risque L_2 est :

$$\vec{h}^* \in \arg \min_{\vec{h}} R_2(\vec{h})$$

On peut calculer explicitement :

$$h_k^*(x) = \mathbb{E}[Z_k|X = x] = 2\mathbb{E}[\mathbf{1}_{\{Y=k\}}|X = x] - 1 = 2P_k(x) - 1 \quad \forall k$$

Le classifieur associé au minimiseur est :

$$\begin{aligned} f_{\vec{h}^*}(x) &\in \arg \max_k h_k^*(x) \\ &= \arg \max_k (2P_k(x) - 1) \\ &= \arg \max_k P_k(x) \\ &= f^*(x) \quad \text{p.s.} \end{aligned}$$

Zhang's Lemma et Consistance

Théorème 1.33 (Zhang's Lemma (2004) - Pour la perte L_2). *Pour toute fonction de score $\vec{h}$ et son classifieur associé $f_{\vec{h}}$, on a :*

$$R(f_{\vec{h}}) - R(f^*) \leq \frac{1}{\sqrt{2}} \left(R_2(\vec{h}) - R_2(\vec{h}^*) \right)^{1/2}$$

Corollaire 1.34 (Consistance via le risque surrogate). *Si $\hat{\vec{h}}$ est consistant par rapport au risque R_2 (i.e., $R_2(\hat{\vec{h}}) \rightarrow R_2(\vec{h}^*)$ quand $n \rightarrow \infty$), alors le classifieur associé $f_{\hat{\vec{h}}}$ est consistant par rapport au risque R :*

$$R(f_{\hat{\vec{h}}}) \rightarrow R(f^*) \quad \text{quand } n \rightarrow \infty$$

Ce résultat justifie l'utilisation de la perte L_2 comme surrogate convexe de la perte 0-1 en classification.

1.4 Limites de l'ERM et Transition vers l'Équité

Tout au long de ce chapitre, nous avons cherché à construire des fonctions de décision f minimisant un risque global $R(f) = \mathbb{E}[L(f(X), Y)]$. L'approche par Minimisation du Risque Empirique (ERM) vise explicitement à maximiser la performance moyenne sur l'ensemble de la population, souvent au détriment des sous-groupes minoritaires.

En effet, si un groupe représente une faible proportion de l'échantillon d'apprentissage D_n , une erreur de prédiction sur ce groupe aura un impact négligeable sur le risque empirique global $\hat{R}(f)$. L'algorithme a donc naturellement tendance à optimiser ses prédictions pour le groupe majoritaire, quitte à être systématiquement inexact pour les minorités.

De plus, les données D_n peuvent elles-mêmes contenir des biais historiques ou sociaux profonds (ex : discriminations passées à l'embauche ou dans l'octroi de crédits), que l'algorithme se contentera de reproduire ou d'amplifier. La recherche de la seule performance prédictive pure (accuracy) n'est donc pas suffisante dans des applications critiques où les décisions ont un impact humain fort.

C'est pour répondre à cette limitation fondamentale de l'E.R.M. standard que nous introduisons au chapitre suivant les notions d'**Équité Algorithmique** (Algorithmic Fairness), afin de contraindre mathématiquement nos modèles à traiter les différents groupes de manière équitable.

Chapitre 2

Équité Algorithmique (Algorithmic Fairness)

2.1 Fondements de l'équité (Fairness)

L'adoption croissante d'algorithmes d'apprentissage automatique dans des domaines critiques tels que les admissions universitaires, les diagnostics médicaux, les décisions de justice ou encore l'octroi de crédits bancaires a soulevé des enjeux éthiques fondamentaux. L'équité algorithmique (Algorithmic Fairness) vise à atténuer les biais contenus dans les données historiques et à s'assurer qu'un algorithme ne discrimine pas les individus selon un ou plusieurs attributs dits *sensibles* ou *protégés* (sexe, origine, situation de famille, etc.).

2.1.1 Origines des discriminations algorithmiques

Les biais aboutissant à des discriminations algorithmiques peuvent provenir de plusieurs sources :

- Une discrimination intentionnelle.
- Des biais historiques profondément ancrés dans la base de données d'apprentissage.
- Un biais lié à l'échantillonnage des données (si la base de données d'entraînement n'est pas représentative de la population globale).
- Un biais lié aux objectifs mathématiques fixés à l'algorithme (qui a souvent tendance à optimiser les profits pour le groupe majoritaire en délaissant les minorités).

2.1.2 Awareness vs Unawareness

La formalisation de la notion d'équité confronte deux visions majeures :

- **Fairness through awareness** : Le modèle a directement accès à l'attribut sensible S lors de l'apprentissage et de la prédiction ($f(X, S)$). L'inconvénient est que le système utilise ouvertement l'information sensible pour statuer.
- **Fairness through unawareness** : Le modèle ignore aveuglément la variable S et ne prédit qu'à l'aide du reste des variables ($f(X)$), pour éviter toute discrimination directe. Cette situation simule également le cas où l'information S n'est légalement pas disponible au moment de la prédiction, formant un modèle de *Disparate learning process*.

2.1.3 L'Illusion de l'Unawareness (Discrimination Indirecte)

Il est faux de croire qu'ignorer l'attribut sensible (S) résout automatiquement les problèmes d'équité. En effet, l'attribut S n'est pratiquement jamais indépendant des autres caractéristiques X (exemple : un code postal peut trahir fortement l'origine socio-économique d'une personne).

Ainsi, retirer manuellement S revient à plonger dans la **discrimination indirecte**, expressément pointée par la loi (Article 1 de la loi française n° 2008-496) : l'algorithme trouvera des corrélations latentes pour reproduire la discrimination à travers des variables apparemment neutres. L'absence de l'information (unawareness) n'apporte donc pas d'équité algorithmique.

2.1.4 Équité individuelle vs Équité de groupe

Deux visions philosophiques s'opposent quant à la considération de l'équité :

1. **Équité individuelle (Individual fairness)** : Le dogme imposant que des « individus similaires doivent recevoir des traitements similaires ». L'algorithme doit alors estimer mathématiquement la similarité entre les individus.
2. **Équité de groupe (Group fairness)** : Le dogme selon lequel des métriques de traitements doivent valoir de façon égale à l'échelle des diverses populations ou communautés.

Le cours se focalise sur l'*Équité de groupe*. Soit l'entrée $Z = (X, S)$ ou $Z = X$ (selon le niveau d'awareness). Le but mathématique est de viser mathématiquement soit à l'Indépendance globale ($f(Z) \perp\!\!\!\perp S$), soit à la Séparation locale conditionnée au résultat ($f(Z) \perp\!\!\!\perp S \mid Y$).

2.1.5 Théorème de l'impossibilité

Il existe un résultat fondamental démontrant les limites intrinsèques des algorithmes quant à la satisfaction absolue de plusieurs définitions d'équité : un classifieur f ne peut satisfaire **simultanément** l'indépendance parfaite vis-à-vis de l'attribut sensible **et** la séparation sur les labels, hormis dans des scénarios dégénérés (soit les labels de la vie réelle Y sont déjà originellement parfaitement indépendants de S , soit la prédiction de l'algorithme $f(Z)$ ignore fondamentalement Y et fait des prédictions aléatoires). Il faut donc faire un choix de modélisation mathématique selon le domaine.

2.2 Autres métriques et taxonomie des méthodes

Bien que ce chapitre se focalise sur une contrainte spécifique, d'autres métriques mathématiques importantes définissent l'équité de groupe dans le cas de classifications binaires (où $S \in \mathcal{S}$ et $Y \in \{0, 1\}$) :

- **Demographic Parity (DP)** : Le taux de prédiction positive doit être similaire d'un groupe à un autre. $\mathbb{P}(f(Z) = 1 | S = s) = \mathbb{P}(f(Z) = 1)$.
- **Equalized odds (EOd)** : Il s'agit des taux de vrais positifs et de faux positifs qui doivent être identiques d'un groupe à un autre. $\mathbb{P}(f(Z) = y | S = s, Y = y) = \mathbb{P}(f(Z) = y | Y = y)$ (pour $y \in \{0, 1\}$).
- **Equal opportunity (EO)** : Plus clément que l'EOd, requiert seulement l'égalisation des taux de Vrais Positifs (les résultats bénéfiques pour le candidat). $\mathbb{P}(f(Z) = 1 | S = s, Y = 1) = \mathbb{P}(f(Z) = 1 | Y = 1)$.

2.2.1 Grandes familles d'approches

Pour forcer le respect de ces contraintes, les méthodes se rangent en trois catégories :

1. **Pre-processing** : Vise à modifier, en première intention, la base de données. Il s'agit de trouver une représentation modifiée $\phi(Z)$ des données telle que $\phi(Z)$ soit mathématiquement indépendante de S , puis d'entraîner tout modèle standard innocent sur ϕ .
2. **In-processing** : Basée sur de l'Empirical Risk Minimization, cette méthode intègre la contrainte d'équité directement dans la fonction Lagrangienne de coût du modèle durant l'apprentissage $\min_f \hat{R}(f) + \lambda \hat{C}(f)$.

3. **Post-processing** : Procédure plus a posteriori. L'algorithme principal $\hat{f}$ est d'abord entraîné sans considération d'équité en cherchant la performance pure. Dans un second temps, on trouve a posteriori une transformation $\hat{T}$ qui altère la prédiction pour que $\hat{T}(\hat{f})$ respecte exactement la contrainte d'équité ciblée.

2.3 Classification sous Post-Processing et contrainte DP

2.3.1 Notations du Problème Initial

- Une observation est un triplet (X, S, Y) .
- $X \in \mathbb{R}^d$ représente les caractéristiques (features).
- $S \in \{-1, 1\}$ est l'attribut sensible (sensitive attribute).
- $Y \in \{0, 1\}$ est la sortie (label).

Un prédicteur (ou classifieur) f est une fonction de (X, S) telle que $f(X, S) \in \{0, 1\}$. Nous considérons le risque de mauvaise classification (*misclassification risk*) :

$$R(f) = \mathbb{P}(f(X, S) \neq Y) \quad (2.1)$$

comme mesure de performance.

Dans ce cas, le prédicteur optimal (ou Classifieur de Bayes) qui satisfait :

$$f^* \in \arg \min_f R(f) \quad (2.2)$$

est défini par :

$$f^*(X, S) = \mathbf{1}\{\eta(X, S) \geq 1/2\} \quad (2.3)$$

où $\eta(X, S) = \mathbb{P}(Y = 1|X, S)$.

2.3.2 Définition de l'Équité (Fairness)

Nous considérons la contrainte de Parité Démographique (Demographic Parity constraint ou DP-constraint). Nous disons qu'un prédicteur f satisfait la contrainte DP si (comme vu intuitivement à la section 2) :

$$\forall s \in \{-1, 1\}, \quad \mathbb{P}(f(X, S) = 1|S = s) = \mathbb{P}(f(X, S) = 1) \quad (2.4)$$

Ceci équivaut aux propriétés suivantes :

$$\begin{aligned} f(X, S) \perp\!\!\!\perp S &\iff \mathbb{P}(f(X, S) = 1|S = 1) = \mathbb{P}(f(X, S) = 1|S = -1) \\ &\iff \sum_{s \in \{-1, 1\}} s \cdot \mathbb{P}(f(X, S) = 1|S = s) = 0 \end{aligned}$$

2.3.3 Classifieur Optimal sous Contrainte DP

Nous considérons f_{fair}^* défini comme :

$$f_{fair}^* \in \arg \min_{f \text{ satisfaisant DP}} R(f) \quad (2.5)$$

Ceci est équivalent à résoudre le problème d'optimisation sous contrainte :

$$\begin{aligned} f_{fair}^* \in & \arg \min_f R(f) \\ \text{t.q. } & \sum_{s \in \{-1, 1\}} s \cdot \mathbb{P}(f(X, S) = 1|S = s) = 0 \end{aligned} \quad (2.6)$$

Le Lagrangien associé s'écrit comme suit :

$$\mathcal{L}(f, \lambda) = R(f) + \lambda \sum_{s \in \{-1, 1\}} s \mathbb{P}(f(X, S) = 1 | S = s) \quad (2.7)$$

En introduisant la notation $\mathbb{P}(\cdot | S = s) := \mathbb{P}_{X|S=s}(\cdot)$, on a :

$$\mathcal{L}(f, \lambda) = R(f) + \lambda \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f(X, S) = 1) \quad (2.8)$$

Pour résoudre le problème d'optimisation :

$$f_{fair}^* \in \arg \min_{f \text{ satisfaisant DP}} R(f) \quad (2.9)$$

nous devons résoudre le problème d'optimisation suivant (problème primal) :

$$\min_f \max_{\lambda} \mathcal{L}(f, \lambda) \quad (2.10)$$

En général, nous résolvons le problème dual :

$$\max_{\lambda} \min_f \mathcal{L}(f, \lambda) \quad (*)$$

Nous avons toujours la propriété suivante (*principe de dualité faible*) :

$$\min_f \max_{\lambda} \mathcal{L}(f, \lambda) \geq \max_{\lambda} \min_f \mathcal{L}(f, \lambda) \quad (2.11)$$

Nous résolvons le problème (*) et montrons que :

$$\min_f \max_{\lambda} \mathcal{L}(f, \lambda) = \max_{\lambda} \min_f \mathcal{L}(f, \lambda) \quad (2.12)$$

C'est-à-dire qu'il n'y a pas de saut de dualité (*no duality gap*, ou dualité forte).

2.3.4 Résolution du Problème Dual

Le but est d'obtenir une expression analytique (*closed form expression*) du prédicteur optimal f_{fair}^* .

Première étape : Minimisation par rapport à f

Pour tout $\lambda \in \mathbb{R}$ fixé, nous cherchons à résoudre :

$$\min_f \mathcal{L}(f, \lambda) \quad (2.13)$$

Rappelons l'expression du Lagrangien :

$$\mathcal{L}(f, \lambda) = R(f) + \lambda \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f(X, S) = 1) \quad (2.14)$$

Le risque s'écrit comme une espérance :

$$\begin{aligned} R(f) &= \mathbb{P}(f(X, S) \neq Y) \\ &= \mathbb{E}[\mathbf{1}\{f(X, S) \neq Y\}] \end{aligned}$$

En conditionnant par rapport à Y , on obtient :

$$R(f) = \mathbb{E}[\mathbf{1}\{f(X, S) \neq Y\} \mathbf{1}\{Y = 0\}] + \mathbb{E}[\mathbf{1}\{f(X, S) \neq Y\} \mathbf{1}\{Y = 1\}]$$

Pour tout $y \in \{0, 1\}$, en utilisant la loi des espérances itérées par rapport à (X, S) :

$$\begin{aligned}\mathbb{E}[\mathbf{1}\{f(X, S) \neq y\} \mathbf{1}\{Y = y\}] &= \mathbb{E}[\mathbb{E}[\mathbf{1}\{f(X, S) \neq y\} \mathbf{1}\{Y = y\} | X, S]] \\ &= \mathbb{E}[\mathbf{1}\{f(X, S) \neq y\} \mathbb{E}[\mathbf{1}\{Y = y\} | X, S]] \\ &= \mathbb{E}[\mathbf{1}\{f(X, S) \neq y\} \mathbb{P}(Y = y | X, S)]\end{aligned}$$

En notant $\eta(X, S) = \mathbb{P}(Y = 1 | X, S)$, on a $\mathbb{P}(Y = 0 | X, S) = 1 - \eta(X, S)$. Ainsi, le risque devient :

$$R(f) = \mathbb{E}[\mathbf{1}\{f(X, S) \neq 0\}(1 - \eta(X, S))] + \mathbb{E}[\mathbf{1}\{f(X, S) \neq 1\}\eta(X, S)]$$

Puisque $f(X, S) \in \{0, 1\}$, nous avons les identités suivantes :

$$\begin{aligned}\mathbf{1}\{f(X, S) \neq 0\} &= \mathbf{1}\{f(X, S) = 1\} = f(X, S) \\ \mathbf{1}\{f(X, S) \neq 1\} &= \mathbf{1}\{f(X, S) = 0\} = 1 - f(X, S)\end{aligned}$$

En substituant ces identités dans l'expression du risque, on obtient :

$$\begin{aligned}R(f) &= \mathbb{E}[f(X, S)(1 - \eta(X, S))] + \mathbb{E}[(1 - f(X, S))\eta(X, S)] \\ &= \mathbb{E}[f(X, S)(1 - 2\eta(X, S))] + \mathbb{E}[\eta(X, S)]\end{aligned}$$

De plus, par la loi des espérances itérées :

$$\begin{aligned}\mathbb{E}[\eta(X, S)] &= \mathbb{E}[\mathbb{P}(Y = 1 | X, S)] \\ &= \mathbb{E}[\mathbb{E}[\mathbf{1}\{Y = 1\} | X, S]] \\ &= \mathbb{E}[\mathbf{1}\{Y = 1\}] \\ &= \mathbb{E}[Y]\end{aligned}$$

car $Y \in \{0, 1\}$, donc $\mathbb{E}[Y | X, S] = \mathbb{P}(Y = 1 | X, S) = \eta(X, S)$. Ainsi :

$$R(f) = \mathbb{E}[Y] + \mathbb{E}[f(X, S)(1 - 2\eta(X, S))] \quad (2.15)$$

Notons $\pi_s = \mathbb{P}(S = s)$. Nous pouvons décomposer l'espérance sur S :

$$\begin{aligned}R(f) &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{P}(S = s) \mathbb{E}_{X|S=s}[f(X, S)(1 - 2\eta(X, S))] \\ &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \pi_s \mathbb{E}_{X|S=s}[f(X, S)(1 - 2\eta(X, S))]\end{aligned}$$

Reprenons le Lagrangien :

$$\begin{aligned}\mathcal{L}(f, \lambda) &= R(f) + \lambda \sum_{s \in \{-1, 1\}} s \mathbb{E}_{X|S=s}[f(X, S)] \\ &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \pi_s \mathbb{E}_{X|S=s}[f(X, S)(1 - 2\eta(X, S))] + \sum_{s \in \{-1, 1\}} \lambda s \mathbb{E}_{X|S=s}[f(X, S)] \\ &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s}[\pi_s f(X, S)(1 - 2\eta(X, S)) + \lambda s f(X, S)] \\ &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s}[(\pi_s(1 - 2\eta(X, S)) + \lambda s) f(X, S)]\end{aligned}$$

Ainsi, chercher $f_\lambda^* \in \arg \min_f \mathcal{L}(f, \lambda)$ revient à minimiser point par point le terme sous l'espérance. Puisque $f(X, S) \in \{0, 1\}$, pour minimiser une expression de la forme $A \cdot f(X, S)$, nous choisissons :

$$f(X, S) = 1 \iff A < 0$$

Ici, $A = \pi_s(1 - 2\eta(X, S)) + \lambda s$. Nous avons donc :

$$\begin{aligned} f_\lambda^*(X, S) = 1 &\iff \pi_s(1 - 2\eta(X, S)) + \lambda s < 0 \\ &\iff 1 - 2\eta(X, S) < -\frac{\lambda s}{\pi_s} \\ &\iff 2\eta(X, S) > 1 + \frac{\lambda s}{\pi_s} \\ &\iff \eta(X, S) > \frac{1}{2} + \frac{\lambda s}{2\pi_s} \end{aligned}$$

Le prédicteur optimal pour un λ fixé est donc :

$$f_\lambda^*(X, S) = \mathbf{1} \left\{ \eta(X, S) > \frac{1}{2} + \frac{\lambda s}{2\pi_s} \right\} \quad (2.16)$$

Deuxième étape : Maximisation par rapport à λ

Nous cherchons maintenant à résoudre :

$$\max_{\lambda \in \mathbb{R}} \mathcal{L}(f_\lambda^*, \lambda) \quad (2.17)$$

Soit λ^* la solution :

$$\lambda^* \in \arg \max_{\lambda \in \mathbb{R}} \mathcal{L}(f_\lambda^*, \lambda) \quad (2.18)$$

En réinjectant l'expression de f_λ^* dans le Lagrangien, on obtient pour tout $\lambda \in \mathbb{R}$:

$$\begin{aligned} \mathcal{L}(f_\lambda^*, \lambda) &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [(\pi_s(1 - 2\eta(X, S)) + \lambda s) f_\lambda^*(X, S)] \\ &= \mathbb{E}[Y] + \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\min(\pi_s(1 - 2\eta(X, S)) + \lambda s, 0)] \end{aligned} \quad (2.19)$$

Nous observons que :

$$\lambda^* \in \arg \max_{\lambda \in \mathbb{R}} \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\min(\pi_s(1 - 2\eta(X, S)) + \lambda s, 0)]$$

Ceci est équivalent à :

$$\lambda^* \in \arg \min_{\lambda \in \mathbb{R}} \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\max(\pi_s(2\eta(X, S) - 1) - \lambda s, 0)] \quad (2.20)$$

en utilisant l'identité $\max(A) = -\min(-A)$.

La fonction $\lambda \mapsto \max(\pi_s(2\eta(X, S) - 1) - \lambda s, 0)$ est convexe. Par conséquent, la fonction objectif :

$$\lambda \mapsto \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\max(\pi_s(2\eta(X, S) - 1) - \lambda s, 0)]$$

est convexe.

De plus, la fonction

$$\mathcal{H}(\lambda) = \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [\max(\pi_s(2\eta(X, S) - 1) - \lambda s, 0)] \quad (2.21)$$

est coercive, c'est-à-dire que $\lim_{|\lambda| \rightarrow +\infty} \mathcal{H}(\lambda) = +\infty$.

Exemple 2.1 (Exercice : Coercivité et bornes sur λ^*).

Énoncé : Montrer que la fonction $\lambda \mapsto \mathcal{H}(\lambda)$ est coercive et que le paramètre optimal vérifie $\lambda^* \in [-1, 1]$.

Correction :

1. **Coercivité de $\mathcal{H}(\lambda)$**

Rappelons que $\mathcal{H}(\lambda) = \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [(\pi_s(2\eta(X, S) - 1) - \lambda s)_+]$.

Étudions le comportement quand $\lambda \rightarrow +\infty$:

- Pour $s = 1$, le terme sous l'espérance est $(\pi_1(2\eta - 1) - \lambda)_+$. Puisque $2\eta - 1 \leq 1$ et $\pi_1 \leq 1$, on a $\pi_1(2\eta - 1) - \lambda \leq 1 - \lambda$. Pour $\lambda > 1$, ce terme est négatif, donc la partie positive est nulle.
- Pour $s = -1$, le terme est $(\pi_{-1}(2\eta - 1) + \lambda)_+$. Pour λ assez grand, $\pi_{-1}(2\eta - 1) + \lambda > 0$ presque sûrement. Le terme se comporte comme λ .

Ainsi, $\lim_{\lambda \rightarrow +\infty} \mathcal{H}(\lambda) = +\infty$. Un raisonnement symétrique s'applique pour $\lambda \rightarrow -\infty$ (le terme $s = 1$ domine). La fonction est donc coercive.

2. **Bornes sur λ^***

Montrons que pour tout $\lambda \geq 1$, $\mathcal{H}(\lambda) \geq \mathcal{H}(1)$ (et par symétrie pour $\lambda \leq -1$).

Soit $\lambda \geq 1$.

- Si $s = 1$: Comme vu précédemment, $\pi_1(2\eta - 1) - \lambda \leq \pi_1 - \lambda \leq 1 - 1 = 0$. Donc la contribution est nulle.
- Si $s = -1$: Le terme est $(\pi_{-1}(2\eta - 1) + \lambda)_+$. Or $2\eta - 1 \geq -1$, donc $\pi_{-1}(2\eta - 1) \geq -\pi_{-1}$. Ainsi $\pi_{-1}(2\eta - 1) + \lambda \geq -\pi_{-1} + \lambda$. Comme $\lambda \geq 1$ et $\pi_{-1} \leq 1$, ce terme est positif. La partie positive est donc simplement $\pi_{-1}(2\eta - 1) + \lambda$.

Ainsi, sur l'intervalle $[1, +\infty[$, $\mathcal{H}(\lambda) = \mathbb{E}_{X|S=-1}[\pi_{-1}(2\eta(X, S) - 1)] + \lambda$. C'est une fonction affine strictement croissante de λ .

Soit maintenant $\lambda \leq -1$.

- Si $s = -1$: Le terme est $(\pi_{-1}(2\eta - 1) + \lambda)_+$. Comme $\pi_{-1}(2\eta - 1) \leq \pi_{-1} \leq 1$ et $\lambda \leq -1$, la somme est négative. La contribution est nulle.
- Si $s = 1$: Le terme est $(\pi_1(2\eta - 1) - \lambda)_+$. Or $\pi_1(2\eta - 1) \geq -\pi_1$ et $-\lambda \geq 1$. Donc $\pi_1(2\eta - 1) - \lambda \geq 1 - \pi_1 \geq 0$. La partie positive est donc $\pi_1(2\eta - 1) - \lambda$.

Ainsi, sur l'intervalle $] -\infty, -1]$, $\mathcal{H}(\lambda) = \mathbb{E}_{X|S=1}[\pi_1(2\eta(X, S) - 1)] - \lambda$. C'est une fonction affine strictement décroissante de λ .

On en déduit que pour tout $|\lambda| > 1$, $\mathcal{H}(\lambda) > \min(\mathcal{H}(1), \mathcal{H}(-1))$. Par conséquent, le minimum global λ^* doit se trouver dans l'intervalle $[-1, 1]$.




FIGURE 2.1 – Densités du prédicteur équitable optimal g^* et seuils associés selon le groupe S

Remarque (Autre approche pour dériver le prédicteur équitable optimal). Nous avons établi que

pour tout $\lambda \in \mathbb{R}$, le minimiseur du lagrangien est donné par :

$$f_\lambda \in \arg \min_f \mathcal{L}(f, \lambda) \quad \text{et} \quad f_\lambda(X, S) = \mathbf{1}_{\{\eta(X, S) \geq \frac{1}{2} + \frac{\lambda s}{2\pi_s}\}}$$

Nous cherchons maintenant λ^* tel que f_{λ^*} satisfasse la contrainte de Parité Démographique (DP). C'est-à-dire que nous devons trouver λ^* tel que :

$$\mathbb{P}(f_{\lambda^*}(X, S) = 1 | S = 1) = \mathbb{P}(f_{\lambda^*}(X, S) = 1 | S = -1)$$

Notons par $F_s(t)$ la fonction de queue (ou survie) de $\eta(X, S)$ sachant $S = s$:

$$F_s(t) = \mathbb{P}(\eta(X, S) > t | S = s)$$

La condition $f_{\lambda^*}(X, s) = 1$ est équivalente à $\eta(X, s) \geq \frac{1}{2} + \frac{\lambda^* s}{2\pi_s}$.

Si nous supposons que la distribution de $\eta(X, S)$ sachant $S = s$ est continue (pour éviter les problèmes aux bornes des indicatrices), alors :

$$\mathbb{P}(f_{\lambda^*}(X, S) = 1 | S = s) = F_s\left(\frac{1}{2} + \frac{\lambda^* s}{2\pi_s}\right)$$

Nous devons donc résoudre l'équation suivante en λ :

$$F_1\left(\frac{1}{2} + \frac{\lambda}{2\pi_1}\right) = F_{-1}\left(\frac{1}{2} - \frac{\lambda}{2\pi_{-1}}\right)$$

Remarquons que :

- Le terme de gauche, $\lambda \mapsto F_1\left(\frac{1}{2} + \frac{\lambda}{2\pi_1}\right)$, est décroissant (car F_1 est décroissante et λ apparaît avec un signe +).
- Le terme de droite, $\lambda \mapsto F_{-1}\left(\frac{1}{2} - \frac{\lambda}{2\pi_{-1}}\right)$, est croissant (car F_{-1} est décroissante et λ apparaît avec un signe -).

Si l'on suppose de plus que les applications $t \mapsto F_s(t)$ sont continues, alors les deux membres de l'équation sont continus. L'existence et l'unicité de la solution (sous certaines conditions de support strictes) peuvent alors être étudiées via ces propriétés de monotonie, nous assurant de trouver le λ^* optimal.

Ceci implique que le minimiseur λ^* existe et $\lambda^* \in [-1, 1]$.

Pour terminer la dérivation de f_{fair}^* , nous devons considérer l'hypothèse suivante :

$$t \mapsto \mathbb{P}_{X|S=s}(\eta(X, S) \leq t) \quad \text{est continue.} \quad (2.22)$$

Ceci implique que $\forall x \in \mathbb{R}, \mathbb{P}_{X|S=s}(\eta(X, S) = x) = 0$.

Sous cette hypothèse, nous avons que $\lambda \mapsto \mathcal{H}(\lambda)$ est différentiable (par rapport à λ).

Si nous considérons $h_s(\lambda) = \pi_s(2\eta(X, S) - 1) - \lambda s$, alors :


$$\begin{aligned} \mathbb{E}_{X|S=s}[\max(h_s(\lambda), 0)] &= \mathbb{E}_{X|S=s}[h_s(\lambda)\mathbf{1}\{h_s(\lambda) > 0\}] \\ &\quad + \mathbb{E}_{X|S=s}[0 \cdot \mathbf{1}\{h_s(\lambda) < 0\}] \\ &\quad + \mathbb{E}_{X|S=s}[h_s(\lambda)\mathbf{1}\{h_s(\lambda) = 0\}] \end{aligned}$$

Or, $h_s(\lambda) = 0 \iff \pi_s(2\eta(X, S) - 1) - \lambda s = 0 \iff \eta(X, S) = \frac{1}{2} + \frac{\lambda s}{2\pi_s}$. D'après notre hypothèse de continuité, la probabilité de cet événement est nulle. Ainsi, le dernier terme est nul et le deuxième terme est nul car on multiplie par 0. Pour le premier terme, $h_s(\lambda)$ est dérivable par rapport à λ avec $\frac{\partial h_s(\lambda)}{\partial \lambda} = -s$.

On en déduit que $\lambda \mapsto \mathcal{H}(\lambda)$ est différentiable et sa dérivée est donnée par :

$$\frac{\partial \mathcal{H}}{\partial \lambda}(\lambda) = \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} \left[\frac{\partial h_s(\lambda)}{\partial \lambda} \mathbf{1}\{h_s(\lambda) > 0\} \right] = \sum_{s \in \{-1, 1\}} -s \cdot \mathbb{P}_{X|S=s}(h_s(\lambda) > 0) \quad (2.23)$$

Illustration de la convexité de la fonction associée à chaque s :



De plus, nous avons :

$$\begin{aligned}\mathbb{E}_{X|S=s}[\mathbf{1}\{h_s(\lambda) > 0\}] &= \mathbb{P}_{X|S=s}(h_s(\lambda) > 0) \\ &= \mathbb{P}_{X|S=s}\left(\eta(X, S) > \frac{1}{2} + \frac{\lambda s}{2\pi_s}\right) \\ &= \mathbb{P}_{X|S=s}(f_{\lambda}^*(X, S) = 1)\end{aligned}$$

Ainsi, pour tout $\lambda \in \mathbb{R}$:

$$\frac{\partial \mathcal{H}}{\partial \lambda}(\lambda) = - \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f_{\lambda}^*(X, S) = 1) \quad (2.24)$$

Puisque λ^* est un minimum de $\mathcal{H}$ (fonction convexe différentiable et coercive sur $\mathbb{R}$), nous avons :

$$\frac{\partial \mathcal{H}}{\partial \lambda}(\lambda^*) = 0 \iff \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f_{\lambda^*}^*(X, S) = 1) = 0 \quad (2.25)$$

2.3.5 Algorithme de Post-traitement pour la DP

Contexte et Objectifs

Rappelons que le prédicteur optimal équitale est donné par :

$$f_{\lambda^*}^*(X, S) = \mathbf{1}_{\{\eta(X, S) \geq \frac{1}{2} + \frac{\lambda^* s}{2\pi_s}\}}$$

avec $\lambda^* \in \arg \min_{\lambda} \mathcal{H}(\lambda)$. Sous l'hypothèse de continuité, on a $f_{\lambda^*}^* = f_{fair}^*$.

En pratique, nous ne connaissons pas la distribution sous-jacente. Nous disposons d'un échantillon d'apprentissage :

$$D_n = \{(X_i, S_i, Y_i), i = 1, \dots, n\}$$

Nous voulons construire un prédicteur empirique $\hat{f}$ tel que :

$$\hat{f} \approx f_{\lambda^*}^*$$

Nous exigeons deux propriétés pour $\hat{f}$:

1. $\hat{f}$ satisfait la contrainte de Parité Démographique (DP).
2. $R(\hat{f}) \approx R(f_{\lambda^*}^*)$.

Dans la suite, nous introduisons l'**injustice** (unfairness) d'un prédicteur f , définie par :

$$\mathcal{U}(f) = \left| \sum_{s \in \{-1, 1\}} s \mathbb{P}(f(X, S) = 1 | S = s) \right| \quad (2.26)$$

Un prédicteur f est dit équitale (fair) si et seulement si $\mathcal{U}(f) = 0$. Pour un prédicteur empirique $\hat{f}$, nous voulons $\mathcal{U}(\hat{f}) \approx 0$.

Stratégie d'Estimation

À partir de l'échantillon d'apprentissage D_n , nous pouvons utiliser une approche "plug-in" :

- Nous pouvons estimer la fonction de régression $\eta(X, S)$ par un estimateur $\hat{\eta}(X, S)$ (par exemple, obtenu par régression logistique, forêts aléatoires, réseaux de neurones, etc.).
- Nous pouvons estimer les proportions $\pi_s = \mathbb{P}(S = s)$ par les fréquences empiriques :

$$\hat{\pi}_s = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{S_i=s\}} \xrightarrow{n \rightarrow +\infty} \pi_s \quad (\text{p.s.})$$

- Nous devons estimer le paramètre optimal λ^* par un $\hat{\lambda}$.

Le prédicteur estimé (prédicteur équitable $\hat{f}$) sera alors de la forme :

$$\hat{f}(x, s) = \mathbf{1}_{\left\{ \bar{\eta}(x, s) \geq \frac{1}{2} + \frac{\hat{\lambda}_s}{2\hat{\pi}_s} \right\}} \quad (2.27)$$

avec un estimateur lissé pour assurer la continuité :

$$\bar{\eta}(x, s) = \hat{\eta}(x, s) + \xi \quad \text{avec} \quad \xi \sim \mathcal{U}_{[0, \nu]} \quad (2.28)$$

où $\hat{\eta}$ est un estimateur de η (avec $\eta(x, s) = \mathbb{P}(Y = 1 | X = x, S = s)$) appris sur un ensemble de données labellisées (*labeled data set*).

Le terme $\frac{\hat{\lambda}_s}{2\hat{\pi}_s}$ contrôle le compromis (*trade-off*) entre précision (*accuracy*) et équité (*fairness*).

Équité Approximative (ε -équité)

Au lieu de se restreindre à une équité parfaite $\mathcal{U}(f) = 0$ (où f est strictement DP-équitable), nous pouvons considérer une **équité approximative** ou ε -équité. Nous disons qu'un prédicteur f est ε -équitable si et seulement si :

$$\mathcal{U}(f) \leq \varepsilon \quad (2.29)$$

Rappelons que l'injustice d'un prédicteur scalaire est définie par :

$$\mathcal{U}(f) = \left| \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f(X, S) = 1) \right| \quad (2.30)$$

Le prédicteur ε -équitable optimal est alors logiquement défini par :

$$f_\varepsilon^* \in \arg \min_f \{R(f) \mid f \text{ est } \varepsilon\text{-équitable}\} \quad (2.31)$$

Garanties Théoriques pour le Prédicteur Équitable $\hat{f}$

Théorème 2.2 (Injustice). *Il existe une constante C (qui dépend des probabilités a priori $(\pi_s)_{s \in \mathcal{S}}$) telle que :*

$$\mathbb{E}[\mathcal{U}(\hat{f})] \leq C \times N^{-1/2} \quad (2.32)$$

Démonstration. Notations : Soit $\hat{\eta}$ l'estimateur de η (où $\eta(x, s) = \mathbb{P}(Y = 1 | X = x, S = s)$) appris sur un ensemble de données labellisées (*labeled data set*) de taille N_L . Soit un ensemble de données non labellisées (*unlabeled data set*) de taille N , avec pour chaque groupe $N_s = \sum_{i=1}^N \mathbf{1}_{\{S_i=s\}}$. Nous notons $(X_i^s)_{i=1}^{N_s}$ les descripteurs des observations du groupe $S = s$ dans cet ensemble non labellisé.

Nous définissons la probabilité empirique conditionnelle pour un groupe s et un événement A par :

$$\hat{\mathbb{P}}_{X|S=s}(A) = \frac{1}{N_s} \sum_{i=1}^{N_s} \mathbf{1}_A(X_i^s) \quad (2.33)$$

L'injustice du prédicteur s'écrit par définition :

$$\mathcal{U}(\hat{f}) = \left| \mathbb{P}_{X|S=1}(\hat{f}(X, S) = 1) - \mathbb{P}_{X|S=-1}(\hat{f}(X, S) = 1) \right| = \left| \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(\hat{f}(X, S) = 1) \right| \quad (2.34)$$

En introduisant la probabilité empirique $\hat{\mathbb{P}}$, nous pouvons utiliser l'inégalité triangulaire :

$$\begin{aligned} \mathcal{U}(\hat{f}) &= \left| \sum_{s \in \{-1, 1\}} s \left(\mathbb{P}_{X|S=s}(\hat{f}(X, S) = 1) - \hat{\mathbb{P}}_{X|S=s}(\hat{f}(X, S) = 1) \right) + \sum_{s \in \{-1, 1\}} s \hat{\mathbb{P}}_{X|S=s}(\hat{f}(X, S) = 1) \right| \\ &\leq \sum_{s \in \{-1, 1\}} \left| \mathbb{P}_{X|S=s}(\hat{f}(X, S) = 1) - \hat{\mathbb{P}}_{X|S=s}(\hat{f}(X, S) = 1) \right| + \left| \sum_{s \in \{-1, 1\}} s \hat{\mathbb{P}}_{X|S=s}(\hat{f}(X, S) = 1) \right| \end{aligned} \quad (2.35)$$

Le dernier terme correspond à l'injustice empirique du prédicteur, notée $\hat{\mathcal{U}}(\hat{f})$.

Pour analyser le premier terme de la somme (pour un s fixé), rappelons que la probabilité d'une prédiction positive s'écrit :

$$\mathbb{P}_{X|S=s}(\hat{f}(X, s) = 1) = \mathbb{P}_{X|S=s} \left(\hat{\eta}(X, s) \geq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right) \quad (2.36)$$

Si la loi de la variable aléatoire $\hat{\eta}(X, s)$ est sans atome (*non-atomic*), alors aucune valeur ponctuelle n'a de masse de probabilité :

$$\mathbb{P}_{X|S=s} \left(\hat{\eta}(X, s) \geq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right) = 1 - \mathbb{P}_{X|S=s} \left(\hat{\eta}(X, s) \leq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right) \quad (2.37)$$

En utilisant la même propriété pour la probabilité empirique, on réécrit la différence absolue entre l'estimation théorique et empirique à l'aide des fonctions de répartition :

$$\begin{aligned} &\left| \mathbb{P}_{X|S=s}(\hat{f}(X, s) = 1) - \hat{\mathbb{P}}_{X|S=s}(\hat{f}(X, s) = 1) \right| \\ &= \left| \mathbb{P}_{X|S=s} \left(\hat{\eta}(X, s) \leq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right) - \hat{\mathbb{P}}_{X|S=s} \left(\hat{\eta}(X, s) \leq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right) \right| \end{aligned} \quad (2.38)$$

Par définition, la quantité empirique est :

$$\hat{\mathbb{P}}_{X|S=s} \left(\hat{\eta}(X, s) \leq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right) = \frac{1}{N_s} \sum_{i=1}^{N_s} \mathbf{1}_{\left\{ \hat{\eta}(X_i^s, s) \leq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right\}} \quad (2.39)$$

Afin de maîtriser la différence en espérance, nous travaillons conditionnellement à l'échantillon labellisé (*labeled sample*). Sous ce conditionnement, l'estimateur appris $\hat{\eta}$ devient une variable (ou fonction) déterministe sur les N_s observations.

De plus, le calcul est conditionné par rapport à la taille aléatoire des classes $N_s \sim \mathcal{B}(N, \pi_s)$, et sur l'ensemble $\{N_s \geq 1\}$.

Remarque. La probabilité d'avoir une classe vide décroît exponentiellement avec la taille de l'échantillon N :

$$\mathbb{P}(N_s = 0) = (1 - \pi_s)^N = \exp(N \log(1 - \pi_s))$$

pourvu que $\pi_s \in (0, 1)$.

Nous voulons alors contrôler l'espérance suivante, appelée (I) :

$$\mathbb{E} \left[\left| \mathbb{P}_{X|S=s} \left(\hat{\eta}(X, s) \leq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right) - \frac{1}{N_s} \sum_{i=1}^{N_s} \mathbf{1}_{\left\{ \hat{\eta}(X_i^s, s) \leq \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s} \right\}} \right| \right] := (I) \quad (2.40)$$

Nous pouvons majorer ce terme en considérant le supremum sur toutes les valeurs de seuil possibles $t \in \mathbb{R}$:

$$(I) \leq \mathbb{E} \left[\sup_{t \in \mathbb{R}} |F_s(t) - \hat{F}_s(t)| \right] \quad (2.41)$$

où nous définissons les fonctions de répartition théorique et empirique des scores $\hat{\eta}$ par :

$$F_s(t) = \mathbb{P}_{X|S=s}(\hat{\eta}(X, s) \leq t) \quad (2.42)$$

$$\hat{F}_s(t) = \frac{1}{N_s} \sum_{i=1}^{N_s} \mathbf{1}_{\{\hat{\eta}(X_i^s, s) \leq t\}} \quad (2.43)$$

Remarque. D'après le théorème de Glivenko-Cantelli, nous savons que la fonction de répartition empirique converge uniformément presque sûrement vers la fonction de répartition théorique :

$$\sup_{t \in \mathbb{R}} |F_s(t) - \hat{F}_s(t)| \xrightarrow[N_s \rightarrow +\infty]{p.s.} 0$$

Pour obtenir une borne quantitative à taille finie N_s , nous utilisons l'**inégalité de Dvoretzky-Kiefer-Wolfowitz (D-K-W)**. Celle-ci énonce que pour tout $\varepsilon > 0$:

$$\mathbb{P} \left(\sup_{t \in \mathbb{R}} |F_s(t) - \hat{F}_s(t)| \geq \varepsilon \right) \leq 2 \exp(-2N_s \varepsilon^2) \quad (2.44)$$

(Note : La constante serrée 2 a été obtenue par Massart en 1990).

Pour calculer l'espérance d'une variable aléatoire positive $Z \geq 0$, nous pouvons l'intégrer sur ses probabilités de queue :

$$\mathbb{E}[Z] = \int_0^{+\infty} \mathbb{P}(Z \geq \varepsilon) d\varepsilon \quad (2.45)$$

En posant $Z = \sup_{t \in \mathbb{R}} |F_s(t) - \hat{F}_s(t)|$ et en appliquant l'inégalité de D-K-W, l'intégration conduit à borner (I) de la manière suivante (conditionnellement à $\{N_s \geq 1\}$) :

$$\mathbb{P}((I)) \leq \frac{C}{\sqrt{N_s}} \quad (2.46)$$

où C est une constante (qui ne dépend ni de N , ni de l'échantillon).

Par conséquent, en prenant l'espérance globale sur les variations de N_s , nous obtenons :

$$\Rightarrow \mathbb{E}[(I)] \leq C \mathbb{E} \left[\frac{\mathbf{1}_{\{N_s \geq 1\}}}{\sqrt{N_s}} \right] \leq \frac{C}{\sqrt{N\pi_s}} \quad (2.47)$$

Ce dernier passage utilise le lemme classique suivant sur la loi binomiale, combiné à l'inégalité de Jensen. **Lemme** : Si $Z \sim \mathcal{B}(N, p)$, alors :

$$\mathbb{E} \left[\frac{\mathbf{1}_{\{Z > 0\}}}{Z} \right] \leq \frac{C}{Np}$$

Preuve du Lemme. Nous commençons par borner le terme d'intérêt :

$$\frac{\mathbf{1}_{\{Z > 0\}}}{Z} \leq \frac{2}{Z+1} \quad (2.48)$$

Nous pouvons alors calculer l'espérance de ce majorant de manière exacte :

$$\mathbb{E} \left[\frac{1}{Z+1} \right] = \sum_{k=0}^N \frac{1}{k+1} \binom{N}{k} p^k (1-p)^{N-k} \quad (2.49)$$

L'astuce consiste à observer que le facteur $\frac{1}{k+1}$ s'écrit comme une intégrale :

$$\frac{1}{k+1} = \int_0^1 x^k dx$$

En substituant cette identité dans la somme et en intervertissant somme et intégrale par linéarité :

$$\begin{aligned} \mathbb{E} \left[\frac{1}{Z+1} \right] &= \int_0^1 \sum_{k=0}^N \binom{N}{k} (px)^k (1-p)^{N-k} dx \\ &= \int_0^1 (px + (1-p))^N dx \end{aligned} \quad (2.50)$$

où nous avons reconnu le développement du binôme de Newton $(px + (1-p))^N$.

Pour calculer cette intégrale, on effectue le changement de variable $y = px + (1-p)$, d'où $dy = p dx$:

$$\mathbb{E} \left[\frac{1}{Z+1} \right] = \frac{1}{p} \int_{1-p}^1 y^N dy \leq \frac{1}{p} \int_0^1 y^N dy = \frac{1}{(N+1)p} \quad (2.51)$$

On en déduit donc la première borne voulue (avec la constante $C = 2$) :

$$\mathbb{E} \left[\frac{\mathbf{1}_{\{Z>0\}}}{Z} \right] \leq \mathbb{E} \left[\frac{2}{Z+1} \right] \leq \frac{2}{(N+1)p} \quad (2.52)$$

□

Enfin, pour conclure la preuve du théorème initial, nous remarquons que par l'inégalité de Jensen (la fonction $x \mapsto 1/\sqrt{x}$ étant convexe, ou de manière équivalente par l'inégalité de Cauchy-Schwarz d'après la majoration au carré) :

$$\mathbb{E} \left[\frac{\mathbf{1}_{\{Z>0\}}}{\sqrt{Z}} \right] \leq \sqrt{\mathbb{E} \left[\frac{\mathbf{1}_{\{Z>0\}}}{Z} \right]} \leq \sqrt{\frac{2}{(N+1)p}} \leq \frac{C}{\sqrt{Np}}$$

Enfin, nous revenons à l'expression de l'injustice attendue de notre prédicteur. En prenant l'espérance de l'injustice globale :

$$\begin{aligned} \mathbb{E}[\mathcal{U}(\hat{f})] &\leq \mathbb{E} \left[\sum_{s \in \mathcal{S}} \mathbb{E} \left[\left| \mathbb{P}_{X|S=s}(\hat{f}(X, S) = 1) - \hat{\mathbb{P}}_{X|S=s}(\hat{f}(X, S) = 1) \right| \right] \right] \\ &\quad + \mathbb{E} \left[\left| \sum_{s \in \mathcal{S}} s \hat{\mathbb{P}}_{X|S=s}(\hat{f}(X, S) = 1) \right| \right] \end{aligned} \quad (2.53)$$

Cela conclut l'esquisse de la preuve prouvant que $\mathbb{E}[\mathcal{U}(\hat{f})] \leq C \times N^{-1/2}$. □

2.3.6 Algorithmique et Sous-gradients

Afin de trouver le paramètre empirique optimal $\hat{\lambda}$, nous devons résoudre le problème d'optimisation suivant :

$$\hat{\lambda} \in \arg \min_{\lambda} \sum_{s \in \mathcal{S}} \frac{1}{N_s} \sum_{i=1}^{N_s} \max(\hat{\pi}_s(2\hat{\eta}(X_i^s, s) - 1) - s\lambda, 0) \quad (2.54)$$

Pour minimiser cette fonction objectif qui n'est pas différentiable partout (à cause de la fonction max), nous introduisons la notion de **sous-gradient** (sub-gradient).

Rappels : Sous-gradient

Soit $f : \mathbb{R}^d \rightarrow \mathbb{R}$ une fonction convexe. Le domaine de f est $\mathcal{D}_f = \mathbb{R}^d$.

Définition 2.3 (Sous-gradient). Un vecteur $b \in \mathbb{R}^d$ est un sous-gradient de f au point x si :

$$f(z) \geq f(x) + b^\top(z - x), \quad \forall z \in \mathbb{R}^d \quad (2.55)$$

Si, au point $x \in \mathbb{R}^d$, il existe au moins un sous-gradient, alors on dit que f est **sous-différentiable** en x .

Nous notons $\partial f(x)$ l'ensemble des sous-gradients de f en x .

$$\begin{aligned} \partial f(x) \neq \emptyset &\iff f \text{ est sous-différentiable en } x \\ \partial f(x) = \{b\} &\iff f \text{ est différentiable en } x \end{aligned}$$

(où la dernière équivalence s'applique car f est supposée convexe, et le sous-gradient unique b est alors $\nabla f(x)$).

Exemple 2.4 (Sous-différentiel de la valeur absolue).

Considérons la fonction $x \mapsto |x|$. Son sous-différentiel en zéro est :

$$\partial f(0) = [-1, 1] \quad (2.56)$$

On vérifie facilement que pour tout $b \in [-1, 1]$ et pour tout $z \in \mathbb{R}$, on a $|z| \geq bz$, ce qui correspond à la définition au point $x = 0$ (puisque $|0| = 0$).

Théorème 2.5 (Propriété d'optimalité). x^* est un minimiseur de $f \iff f$ est sous-différentiable en x^* et $0 \in \partial f(x^*)$.

Propriétés opératoires

- Si $f = f_1 + \dots + f_m$, où $f_i : \mathbb{R}^d \rightarrow \mathbb{R}$ sont convexes, alors le sous-différentiel de la somme est la somme de Minkowski des sous-différentiels :

$$\partial f(x) = \partial f_1(x) + \dots + \partial f_m(x) \quad (2.57)$$

- Si $f(x) = \max_{i=1, \dots, m} (f_i(x))$ avec des $f_i : \mathbb{R}^d \rightarrow \mathbb{R}$ convexes et différentiables, alors :

$$\partial f(x) = \text{Conv} \{ \nabla f_i(x) \mid f_i(x) = f(x) \} \quad (2.58)$$

où Conv désigne l'enveloppe convexe. En d'autres termes, le sous-différentiel du maximum en un point x est l'enveloppe convexe des gradients des fonctions "actives" en ce point (celles qui atteignent le maximum).

Application à la minimisation empirique de $\hat{\lambda}$

Revenons à notre fonction objectif empirique :

$$\hat{\mathcal{H}}(\lambda) = \sum_{s \in \mathcal{S}} \frac{1}{N_s} \sum_{i=1}^{N_s} \max(\hat{\pi}_s(2\hat{\eta}(X_i^s, s) - 1) - s\lambda, 0) \quad (2.59)$$

Nous cherchons $\hat{\lambda} \in \arg \min_{\lambda} \hat{\mathcal{H}}(\lambda)$.

Posons pour un point X_i^s fixé :

$$f(\lambda) = \max \left(\underbrace{\hat{\pi}_s(2\hat{\eta}(X_i^s, s) - 1) - s\lambda}_{:=f_1(\lambda)}, \underbrace{0}_{:=f_2(\lambda)} \right)$$

Un élément $b \in \partial f(\lambda)$ dépend des valeurs relatives de $f_1(\lambda)$ et $f_2(\lambda)$:

- Si $f_1(\lambda) > f_2(\lambda)$ c'est-à-dire $\hat{\pi}_s(2\hat{\eta}(X_i^s, s) - 1) - s\lambda > 0 \iff 2\hat{\eta}(X_i^s, s) > 1 + \frac{s\lambda}{\hat{\pi}_s}$, alors la fonction est différentiable en λ et $\partial f(\lambda) = \{f'_1(\lambda)\} = \{-s\}$.
- Si $f_1(\lambda) < f_2(\lambda)$ c'est-à-dire $2\hat{\eta}(X_i^s, s) < 1 + \frac{s\lambda}{\hat{\pi}_s}$, alors la fonction est différentiable en λ et $\partial f(\lambda) = \{f'_2(\lambda)\} = \{0\}$.
- Si $f_1(\lambda) = f_2(\lambda)$ c'est-à-dire $2\hat{\eta}(X_i^s, s) = 1 + \frac{s\lambda}{\hat{\pi}_s}$, alors le sous-différentiel est l'enveloppe convexe des deux gradients :

$$\partial f(\lambda) = \text{Conv}(\{-s, 0\}) = \{\alpha_i^s(-s) + (1 - \alpha_i^s)0 \mid \alpha_i^s \in [0, 1]\} = \{-\alpha_i^s s \mid \alpha_i^s \in [0, 1]\}$$

Nous pouvons résumer cela de manière plus condensée. Dire que $b \in \partial f(\lambda)$ implique qu'il existe $\alpha_i^s \in [0, 1]$ (spécifique à l'observation i du groupe s) tel que :

$$b = -s \mathbf{1}_{\{\hat{\pi}_s(2\hat{\eta}(X_i^s, s) - 1) - s\lambda > 0\}} + (-\alpha_i^s s) \mathbf{1}_{\{\hat{\pi}_s(2\hat{\eta}(X_i^s, s) - 1) - s\lambda = 0\}} + 0 \cdot \mathbf{1}_{\{\dots < 0\}} \quad (2.60)$$

Puisque $\hat{\lambda}$ est choisi dans $\arg \min_{\lambda \in \mathbb{R}} \hat{\mathcal{H}}(\lambda)$, la propriété d'optimalité stipule que $0 \in \partial \hat{\mathcal{H}}(\hat{\lambda})$. Par linéarité du sous-différentiel, cela implique qu'il existe des coefficients $\alpha_i^s \in [0, 1]$ pour tout (i, s) tels que :

$$0 = \sum_{s \in \mathcal{S}} \frac{1}{N_s} \sum_{i=1}^{N_s} -s \left[\mathbf{1}_{\{\hat{\eta}(X_i^s, s) > \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s}\}} + \alpha_i^s \mathbf{1}_{\{\hat{\eta}(X_i^s, s) = \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s}\}} \right] \quad (2.61)$$

En réorganisant cette équation de point fixe par rapport aux classes $S = 1$ et $S = -1$, on obtient l'égalité d'équilibre (noter que $\sum(-s)(\dots) = 0 \Rightarrow (\dots)_{s=1} = (\dots)_{s=-1}$) :

$$\Rightarrow \sum_{s \in \mathcal{S}} \frac{s}{N_s} \sum_{i=1}^{N_s} \left[\mathbf{1}_{\{\hat{\eta}(X_i^s, s) > \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s}\}} + \alpha_i^s \mathbf{1}_{\{\hat{\eta}(X_i^s, s) = \frac{1}{2} + \frac{s\hat{\lambda}}{2\hat{\pi}_s}\}} \right] = 0 \quad (2.62)$$

Ceci revient exactement à tenter d'égaliser les taux de prédiction positive $\hat{\mathbb{P}}_{X|S=s}(\hat{f}(X, S) = 1)$ pour les deux groupes. Le terme en α_i^s sert algorithmiquement à résoudre de manière exacte l'égalité si de multiples observations tombent exactement sur le seuil, ce qui est appelé la randomisation (une prédiction probabiliste α au lieu de déterministe) pour casser les égalités sur la frontière de décision.

2.3.7 Consistance du Risque de Classification

Nous considérons la fonction de risque suivante pour un classifieur f :

$$R_{\lambda^*}(f) = \underbrace{\mathbb{P}(f(X, S) \neq Y)}_{\text{Risque de classification}} + \underbrace{\lambda^* \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f(X, S) = 1)}_{\text{Injustice (Unfairness)}} \quad (2.63)$$

Soit f^* le prédicteur équitable optimal. Nous avons que $f^*(x, s) = \mathbf{1}_{\{\eta(x, s) \geq \frac{1}{2} + \frac{\lambda^* s}{2\pi_s}\}}$. Plus formellement, ce prédicteur optimal s'écrit comme un minimax :

$$\begin{aligned} f^* &\in \arg \min_{f \text{ prédicteur}} R_{\lambda^*}(f) \\ f^* &:= f_{\lambda^*}^* \quad \text{où pour chaque } \lambda \in \mathbb{R}, \\ f_{\lambda}^*(x, s) &= \mathbf{1}_{\{\eta(x, s) \geq \frac{1}{2} + \frac{s\lambda}{2\pi_s}\}} \\ \lambda^* &\in \arg \max_{\lambda} R_{\lambda}(f_{\lambda}^*) \end{aligned} \quad (2.64)$$

avec $R_\lambda(f) = \mathbb{P}(f(X, S) \neq Y) + \lambda \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f(X, S) = 1)$.

On notera que pour tout $\lambda \in \mathbb{R}$, le risque $R_\lambda(f)$ est minimisé par ce prédicteur paramétrique f_λ^* :

$$f_\lambda^* \in \arg \min_{f \text{ prédicteur}} R_\lambda(f) \quad (2.65)$$

Nous étudions l'erreur d'estimation introduite par notre classifieur plug-in $\hat{f}$, basé sur des probabilités empiriques.

Théorème 2.6 (Consistance du risque). *L'excès de risque converge vers zéro quant le nombre d'échantillons grandit :*

$$\mathbb{E} [R_{\lambda^*}(\hat{f}) - R_{\lambda^*}(f^*)] \xrightarrow{n, N \rightarrow \infty} 0 \quad (2.66)$$

pourvu que les probabilités conditionnelles estimées soient consistantes :

$$\mathbb{E} [|\hat{\eta}(X, S) - \eta(X, S)|] \xrightarrow{n \rightarrow \infty} 0 \quad (2.67)$$

Démonstration. Nous reprenons l'expression du risque $R_\lambda(f)$:

$$R_\lambda(f) = \mathbb{P}(f(X, S) \neq Y) + \lambda \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(f(X, S) = 1)$$

Pour évaluer le saut de risque de notre estimateur $R_{\lambda^*}(\hat{f}) - R_{\lambda^*}(f^*)$, nous pouvons le décomposer en ajoutant et soustrayant le terme intermédiaire $R_{\hat{\lambda}}(\hat{f})$:

$$R_{\lambda^*}(\hat{f}) - R_{\lambda^*}(f^*) = \underbrace{R_{\lambda^*}(\hat{f}) - R_{\hat{\lambda}}(\hat{f})}_{(I)} + \underbrace{R_{\hat{\lambda}}(\hat{f}) - R_{\lambda^*}(f^*)}_{(II)} \quad (2.68)$$

En développant le terme (I) (risque d'estimation de λ^*), nous obtenons l'écart pénalisé uniquement par la différence de λ , puisque la probabilité d'erreur de classification s'annule :

$$R_{\lambda^*}(\hat{f}) - R_{\hat{\lambda}}(\hat{f}) = (\lambda^* - \hat{\lambda}) \sum_{s \in \{-1, 1\}} s \mathbb{P}_{X|S=s}(\hat{f}(X, S) = 1) \quad (2.69)$$

Pour contrôler le second terme (II), nous évaluons la différence des risques pour un même λ . D'après la caractérisation du classifieur optimal, nous savons que l'événement d'erreur $\{f_\lambda^*(X, S) \neq \hat{f}(X, S)\}$ se produit lorsque les expressions $\pi_s(2\eta(X, S) - 1) - s\hat{\lambda}$ (vrai signal) et $\hat{\pi}_s(2\hat{\eta}(X, S) - 1) - s\hat{\lambda}$ (signal estimé) n'ont pas le même signe.

Géométriquement, cela signifie que zéro est compris entre les deux valeurs, comme illustré dans le schéma suivant :

$$\begin{array}{c} \hat{\pi}_s(2\hat{\eta}(x, s) - 1) - s\hat{\lambda} \quad \pi_s(2\eta(x, s) - 1) - s\hat{\lambda} \\ \hline \qquad \qquad \qquad * \qquad \qquad \qquad | \qquad \qquad \qquad * \\ \qquad \qquad \qquad \qquad \qquad \qquad \qquad \qquad 0 \end{array}$$

FIGURE 2.2 – Illustration du croisement de la frontière de décision lorsque la prédiction diffère de l'optimum.

Sur l'événement d'erreur $\{f_\lambda^*(X, S) \neq \hat{f}(X, S)\}$, puisque 0 se trouve formellement entre la valeur théorique et la valeur estimée, la distance de la valeur théorique à 0 est nécessairement

plus petite que la distance totale entre les deux valeurs. On a donc la majoration essentielle suivante :

$$\begin{aligned} |\pi_s(2\eta(X, S) - 1) - s\hat{\lambda}| &\leq |\pi_s(2\eta(X, S) - 1) - s\hat{\lambda} - (\hat{\pi}_s(2\hat{\eta}(X, S) - 1) - s\hat{\lambda})| \\ &\leq |\pi_s(2\eta(X, S) - 1) - \hat{\pi}_s(2\hat{\eta}(X, S) - 1)| \end{aligned} \quad (2.70)$$

Plus précisément, le terme de saut de risque (II) se majore formellement comme suit :

$$\begin{aligned} R_{\hat{\lambda}}(\hat{f}) - R_{\hat{\lambda}}(f_{\hat{\lambda}}^*) &= \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} \left[\left(\pi_s(2\eta(X, S) - 1) - s\hat{\lambda} \right) \left(f_{\hat{\lambda}}^*(X, S) - \hat{f}(X, S) \right) \right] \\ &\leq \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [|\pi_s(2\eta(X, S) - 1) - \hat{\pi}_s(2\hat{\eta}(X, S) - 1)|] \\ &= \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [|\pi_s 2\eta(X, S) - \hat{\pi}_s 2\hat{\eta}(X, S) + \hat{\pi}_s - \pi_s|] \\ &\leq C \sum_{s \in \{-1, 1\}} \pi_s \mathbb{E}_{X|S=s} [|\hat{\eta}(X, S) - \eta(X, S)|] + C \sum_{s \in \{-1, 1\}} \mathbb{E}_{X|S=s} [|\hat{\pi}_s - \pi_s|] \end{aligned} \quad (2.71)$$

(où la dernière inégalité est laissée en exercice : on utilise l'inégalité triangulaire et on borne les variables de probabilité par 1).

De tout ce qui précède, en prenant l'espérance globale sur les données d'apprentissage, et en liant (I) et (II), l'excès de risque complet est majoré par :

$$\mathbb{E} [R_{\lambda^*}(\hat{f}) - R_{\lambda^*}(f^*)] \leq C \left(\mathbb{E} [|\hat{\eta}(X, S) - \eta(X, S)|] + \mathbb{E} [|\hat{\pi}_s - \pi_s|] + \mathbb{E}[U(\hat{f})] \right) \quad (2.72)$$

Or, l'estimateur de la proportion d'un groupe est une moyenne empirique sur un échantillon non labellisé de taille N : $\hat{\pi}_s = \frac{1}{N} \sum_{i=1}^N \mathbf{1}_{\{S_i=s\}}$. Les variables indicatrices suivent des lois de Bernoulli indépendantes identiquement distribuées : $\mathbf{1}_{\{S_i=s\}} \sim_{iid} \mathcal{Ber}(\pi_s)$, donc $\mathbb{E}[\hat{\pi}_s] = \pi_s$. La variance de l'estimateur est donnée par :

$$\mathbb{E} [(\hat{\pi}_s - \pi_s)^2] = \text{Var}(\hat{\pi}_s) = \frac{\text{Var}(\mathbf{1}_{\{S_1=s\}})}{N} = \frac{\pi_s(1 - \pi_s)}{N} \leq \frac{1}{4N} \quad (2.73)$$

Par l'inégalité de Cauchy-Schwarz (ou de Jensen sur la concavité de la racine) :

$$\mathbb{E} [|\hat{\pi}_s - \pi_s|] \leq \sqrt{\mathbb{E} [(\hat{\pi}_s - \pi_s)^2]} \leq \frac{1}{2\sqrt{N}} = \mathcal{O}\left(\frac{1}{\sqrt{N}}\right) \quad (2.74)$$

Sachant que $\mathbb{E}[U(\hat{f})] \leq \mathcal{O}(N^{-1/2})$, la majoration tombe sous la racine carrée de la taille de l'échantillon N . Et enfin, sous l'hypothèse primordiale de consistance de l'estimateur probabiliste du signal $\mathbb{E}[|\hat{\eta} - \eta|] \rightarrow 0$, tous les termes de la borne tendent continûment vers 0 lorsque $n, N \rightarrow \infty$, ce qui conclut la preuve de convergence asymptotique de l'estimateur plug-in vers l'optimum. $\square$

2.4 Classification sous In-Processing

L'approche In-Processing intègre directement les contraintes d'équité lors de la phase d'optimisation du modèle. Contrairement au post-traitement qui fige un modèle potentiellement biaisé $\hat{f}$ pour en corriger les prédictions a posteriori, l'in-processing cherche d'emblée un prédicteur équitable dans une classe de fonctions donnée $\mathcal{F}$.

2.4.1 Minimisation du Risque Empirique (ERM) Équitable

Supposons que nous disposions d'un unique échantillon d'apprentissage supervisé labellisé $\mathcal{D}_n = \{(X_i, S_i, Y_i)\}_{i=1}^n$. Soit $\mathcal{F}$ la classe de classifieurs considérée.

Le **risque empirique** classique est défini par la proportion d'erreurs :

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{f(X_i, S_i) \neq Y_i\}} \quad (2.75)$$

Pour mesurer la violation de la Parité Démographique, on définit la **contrainte d'injustice empirique** (*empirical unfairness constraint*) pour un seuil $\varepsilon > 0$:

$$\hat{\mathcal{U}}(f) = \left| \sum_{s \in \mathcal{S}} s \frac{1}{n_s} \sum_{i=1}^{n_s} f(X_i^s, s) \right| \leq \varepsilon \quad (2.76)$$

où n_s est le nombre d'observations appartenant au groupe sensible $S = s$.

Le minimiseur du risque empirique (E.R.M.) sous contrainte d'équité est alors :

$$\hat{f} \in \arg \min_{f \in \mathcal{F}} \left\{ \hat{R}(f) \quad \text{s.c.} \quad \hat{\mathcal{U}}(f) \leq \hat{\varepsilon} \right\} \quad (2.77)$$

(souvent avec $\hat{\varepsilon} \propto \sum_{s \in \mathcal{S}} \sqrt{\frac{\log(n)}{n_s}}$ pour autoriser une tolérance statistique liée à la taille des échantillons empiriques).

2.4.2 Garanties de l'In-Processing

Si l'on suppose que la classe de fonctions $\mathcal{F}$ a une dimension VC (Vapnik-Chervonenkis) finie : $\mathcal{V}(\mathcal{F}) < \infty$ et que le prédicteur optimal absolu f^* appartient bien à $\mathcal{F}$, nous pouvons borner l'écart de généralisation par des inégalités de concentration classiques :

$$\mathbb{E} \left[\sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)] \right| \right] \leq C \sqrt{\frac{\log(n)}{n}} \quad (2.78)$$

On en déduit les bornes probabilistes suivantes pour l'estimateur in-processing $\hat{f}$:

- L'injustice anticipée est bornée : $\mathbb{E}[\mathcal{U}(\hat{f})] \leq C \sqrt{\frac{\log(n)}{n}}$.
- L'excès de risque pénalisé (le Lagrangien optimisé) est également borné : $\mathbb{E}[R_{\lambda^*}(\hat{f}) - R_{\lambda^*}(f^*)] \leq C \sqrt{\frac{\log(n)}{n}}$.

2.4.3 Algorithmique : Convexification

L'optimisation directe du risque empirique avec des fonctions indicatrices (perte 0-1 booléenne) est NP-difficile. Pour rendre le problème de l'ERM équitable calculable en pratique, l'approche algorithmique standard consiste à recourir à la **convexification** :

1. Remplacer la perte de classification discrète par une **fonction de perte de substitution convexe** (comme la perte logistique ou la *hinge loss* du SVM).
2. Remplacer également la contrainte d'équité $\hat{\mathcal{U}}(f)$ par une approximation convexe.

Une autre ligne de recherche majeure emploie des **classifieurs randomisés** : au lieu de chercher un unique classifieur déterministe, l'algorithme trouve une distribution de probabilité μ optimale sur un ensemble de classifieurs de base (modèle d'ensemble), permettant une résolution exacte par optimisation linéaire.

2.5 La Régression Équitable (Fair Regression)

Jusqu'ici, nous traitons des problèmes de classification ($Y \in \{0, 1\}$). Cependant, la contrainte d'équité s'applique tout aussi bien aux problèmes de régression, où la valeur à prédire est continue : $Y \in \mathbb{R}$.

2.5.1 Formulation du Problème

Les observations sont (X, S, Y) avec $Y = \eta(X, S) + \varepsilon$ et $\mathbb{E}[\varepsilon|X, S] = 0$. La règle de prédiction est une fonction continue $f : \mathbb{R}^d \times \mathcal{S} \rightarrow \mathbb{R}$. Le risque quadratique usuel est $R(f) = \mathbb{E}[(Y - f(X, S))^2]$.

La contrainte stricte de Parité Démographique (DP exacte) en régression stipule que les fonctions de répartition (CDF) des prédictions doivent être rigoureusement identiques entre les différents groupes sensibles.

$$\sup_{t \in \mathbb{R}} |\mathbb{P}(f(X, S) \leq t | S = 1) - \mathbb{P}(f(X, S) \leq t | S = -1)| = 0 \quad (2.79)$$

Le problème du **prédicteur équitable optimal** en régression revient à trouver :

$$f^* \in \arg \min_f \{R(f) \quad \text{s.c.} \quad f \text{ satisfait DP}\} \quad (2.80)$$

2.5.2 Première Approche : La Discrétisation

Une manière d'aborder ce problème complexe est la discrétisation. Supposons $|Y| \leq 1$ et créons une grille spatiale $\mathcal{G}_L = \left\{\frac{l}{L}, l = -L, \dots, L\right\}$ pour $L > 0$. Le prédicteur discrétisé est contraint : $f_L(X, S) \in \mathcal{G}_L$.

Pour ce prédicteur, la contrainte DP devient un problème discret (similaire à la classification multi-classes) :

$$\max_{l \in \{-L, \dots, L\}} \sum_{s \in \mathcal{S}} s \cdot \mathbb{P}_{X|S=s} \left(f_L(X, S) = \frac{l}{L} \right) = 0 \quad (2.81)$$

Propriété d'approximation : L'approche f_L^* (minimiseur du risque sur la grille sous DP discret) approxime très bien l'optimum réel continu.

$$R(f^*) \leq R(f_L^*) \leq R(f^*) + \frac{2\text{Var}(Y)}{L} + \frac{1}{L^2} \quad (2.82)$$

Prédicteur équitable optimal discrétisé : Sous des hypothèses de continuité, f_L^* s'écrit formellement avec un vecteur de multiplicateurs de Lagrange $\lambda^* = (\lambda_{-L}^*, \dots, \lambda_L^*)$ caractérisé de manière analogue au cas de la classification binaire. La procédure empirique *Data-driven* consiste à estimer $\eta(x, s)$, π_s par fréquences empiriques et trouver $\hat{\lambda}$ numériquement de manière de type *plug-in*. Si la taille de la grille grandit modérément $L = N^{-1/4}$, et que l'estimation de η est consistante, alors le risque du modèle discret converge vers celui de l'optimum continu : $\mathbb{E}[R(\hat{f}_L)] \rightarrow R(f^*)$.

2.5.3 Approche par transport optimal : Distance de Wasserstein

Définition 2.7 (Distance de Wasserstein-2). Soit μ, ν deux distributions de probabilité sur $\mathbb{R}$. La distance $\mathcal{W}_2$ est définie par :

$$\mathcal{W}_2^2(\mu, \nu) = \inf_{\gamma \in \Gamma(\mu, \nu)} \int |x - y|^2 d\gamma(\mu, \nu) \quad (2.83)$$

Dans le cas monodimensionnel, où les variables admettent des densités (et donc des fonctions de répartitions F inversibles), le transport optimal s'exprime très simplement via les **fonctions quantiles** (les inverses des CDF) :

$$\mathcal{W}_2^2(\mu, \nu) = \mathbb{E}[(X - T(X))^2] = \int_0^1 (F_\mu^{-1}(t) - F_\nu^{-1}(t))^2 dt \quad (2.84)$$

où $T(x) = F_\nu^{-1}(F_\mu(x))$ est l'application de transport de Monge.

2.5.4 Caractérisation du Prédicteur Équitable Optimal

L'intervention de la distance de Wasserstein permet de formuler analytiquement la pénalité de "rabotage" qu'applique la contrainte d'équité sur le signal parfait $\eta(X, S)$. En notant $\nu_{\eta|s}$ la distribution (la loi) des prédictions pures $\eta(X, S)$ conditionnée au groupe s , Chzhen et al. démontrent que :

$$\min_{f \text{ équitable}} \mathbb{E}[(\eta(X, S) - f(X, S))^2] = \min_{\nu} \sum_{s \in \mathcal{S}} \pi_s \mathcal{W}_2^2(\nu_{\eta|s}, \nu) \quad (2.85)$$

Le terme de droite est calculé via le barycentre de Wasserstein des distributions des groupes.

Cela donne une forme analytique close très intuitive pour le prédicteur équitable optimal f^* :

$$f^*(x, s) = \pi_s \eta(x, s) + (1 - \pi_s) t^*(x, s) \quad (2.86)$$

où $t^*(x, s) = F_{\eta|s'}^{-1}(F_{\eta|s}(\eta(x, s)))$ pour l'autre groupe $s' \neq s$. Autrement dit, le score optimal se révèle être un équilibre (une pondération selon la taille des populations) entre le vrai score de l'individu $\eta(x, s)$ et l'équivalent de ce score mappé sur la distribution de l'autre groupe via les percentiles de transport.

2.5.5 Procédure de Plug-in finale

En pratique, cette caractérisation permet un algorithme post-traitement direct :

1. À l'aide de données d'apprentissage $\mathcal{D}_n$, estimer la fonction de régression $\hat{\eta}$. (Et introduire une légère randomisation $\bar{\eta}$ pour lisser).
2. À l'aide d'un grand ensemble de données non-labellisées $\mathcal{U}_N = \{X_i, S_i\}_{i=1}^N$, estimer les proportions empiriques $\hat{\pi}_s$.
3. Séparer $\mathcal{U}_N$ par groupes cibles : $\mathcal{U}_0$ et $\mathcal{U}_1$. Sur chaque groupe, calculer les fonctions de répartition empiriques $\hat{F}_{\bar{\eta}|s}$ et les quantiles empiriques inverses $\hat{F}_{\bar{\eta}|s}^{-1}$.
4. La prédiction finale est délivrée par la formule approchée :

$$\hat{f}(x, s) = \hat{\pi}_s \hat{\eta}(x, s) + (1 - \hat{\pi}_s) \hat{F}_{\bar{\eta}|s'}^{-1}(\hat{F}_{\bar{\eta}|s}(\hat{\eta}(x, s))) \quad (2.87)$$

Les propriétés théoriques garantissent que cet estimateur maintient les mêmes consistances universelles que lors des méthodes de classification.