

Notes de Cours - Méthodes de Monte Carlo et Malliavin

Part I

Fondements et Méthodes de Monte Carlo

1 Fondements des Méthodes de Monte Carlo

L'objectif premier est d'estimer numériquement une intégrale multidimensionnelle $\int_{\mathbb{R}^d} f(x) d\mu(x)$ lorsqu'aucune solution analytique n'existe.

1.1 Théorèmes de Convergence

- **Loi Forte des Grands Nombres (LFGN)** : Garantit que la moyenne empirique converge presque sûrement vers l'espérance $E[X_1]$, à condition que $E[|X_1|] < \infty$.
- **Théorème Central Limite (TCL)** : Permet de contrôler l'erreur. Pour n grand, l'erreur suit une loi normale.
- **Intervalle de Confiance (95%)** : L'espérance se situe avec 95% de probabilité dans :

$$\left[\bar{S}_n - 1.96 \frac{\sigma}{\sqrt{n}}, \bar{S}_n + 1.96 \frac{\sigma}{\sqrt{n}} \right]$$

Subtilité : Contrairement aux méthodes d'analyse classique (comme les sommes de Riemann) dont l'erreur dépend de la dimension d (en $O(n^{-1/d})$), l'erreur de Monte Carlo (en $O(n^{-1/2})$) est **indépendante de la dimension**, ce qui la rend indispensable en finance.

2 Simulation de Variables Aléatoires

Pour appliquer Monte Carlo, il faut savoir générer des variables suivant des lois spécifiques :

- **Méthode d'Inversion** : Utilise l'inverse de la fonction de répartition $F_X^{-1}(U)$ où $U \sim \mathcal{U}([0, 1])$.
- **Méthode de Box-Muller** : Une transformation spécifique pour générer un couple de variables normales indépendantes à partir de deux variables uniformes.
- **Mouvement Brownien** : Se simule par discrétisation temporelle en utilisant le fait que les incréments sont indépendants et suivent une loi $\mathcal{N}(0, t_k - t_{k-1})$.

3 Le Modèle de Black-Scholes (B&S)

Le prix d'une option à l'instant t est l'espérance actualisée de son payoff Φ_T sous la probabilité risque-neutre Q :

$$P_t = E^Q[e^{-r(T-t)} \Phi_T | \mathcal{F}_t]$$

- **Avantage** : Il existe des formules fermées pour les Calls et Puts classiques.
- **Usage de Monte Carlo** : Indispensable pour des options complexes (ex: options asiatiques, lookback) où aucune formule fermée n'existe.

4 Calcul des Grecs : Méthodes et Comparaisons

Les Grecs mesurent la sensibilité du prix aux paramètres (Delta Δ , Gamma Γ , Vega, etc.).

4.1 Méthode des Différences Finies (DF)

On estime la dérivée par un petit décalage h :

$$\Delta \approx \frac{F(x+h) - F(x-h)}{2h}$$

- **Subtilité technique** : Il est crucial d'utiliser les mêmes échantillons aléatoires pour calculer $F(x+h)$ et $F(x-h)$ afin de réduire la variance du numérateur (méthode des *Common Random Numbers*).
- **Inconvénient** : Choix difficile de h . Trop grand, il y a un biais ; trop petit, la variance explose.

4.2 Méthode d'Intégration par Parties (IPP)

On transforme la dérivée du prix en une espérance du payoff multiplié par un "poids" π :

$$\text{Grec} = E^Q[\text{Payoff} \times \text{Poids}]$$

Exemple de poids pour le Delta : $\pi = \frac{B_T}{x\sigma T}$.

- **Avantages** : Pas de biais d'approximation (contrairement aux DF) et le poids est indépendant du payoff.

5 Synthèse des performances

Le cours met en évidence des résultats numériques majeurs :

- **Régularité du Payoff** : Plus le payoff est irrégulier (ex: option Digitale), plus la méthode IPP est supérieure aux Différences Finies. Pour une option Digitale, le ratio de variance peut être massif (ex: ≈ 2354 pour le Gamma).
- **Ordre de Dérivation** : L'avantage de l'IPP s'accroît pour les dérivées d'ordre supérieur (Gamma vs Delta).
- **Vers le Calcul de Malliavin** : L'IPP présentée ici est une introduction simple. Pour généraliser ces poids à des modèles plus complexes ou des trajectoires entières, on utilise le Calcul de Malliavin, détaillé dans la partie suivante.

Part II

Introduction au Calcul de Malliavin

Ce cours marque le passage du calcul stochastique classique (Itô) à une analyse plus profonde de la sensibilité des variables aléatoires sur l'espace de Wiener.

6 Motivation et Objectifs

Le calcul de Malliavin est un **calcul différentiel en dimension infinie** (sur l'espace de Wiener) qui permet principalement :

- **L'analyse de sensibilité (Greeks)** : Calculer des dérivées de prix même pour des payoffs discontinus (ex: options Digitales).
- **La couverture (Hedging) explicite** : Trouver le processus de couverture ϕ_t dans le théorème de représentation d'Itô de manière directe (formule de Clark-Ocone).
- **La régularité des densités** : Prouver l'existence et la lissage de la densité d'une variable aléatoire.

7 Le Cadre : L'Espace de Wiener

Contrairement au calcul classique, on définit ici précisément l'espace de probabilité :

- **Espace** (Ω) : L'espace de Banach $C_0([0, T])$ des fonctions continues partant de 0.
- **Mesure** (P) : La **mesure de Wiener** W .
- **Variable Aléatoire** : Dans ce cadre, le mouvement brownien est simplement l'évaluation $W_t(\omega) = \omega(t)$.

8 Le problème de la Dérivation en Dimension Infinie

Pourquoi ne pas utiliser la dérivée classique (Fréchet) ?

- **Échec de Fréchet** : Une intégrale stochastique $\int f dW$ vue comme une fonction de ω n'est généralement **pas continue** pour la norme uniforme. Elle ne peut donc pas être différentiable au sens de Fréchet.
- **La Solution** : La **dérivée de Malliavin**. C'est une dérivée directionnelle dans des directions "lisses" appartenant à l'espace de Cameron-Martin $\mathcal{H}^1$.

9 L'Intégration par Parties (IPP) Stochastique

C'est le cœur théorique du cours.

9.1 Définition de l'IPP(X, Y)

Deux variables aléatoires X et Y satisfont l'IPP si pour toute fonction test $\phi \in C_b^1$:

$$E[\phi'(X)Y] = E[\phi(X)\pi]$$

Ici, π est appelé le **poids de Malliavin**.

9.2 Subtilités des Preuves et Cas d'Usage

1. **Cas 1 (Payoff régulier)** : Si f est dérivable, on utilise la *chain rule* classique : $\partial_x E[f(X)] = E[f'(X)\partial_x X]$.
2. **Cas 2 (Payoff non-régulier)** : Si f est discontinue, la formule précédente est inutilisable (la dérivée n'existe pas au sens classique). L'IPP permet de "transférer" la dérivation de f vers le poids π , rendant le calcul possible numériquement : $\partial_x E[f(X^\theta)] = E[f(X^\theta)\pi]$.
3. **Optimalité du Poids** : Si on a plusieurs poids possibles π_i tels que $E[f(X)\pi_i] = \text{Cst}$, le poids qui minimise la variance de l'estimateur Monte Carlo est l'espérance conditionnelle : $\pi^* = E[\pi|X]$.

10 Les Fondements pour la suite

Pour maîtriser la suite du cours, il faut retenir ces trois piliers :

- **Opérateur de Dérivation** (D) : Agit sur des variables aléatoires (comme l'intégrale stochastique) pour mesurer leur sensibilité aux variations du chemin brownien.
- **Opérateur de Skorohod** (δ) : C'est l'adjoint de la dérivée de Malliavin. Il généralise l'intégrale d'Itô à des processus qui peuvent "anticiper" le futur.
- **Théorème de Représentation** : La dérivée de Malliavin permettra d'écrire explicitement le processus de couverture comme $\phi_t = E[D_t F | \mathcal{F}_t]$.

11 Astuce Technique (Cas Gaussien)

Pour prouver l'IPP, on utilise souvent le fait que pour une variable aléatoire normale $G \sim \mathcal{N}(0, 1)$, sa densité $\rho(y)$ vérifie $\rho'(y) = -y\rho(y)$. Cela implique que pour toute fonction lisse ϕ :

$$E[\phi'(G)] = E[\phi(G)G]$$

Le poids de Malliavin pour une gaussienne standard est donc simplement la variable elle-même. C'est ce type de relation (Stein's Lemma) qui est généralisé par le calcul de Malliavin.

Part III

L'Opérateur de Dérivation et l'Espace de Sobolev

Cette partie formalise l'opérateur de dérivation, définit les classes de variables aléatoires "lisses" et introduit les premières règles de calcul fondamentales.

12 L'Opérateur de Dérivation de Malliavin (D)

C'est l'extension de la notion de dérivée aux variables aléatoires définies sur l'espace de Wiener.

12.1 Variables Aléatoires Cylindriques (S)

Pour définir D , on commence par un ensemble de variables "test" simples appelées cylindriques :

$$F = f(B_{t_1}, B_{t_2}, \dots, B_{t_n})$$

où $f \in C_b^\infty(\mathbb{R}^n)$ (fonctions lisses à dérivées bornées).

12.2 Définition de la Dérivée

Pour une variable $F \in S$, la dérivée de Malliavin est le processus aléatoire $(D_t F)_{t \in [0, T]}$ défini par :

$$D_t F = \sum_{i=1}^n \frac{\partial f}{\partial x_i}(B_{t_1}, \dots, B_{t_n}) \mathbf{1}_{[0, t_i]}(t)$$

Interprétation : $D_t F$ mesure l'impact d'un choc infinitésimal du mouvement brownien à l'instant t sur la valeur finale de F .

Subtilité : $D_t F$ n'est pas un nombre, mais un élément de $L^2(\Omega \times [0, T])$. On le voit souvent comme une fonction du temps t pour chaque scénario ω .

13 L'Espace de Sobolev Stochastique ($D^{1,2}$)

La dérivée D est initialement définie sur S . Pour l'étendre à plus de variables (comme les intégrales d'Itô), on utilise une fermeture.

On définit la norme :

$$\|F\|_{1,2}^2 = E[F^2] + E \left[\int_0^T (D_t F)^2 dt \right]$$

$D^{1,2}$ est la fermeture de S sous cette norme. C'est l'espace des variables "une fois dérivables" au sens de Malliavin.

14 Règles de Calcul (Propriétés Fondamentales)

Ces règles sont cruciales pour les examens et la pratique :

- **Règle de la chaîne (Chain Rule)** : Si $F \in D^{1,2}$ et ϕ est Lipschitzienne, alors $\phi(F) \in D^{1,2}$ et :

$$D_t \phi(F) = \phi'(F) D_t F$$

- **Règle du produit** :

$$D_t(FG) = F D_t G + G D_t F$$

- **Dérivée d'une intégrale d'Itô** : Si $F = \int_0^T h_s dB_s$ avec h déterministe, alors :

$$D_t F = h_t$$

C'est le résultat le plus intuitif : la sensibilité de l'intégrale au bruit à l'instant t est exactement le poids h_t de ce bruit.

15 Interaction avec l'Information (Filtration)

Le document souligne deux points très subtils sur la relation entre D et la filtration $(\mathcal{F}_s)$:

- **Variables Mesurables (Propriété de "Non-anticipation")** : Si F est $\mathcal{F}_s$ -mesurable, alors son futur n'est pas sensible aux chocs browniens.

$$\text{Si } t > s, \text{ alors } D_t F = 0$$

- **Espérance Conditionnelle** : L'opérateur D et l'espérance conditionnelle commutent de la manière suivante :

$$D_t E[F | \mathcal{F}_s] = E[D_t F | \mathcal{F}_s] \mathbf{1}_{t \leq s}$$

Subtilité : On ne peut pas "voir" la sensibilité d'une espérance conditionnelle après l'instant s car, par définition, l'information est figée à s .

16 Pourquoi est-ce important pour la suite ?

Cette fiche pose les bases de la formule de Clark-Ocone. En finance, si vous avez un payoff F , le théorème de représentation d'Itô dit qu'il existe un processus de couverture θ_s tel que $F = E[F] + \int_0^T \theta_s dB_s$. Le calcul de Malliavin donne enfin la solution "miracle" pour trouver θ_s :

$$\theta_t = E[D_t F | \mathcal{F}_t]$$

C'est le lien direct entre la dérivée de Malliavin et la stratégie de couverture parfaite.

Points de vigilance pour les preuves :

- La linéarité de D est évidente, mais son caractère "fermé" (closability) est la partie difficile de la preuve mathématique pour passer de S à $D^{1,2}$.
- Toujours vérifier que $t \leq T$ dans les intégrales.

Part IV

Approfondissements sur les Poids de Malliavin

17 Méthode d'Intégration par Parties pour les Grecques

On considère un payoff $\Phi_T = f(S_T)$. Le prix à l'instant t est donné par :

$$P_t = e^{-r(T-t)} E^*[f(S_T) | \mathcal{F}_t] = F(t, S_t)$$

où la fonction F est définie par :

$$F(t, x) = e^{-r(T-t)} E^*[f(S_{T-t}^x)]$$

17.1 Proposition : Formules pour Delta et Gamma

On suppose que $\Phi_T = f(S_T)$. Le résultat suivant est **indépendant de f** .

On a les expressions suivantes pour les Grecques (Delta et Gamma) en utilisant des poids de Malliavin :

$$\begin{aligned}\Delta_t(x) &= e^{-r(T-t)} E^* \left[\frac{B_{T-t}}{x\sigma(T-t)} f(S_{T-t}^x) \right] \\ \Gamma_t(x) &= e^{-r(T-t)} E^* \left[\left(\frac{-B_{T-t}}{x^2\sigma(T-t)} + \frac{B_{T-t}^2 - (T-t)}{(x\sigma(T-t))^2} \right) f(S_{T-t}^x) \right]\end{aligned}$$

Les termes entre crochets qui multiplient $f(S_{T-t}^x)$ sont souvent appelés les poids de Malliavin (π). Cela permet d'exprimer $\Delta_t(x)$ et $\Gamma_t(x)$ sous la forme :

$$\text{Grecque} = E^*[f(S_{T-t}^x)\pi]$$

L'avantage majeur est que ces formules ne font pas intervenir la dérivée de f , ce qui est utile pour des payoffs discontinus (comme les options digitales).

18 Minimisation de la Variance

À l'instant $t = 0$ pour le payoff $f(S_T)$. On cherche à estimer une Grecque sous la forme :

$$\text{Grecque} = E_Q[f(S_T)\pi]$$

Il peut exister plusieurs poids π possibles (par exemple $\pi_1, \pi_2, \dots$) qui donnent le même résultat en espérance pour tout f :

$$E_Q[f(S_T)\pi_1] = E_Q[f(S_T)\pi_2] \quad \forall f$$

Cependant, leurs variances peuvent différer :

$$\text{Var}[f(S_T)\pi_1] \quad \text{vs} \quad \text{Var}[f(S_T)\pi_2]$$

18.1 Théorème

On cherche à trouver le poids π qui minimise la variance de l'estimateur. Le problème s'écrit :

$$\min_{\pi} \text{Var}[f(S_T)\pi]$$

sous la contrainte que π donne le bon prix (la bonne Grecque) pour tout f (ou du moins que l'espérance soit préservée).

Résultat : Si une variable aléatoire π satisfait la condition d'espérance, alors la solution optimale π_0 (celle qui minimise la variance) est donnée par l'espérance conditionnelle :

$$\pi_0 = E[\pi|S_T]$$

C'est la projection de π sur l'espace engendré par S_T .

18.2 Remarque sur l'unicité de la projection

La relation suivante est une équivalence :

$$E_Q[f(S_T)\pi_1] = E_Q[f(S_T)\pi_2] \quad \forall f \quad \Longleftrightarrow \quad E_Q[\pi_1|S_T] = E_Q[\pi_2|S_T]$$

18.3 Preuve du Théorème de Minimisation

On souhaite montrer que $\pi_0 = E[\pi|S_T]$ minimise la variance de l'estimateur $f(S_T)\pi$.

On peut écrire :

$$f(S_T)\pi - \text{Grecque} = \underbrace{f(S_T)(\pi - \pi_0)}_A + \underbrace{f(S_T)\pi_0 - \text{Grecque}}_B$$

En élevant au carré et en prenant l'espérance (ce qui correspond à la variance puisque l'espérance est nulle si on recentre ou on regarde le second moment de l'erreur), on a :

$$\text{Var}[f(S_T)\pi] = E[(f(S_T)(\pi - \pi_0) + (f(S_T)\pi_0 - \text{Grecque}))^2]$$

En développant :

$$\text{Var}[f(S_T)\pi] = E[(f(S_T)(\pi - \pi_0))^2] + \text{Var}[f(S_T)\pi_0] + 2E[f(S_T)(\pi - \pi_0)(f(S_T)\pi_0 - \text{Grecque})]$$

Le terme croisé (le dernier terme) est nul. En effet, en conditionnant par S_T :

$$\begin{aligned} E[f(S_T)(\pi - \pi_0)(f(S_T)\pi_0 - \text{Grecque})|S_T] &= (f(S_T)\pi_0 - \text{Grecque})f(S_T)E[(\pi - \pi_0)|S_T] \\ &= (f(S_T)\pi_0 - \text{Grecque})f(S_T)(E[\pi|S_T] - \pi_0) \\ &= 0 \quad \text{car } \pi_0 = E[\pi|S_T] \end{aligned}$$

Comme l'espérance conditionnelle est nulle, l'espérance totale est nulle. Ainsi :

$$\text{Var}[f(S_T)\pi] = \text{Var}[f(S_T)\pi_0] + E[(f(S_T)(\pi - \pi_0))^2]$$

Le second terme étant positif, la variance est minimisée lorsque $\pi = \pi_0$.

18.4 Définition de l'Espérance Conditionnelle

Soit $X \in L^1(\Omega, \mathcal{A}, P)$ et $\mathcal{G} \subset \mathcal{A}$ une sous-tribu.

L'espérance conditionnelle $E[X|\mathcal{G}]$ est l'**unique** variable aléatoire Z telle que :

- Z est $\mathcal{G}$ -mesurable.
- Pour toute variable aléatoire Y , $\mathcal{G}$ -mesurable et bornée :

$$E[XY] = E[ZY]$$