

Topics in Machine Learning

Cours complet

Zakari HACHEMI

Topics in ML - MMMEF
2025-2026

Contents

1	Régression Linéaire et Sélection de Modèles	1
1.1	Informations Générales du Cours	1
1.2	Introduction et Problématique	1
1.3	Modèles Linéaires (Multiple Linear Regression)	2
1.3.1	Définition et Modélisation	2
1.3.2	Estimation par Moindres Carrés Ordinaires (OLS)	3
1.3.3	Évaluation du Modèle	4
1.4	Sélection de Sous-ensembles (Subset Selection)	5
1.4.1	Best Subset Selection	5
1.4.2	Traitement des Variables Qualitatives (Dummy Variables)	5
1.4.3	Stepwise Selection (Méthodes Pas-à-Pas)	6
1.4.4	Critères de Choix du Modèle Optimal	6
1.5	Implémentation Pratique en R (Extraits)	7
2	Méthodes de Rétrécissement (Shrinkage Methods)	9
2.1	Introduction aux Méthodes de Rétrécissement (Shrinkage Methods)	9
2.1.1	Précision de Prédiction et Erreur Quadratique Moyenne (MSE)	9
2.1.2	Décomposition Biais-Variance	9
2.1.3	Modèle Linéaire et Théorème de Gauss-Markov	10
2.2	Régression Ridge	10
2.2.1	Formulation du Modèle	10
2.2.2	Solution Analytique	11
2.2.3	Mise à l'échelle des Prédicteurs (Scaling)	12
2.2.4	Forme Contrainte et Géométrie	12
2.2.5	Lien entre Moindres Carrés et Ridge (Opérateur Linéaire)	12
2.3	Applications en Traitement d'Image : Pénalisation	13
2.3.1	Données Manquantes et Inpainting	13
2.3.2	Régularisation de Tikhonov (Ridge en image)	14
2.4	Le LASSO (Least Absolute Selection and Shrinkage Operator)	14
2.4.1	Formulation	14
2.4.2	Propriété de Sélection de Variables (Géométrie)	14
2.4.3	Variantes du LASSO	15
2.4.4	Implémentation R (glmnet)	15
2.4.5	Variantes du Lasso	16
3	Méthodes Non-Linéaires : Polynômes et Splines	17
3.1	Introduction et Motivation	17
3.2	Approche par Dictionnaires de Fonctions	17
3.2.1	Exemples de dictionnaires	17
3.2.2	Construction du dictionnaire	18
3.3	Régression Polynomiale	18

3.3.1	Définition et Forme Matricielle	18
3.3.2	Orthonormalisation (Gram-Schmidt)	18
3.3.3	Risque et Compromis Biais-Variance	18
3.4	Sélection de Modèle	18
3.5	Splines de Régression	18
3.5.1	Fonctions constantes par morceaux	18
3.5.2	Splines Polynomiales et Continuité	19
3.5.3	Représentation par Base de Puissances Tronquées	19
3.5.4	Splines Naturelles	19
3.6	Mise en pratique avec R	19
4	Lissage Avancé, Ondelettes et Modèles Additifs	26
4.1	Smoothing Splines (Splines de Lissage)	26
4.1.1	Problématique et Motivation	26
4.1.2	Critère de Minimisation	26
4.1.3	Propriétés et Solution	27
4.1.4	Degrés de liberté effectifs	27
4.2	Régression par Ondelettes (Wavelet Regression)	27
4.2.1	Représentations Temps-Fréquence	27
4.2.2	Définition d'une Ondelette	28
4.2.3	Décomposition et Sparsité	28
4.2.4	Débruitage par Seuillage (Thresholding)	28
4.3	Modèles Additifs Généralisés (GAM)	29
4.3.1	Définition	29
4.3.2	Avantages et Limites	29
4.3.3	(★ EXAMEN) GAM pour la Classification (Régression Logistique)	30
4.3.4	Mise en œuvre en R	30
5	Machines à Vecteurs de Support (SVM)	33
5.1	Introduction et Contexte Historique	33
5.1.1	Objectif de la Classification Supervisée	33
5.2	Classification et Hyperplan Séparateur	33
5.2.1	Définition Mathématique	33
5.2.2	Règle de Décision	34
5.3	Le Classifieur à Marge Maximale	34
5.3.1	Principe	34
5.3.2	Optimisation	34
5.3.3	Vecteurs Supports et Dualité	34
5.4	Support Vector Classifier (Cas Non-Séparable)	35
5.4.1	Variables d'Écart (Slack Variables)	36
5.4.2	Formulation Duale (Soft Margin) et Résolution Mathématique	36
5.5	Support Vector Machines et Noyaux	38
5.5.1	Le "Kernel Trick"	38
5.5.2	Noyaux Usuels	39
5.6	Extensions et Pratique	39
5.6.1	Multi-classes	39
5.6.2	Mise en œuvre avec R (package e1071)	39

6	Fiche de Révision : Modélisation Statistique et Régression sous R (TP)	41
6.1	TP 1 : Méthodes de sélection de variables (Subset Selection)	41
6.1.1	Connaissances préalables	41
6.1.2	Ce qu'il faut retenir (Théorie et Pratique)	41
6.2	TP 2 : Régression Polynomiale et Sélection de Modèle	42
6.2.1	Connaissances préalables	42
6.2.2	Ce qu'il faut retenir (Théorie et Pratique)	42

Chapter 1

Régression Linéaire et Sélection de Modèles

1.1 Informations Générales du Cours

- **Structure** : Alternance entre cours magistraux et travaux pratiques (lab sessions) en R ou Python.
- **Contact** : fabien.navarro@univ-paris1.fr.
- **Évaluation** : Un examen final de 2h (le 13/03), sans session de rattrapage.
- **Ouvrages de référence** : *The Elements of Statistical Learning* (ESL, Hastie et al., 2009) et *An Introduction to Statistical Learning* (ISL, James et al., 2021/23).

1.2 Introduction et Problématique

- L'objectif central de la régression est d'expliquer une quantité (la variable à expliquer, Y) par d'autres variables (les variables explicatives ou prédicteurs, X).
- Les objectifs peuvent être descriptifs, c'est-à-dire comprendre comment les prédicteurs affectent la quantité à expliquer.
- Ils peuvent également être prédictifs, ce qui consiste à prédire la quantité à expliquer en connaissant les prédicteurs.
- On parle de "régression" lorsque la variable Y est quantitative, et de "classification" ou "discrimination" lorsqu'elle est qualitative.
- Le modèle général se formule par $Y = f(X) + \epsilon$, où f est une fonction inconnue de X et ϵ un terme d'erreur indépendant de X . Le but est d'estimer f à partir des observations.
- Le modèle linéaire suppose que f est une fonction linéaire : $f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$. L'estimation de f est grandement simplifiée puisqu'il suffit d'estimer $p+1$ coefficients au lieu d'une fonction en p dimensions.
- Bien que les relations réelles soient rarement strictement linéaires, la régression linéaire reste extrêmement utile sur les plans conceptuel et pratique. Elle offre de nets avantages en matière d'interprétabilité et de performances prédictives (faible biais si la relation réelle est quasi-linéaire).




Figure 1.1: Exemple de tâche de classification (Prédire le Default de paiement en fonction du solde et des revenus)




Figure 1.2: Illustration d'une frontière de décision pour un problème de classification binaire

- Cependant, si le nombre d'observations n est proche de p ($n \geq p$), le modèle peut souffrir de surapprentissage (overfitting) et d'une forte variance. Si $n < p$, la méthode des moindres carrés classique est inopérante : la matrice $X^T X$ n'est pas inversible (il y a plus d'inconnues que d'équations), le système admet une infinité de solutions et l'estimateur n'est plus unique (ce que l'on traduit parfois par un "sur-paramétrage" ou une variance infinie).
- Pour améliorer les modèles linéaires, on peut utiliser la sélection de sous-ensembles (Subset Selection), les méthodes de pénalisation/régularisation (Shrinkage comme Ridge ou Lasso) pour réduire la variance, ou la réduction de dimension.

1.3 Modèles Linéaires (Multiple Linear Regression)

1.3.1 Définition et Modélisation

- Les données se composent de n observations $(Y, X_1, \dots, X_p)$ notées $(y_i, x_{1,i}, \dots, x_{p,i})$.



Figure 1.3: Exemple de relation quasi-linéaire ($\text{Income} \approx \beta_0 + \beta_1 \text{Education}$)

Figure 1.4: Ajustement d'un modèle de régression linéaire simple sur un nuage de points

- L'équation du modèle linéaire multiple (mlm) postule l'existence de $p+1$ paramètres inconnus tels que $Y_i = \beta_0 + \beta_1 x_{1,i} + \dots + \beta_p x_{p,i} + \epsilon_i$.
- Sous forme matricielle, le modèle s'écrit $Y = X\beta + \epsilon$. Ici, $Y \in \mathbb{R}^n$ est le vecteur des réponses, $X \in \mathbb{R}^{n \times (p+1)}$ est la matrice de design, $\beta \in \mathbb{R}^{p+1}$ est le vecteur des coefficients, et $\epsilon \in \mathbb{R}^n$ est le terme d'erreur.
- On suppose que la variance des erreurs est constante : $\text{Var}(\epsilon_i) = \sigma^2$. Le modèle est qualifié de gaussien si $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$.

1.3.2 Estimation par Moindres Carrés Ordinaires (OLS)

- L'estimateur OLS est construit pour minimiser l'erreur d'estimation : $\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} \|Y - X\beta\|^2$.
- Il correspond à la solution des équations normales : $X^T X \beta - X^T Y = 0$.




Figure 2: Credit data set

Figure 1.5: Matrice de nuages de points (Scatterplot Matrix) pour le dataset Credit

- L'estimation des paramètres est donnée par la formule $\hat{\beta} = (X^T X)^{-1} X^T Y$.
- Les valeurs ajustées (prédites) sont $\hat{Y} = X\hat{\beta} = HY$, où $H = X(X^T X)^{-1} X^T$ est appelée la matrice "chapeau" (hat matrix).
- Le vecteur des résidus est calculé par $e = Y - \hat{Y} = (I - H)Y$.
- Selon le théorème de Gauss-Markov, les estimateurs OLS sont dits "BLUE" (Best Linear Unbiased Estimators) : ils sont sans biais et de variance minimale parmi les estimateurs linéaires sans biais.

1.3.3 Évaluation du Modèle

- La somme des carrés des résidus est définie par $RSS = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$.
- L'écart-type résiduel (RSE) estime l'écart-type de l'erreur σ et se calcule par $\hat{\sigma} = RSE = \sqrt{\frac{RSS}{n-2}}$ (dans le cas simple).
- La qualité d'ajustement est aussi mesurée par le R^2 , représentant la fraction de variance expliquée : $R^2 = 1 - \frac{RSS}{TSS}$, où le TSS (Total Sum of Squares) est $\sum_{i=1}^n (y_i - \bar{y})^2$. Plus le R^2 est grand, plus le modèle explique efficacement la variance des données.

1.4 Sélection de Sous-ensembles (Subset Selection)

Afin de pallier la complexité d'un modèle incluant de multiples variables non pertinentes (ce qui nuit à l'interprétabilité), plusieurs techniques de sélection existent.

1.4.1 Best Subset Selection

- Soit $\mathcal{M}_0$ le modèle nul, qui ne contient aucun prédicteur et prédit systématiquement la moyenne de l'échantillon.
- Pour $k = 1, 2, \dots, p$, on ajuste la totalité des $\binom{p}{k}$ modèles contenant très exactement k prédicteurs. (★ EXAMEN) Au total, cela demande d'ajuster 2^p modèles, un calcul qui explose rapidement en complexité.
- Parmi ces modèles de taille k , on retient le meilleur (celui ayant le plus petit RSS ou le plus grand R^2), que l'on nomme $\mathcal{M}_k$. (★ EXAMEN) **Attention au piège de l'emboîtement** : le modèle $\mathcal{M}_k$ n'est absolument pas garanti de contenir les variables du modèle $\mathcal{M}_{k-1}$. Les modèles successifs dans "Best Subset" ne sont donc généralement pas emboîtés.
- Enfin, on choisit un unique modèle optimal parmi la séquence $\mathcal{M}_0, \dots, \mathcal{M}_p$ en se basant sur des critères pénalisés comme le C_p (AIC), le BIC, le R^2 ajusté, ou l'erreur de validation croisée.




Figure 1.6: RSS et R^2 pour l'ensemble des modèles ajustés en fonction du nombre de prédicteurs. La courbe rouge relie les meilleurs modèles $\mathcal{M}_k$.

1.4.2 Traitement des Variables Qualitatives (Dummy Variables)

- Si un prédicteur qualitatif possède deux niveaux (ex: genre), on crée une variable indicatrice valant 1 ou 0. Le choix de la valeur (ex: 0 pour homme, 1 pour femme) est arbitraire et n'altère pas l'ajustement global, mais il change l'interprétation des coefficients.
- Si le prédicteur possède plus de deux niveaux, une seule variable indicatrice ne suffit pas. On crée alors de multiples variables indicatrices, au nombre de niveaux moins un.
- Le niveau ne disposant pas de variable indicatrice propre est utilisé comme catégorie de référence (baseline).

1.4.3 Stepwise Selection (Méthodes Pas-à-Pas)

La sélection "Best Subset" devient trop onéreuse en calcul lorsque p est grand (nécessité de calculer 2^p modèles) et risque d'engendrer un surapprentissage (overfitting). Les méthodes Stepwise offrent une alternative plus rapide.

SUB

Forward Stepwise Selection

- Commence par le modèle nul $\mathcal{M}_0$.
- À chaque itération k (de 0 à $p - 1$), l'algorithme évalue les $p - k$ modèles qui ajoutent un unique prédicteur supplémentaire au modèle $\mathcal{M}_k$. (**★ EXAMEN**) **Propriété clé** : Étant donné qu'on ne fait qu'ajouter, les modèles sont **emboîtés**. Les variables du modèle $\mathcal{M}_k$ sont un sous-ensemble strict des variables du modèle $\mathcal{M}_{k+1}$.
- Le meilleur de ces $p - k$ modèles (plus petit RSS ou plus grand R^2) est sélectionné et nommé $\mathcal{M}_{k+1}$.
- (**★ EXAMEN**) **Avantage computationnel** : cette approche n'ajuste qu'environ $1 + p(p+1)/2$ modèles au total, contre 2^p pour Best Subset. Elle peut s'appliquer même dans le cas critique où $n < p$.
- Inconvénient : il n'y a aucune garantie que le modèle sélectionné soit le meilleur possible parmi tous les 2^p modèles existants.

SUB

Backward Stepwise Selection

- Commence à l'inverse, par le modèle complet $\mathcal{M}_p$ contenant tous les prédicteurs.
- À chaque itération k (de p à 1), on évalue les k modèles formés en retirant exactement un prédicteur de $\mathcal{M}_k$. Comme pour le Forward, ces modèles sont **emboîtés** (les variables de $\mathcal{M}_{k-1}$ sont un sous-ensemble de $\mathcal{M}_k$). (**★ EXAMEN**) La complexité de calcul est aussi de l'ordre de $1 + p(p+1)/2$ modèles.
- Le meilleur est retenu comme $\mathcal{M}_{k-1}$.
- Contrainte forte : exige impérativement que $n > p$ afin de pouvoir ajuster le modèle complet initial.

1.4.4 Critères de Choix du Modèle Optimal

Le RSS et le R^2 calculés sur les données d'entraînement diminuent mécaniquement à mesure que le nombre de variables augmente, ce qui les rend inaptes pour sélectionner la bonne taille de modèle. Il faut recourir à d'autres indicateurs pour estimer l'erreur de test (soit indirectement via pénalité, soit directement).

- **C_p de Mallows / AIC** : Estime l'erreur de test via $C_p = \frac{1}{n}(RSS + 2d\hat{\sigma}^2)$, où d est la dimension du modèle. Dans le cadre d'erreurs gaussiennes, l'AIC ($-2\log L + 2d$) est équivalent au C_p .

- **BIC** : Se calcule par $BIC = \frac{1}{n}(RSS + \log(n)d\hat{\sigma}^2)$. Il remplace le facteur 2 de l'AIC par $\log(n)$. (★ EXAMEN) **Point crucial** : puisque $\log(n) > 2$ pour $n > 7$, le BIC pénalise plus lourdement la complexité que l'AIC. En conséquence, le BIC a tendance à sélectionner des modèles plus petits (plus parcimonieux) que l'AIC.
- R^2 **Ajusté** : Défini par $1 - \frac{RSS/(n-d-1)}{TSS/(n-1)}$. Contrairement au R^2 usuel, il pénalise l'inclusion de variables superflues.
- **Validation Croisée (CV) et Validation Set** : L'erreur de test est estimée directement (sans estimer σ^2 ni d) en retirant une partie des données.
 - **Attention cruciale de Leakage** : la sélection des variables doit impérativement s'effectuer *uniquement* sur le jeu d'entraînement pour chaque sous-échantillon. Faire la sélection sur l'ensemble complet avant la CV introduirait un biais majeur sous-estimant fortement l'erreur réelle.
 - (★ EXAMEN) **Ré-Ajustement Final (Refit sur données complètes)** : Une fois que la taille ou le sous-ensemble optimal de variables a été choisi par validation (par exemple "le modèle contenant les variables 1, 3, 5 et 8 est le meilleur"), il est **impératif** de réajuster l'équation finale sur l'intégralité du dataset disponible (Train + Validation)**. Le ***validation set*** ne sert qu'à sélectionner les ***dimensions*** ou le sous-ensemble ; le modèle livré in fine doit bénéficier de l'estimation de coefficients (β) la plus précise possible, usant de la totalité des données existantes.





Figure 1.7: Critères de sélection pénalisés (C_p , BIC, R^2 ajusté) appliqués à la séquence de modèles $\mathcal{M}_k$.

1.5 Implémentation Pratique en R (Extraits)

- Importer des données : `read.table("fichier.txt", header=T)` ou `read.csv()`.
- Supprimer une colonne (ex: index) : `Credit[, "X"] <- NULL`.
- Inspecter la structure des données : `str(Credit)`. Visualiser les corrélations : `ggpairs()`.
- Ajuster un modèle linéaire : `reg <- lm(Y ~ X1, data=w)`. Résumé statistique complet : `summary(reg)`.
- Prédire une nouvelle valeur : `predict(reg, data.frame(X1=8), interval="confidence")`.
- Intervalles de confiance des coefficients : `confint(reg, level=0.95)`.

Figure 1.8: Visualisation avancée avec `ggpairs` (corrélations et densités)

- Best Subset Selection : utiliser la librairie `leaps` avec `regsubsets(Balance ~ ., data=Credit, nvmax=11)`.
- Forward Selection : ajouter l'argument `method="forward"` dans `regsubsets`.
- Scinder les données en Test/Train aléatoirement : `train <- sample(c(TRUE,FALSE), nrow(Credit), rep=TRUE)`. *Attention : cette méthode assigne chaque ligne au train ou au test avec 50% de chance, la taille finale varie donc. Pour forcer une proportion exacte (ex: 80% / 20%), on utilisera plutôt `train <- sample(1:nrow(Credit), size = floor(0.8*nrow(Credit)))`.*
- Créer une matrice de design pour gérer automatiquement les *dummy variables* sur les données de test : `model.matrix(Balance ~ ., data=Credit[test,])`. **Important :** C'est impératif pour s'assurer que les indicatrices de test sont construites de manière identique au train, évitant un décalage si un niveau catégoriel manque dans le jeu de test.

Chapter 2

Méthodes de Rétrécissement (Shrinkage Methods)

2.1 Introduction aux Méthodes de Rétrécissement (Shrinkage Methods)

Les méthodes traditionnelles de sélection de sous-ensembles utilisent les moindres carrés pour ajuster un modèle linéaire contenant un sous-ensemble des prédicteurs. En alternative, nous pouvons ajuster un modèle contenant l'ensemble des p prédicteurs en utilisant une technique qui contraint ou régularise les estimations des coefficients. De manière équivalente, cela rétrécit (shrink) les estimations des coefficients vers zéro. Il n'est pas forcément évident de comprendre pourquoi une telle contrainte améliore l'ajustement, mais il s'avère que le rétrécissement des coefficients permet de réduire significativement leur variance.

2.1.1 Précision de Prédiction et Erreur Quadratique Moyenne (MSE)

Supposons que nous observons des données de la forme :

$$y_i = f(x_i) + \epsilon_i, \quad i = 1, \dots, n$$

où $f : \mathbb{R}^p \rightarrow \mathbb{R}$. Les $x_i \in \mathbb{R}^p$ sont des mesures de prédicteurs fixes. Les $\epsilon_i \in \mathbb{R}$ sont des erreurs aléatoires avec $\mathbb{E}(\epsilon_i) = 0$, $Var(\epsilon_i) = \sigma^2$ et $Cov(\epsilon_i, \epsilon_j) = 0$.

Considérons un nouveau point de donnée $y_0 = f(x_0) + \epsilon_0$, indépendant des précédents, que nous cherchons à prédire à l'aide de $\hat{f}(x_0)$. L'erreur de prédiction (PE) est liée à l'erreur quadratique moyenne (MSE) par la relation suivante :

$$PE(\hat{f}(x_0)) = \mathbb{E}[(y_0 - \hat{f}(x_0))^2]$$

$$PE(\hat{f}(x_0)) = \sigma^2 + MSE(\hat{f}(x_0))$$

Ainsi, le PE et le MSE représentent essentiellement le même concept : optimiser l'un revient à optimiser l'autre.

2.1.2 Décomposition Biais-Variance

L'erreur quadratique moyenne (MSE) dépend de deux quantités fondamentales :

$$MSE(\hat{f}(x_0)) = \text{Biais}(\hat{f}(x_0))^2 + Var(\hat{f}(x_0))$$

Ceci est connu sous le nom de compromis biais-variance.




Figure 2.1: Évolution du Biais au carré (en rouge) et de la Variance (en bleu) en fonction de la flexibilité ou de la pénalité (λ).

2.1.3 Modèle Linéaire et Théorème de Gauss-Markov

Dans le cadre d'un modèle linéaire, on suppose $f(x_i) = x_i^T \beta^*$. La prédiction par les moindres carrés (LS) est donnée par $\hat{f}^{LS}(x_i) = x_i^T \hat{\beta}$. Le théorème de Gauss-Markov stipule que cet estimateur est le "BLUE" (Best Linear Unbiased Estimator). Cela signifie que parmi tous les estimateurs linéaires et sans biais, l'estimateur des moindres carrés possède la plus petite variance, et donc le plus petit MSE.

Cependant, il est possible de construire un autre estimateur linéaire (qui introduit un biais) mais qui possède un MSE global inférieur à celui de l'estimateur des moindres carrés.

En analysant l'erreur pour la régression linéaire sur l'ensemble des points, on obtient :

$$PE(\hat{f}) = \sigma^2 + 0 + \frac{p\sigma^2}{n}$$

La variance $\frac{1}{n} \sum Var(x_i^T \hat{\beta})$ correspond exactement à $\frac{p\sigma^2}{n}$. Cela démontre que la variance croît linéairement avec le nombre de prédicteurs p . Chaque variable prédictive supplémentaire ajoute la même quantité de variance $\frac{\sigma^2}{n}$, que son vrai coefficient soit grand, petit ou nul. Nous pouvons donc faire mieux en rétrécissant (shrink) les petits coefficients vers zéro. Cela introduit un biais, mais réduit considérablement la variance pour obtenir une image globale plus stable.

2.2 Régression Ridge

2.2.1 Formulation du Modèle

La procédure des moindres carrés (LS) estime les coefficients en minimisant le RSS :

$$RSS = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2$$

En contraste, la régression Ridge estime les coefficients $\hat{\beta}^R$ en minimisant la quantité suivante :

$$RSS + \lambda \sum_{j=1}^p \beta_j^2$$

où $\lambda \geq 0$ est un paramètre de réglage qui contrôle la force du terme de pénalité.

- Lorsque $\lambda = 0$, on retrouve l'estimation de la régression linéaire classique.
- Lorsque $\lambda = \infty$, la pénalité force les coefficients à être nuls : $\hat{\beta}^R = 0$.

Le second terme est une "pénalité de rétrécissement" qui pousse les estimations des β_j vers zéro. Le choix d'un bon paramètre λ est critique et se fait généralement par validation croisée.




Figure 2.2: Shrinkage des coefficients de la régression Ridge en fonction de λ . Les coefficients convergent asymptotiquement vers 0 sans jamais l'atteindre exactement.

2.2.2 Solution Analytique

En calculant la dérivée du critère $(y - X\beta)^T(y - X\beta) + \lambda\beta^T\beta$ par rapport à β , on obtient les équations normales de Ridge:

$$X^T y = (X^T X + \lambda I_p) \beta$$

Ce qui donne l'estimateur Ridge explicite :

$$\hat{\beta}^R = (X^T X + \lambda I_p)^{-1} X^T y$$

Contrairement à l'estimateur des moindres carrés qui n'existe pas toujours (si $X^T X$ n'est pas inversible), la solution Ridge est toujours unique pour $\lambda > 0$, car la matrice $(X^T X + \lambda I_p)$ est toujours inversible.

(★ EXAMEN) Prédicteurs identiques (Grouping Effect) : Si deux variables sont rigoureusement identiques temporellement (ex: $n = 2, p = 2, X_1 = X_2$), la régression Ridge divisera exactement les coefficients de manière égale ($\hat{\beta}_1^R = \hat{\beta}_2^R$). Le Lasso, au contraire, est mathématiquement instable dans cette configuration et choisira arbitrairement l'une des deux variables en annulant le coefficient de l'autre.

2.2.3 Mise à l'échelle des Prédicteurs (Scaling)

Les estimateurs des moindres carrés sont invariants à l'échelle : multiplier un prédicteur X_j par une constante c entraîne simplement la division du coefficient estimé par c , gardant $X_j\hat{\beta}_j$ inchangé. À l'inverse, les estimations de la régression Ridge peuvent changer substantiellement si l'on multiplie un prédicteur par une constante. Ceci est dû à la somme des carrés des coefficients dans la pénalité. Il est donc **absolument impératif de centrer-réduire (standardiser)** les prédicteurs avant d'ajuster un modèle Ridge ou Lasso, sous peine d'attribuer par erreur une faible pénalité aux variables possédant des valeurs modélisées sur une grande échelle unitaire.

(★ EXAMEN) **Règle d'Or (Validation et Test) :** Lors de l'évaluation sur un jeu de test, il faut **impérativement utiliser la moyenne et l'écart-type calculés sur l'ensemble d'entraînement** pour standardiser les données de test. Jamais l'inverse, sous peine de fuite de données (data leakage). Par exemple, si l'intervalle d'entraînement était $[-10, 10]$ et qu'on l'a ramené à $[-1, 1]$ (soit une division par 10), des valeurs test évoluant sur $[-11, 8]$ devront impérativement devenir $[-1.1, 0.8]$, de façon purement proportionnelle.

2.2.4 Forme Contrainte et Géométrie

La régression Ridge peut être reformulée comme un problème d'optimisation sous contrainte :

$$\hat{\beta}^R = \arg \min_{\beta \in \mathbb{R}^p} \|y - X\beta\|_2^2 \quad \text{s.c.} \quad \|\beta\|_2^2 \leq s$$

Géométriquement, la contrainte Ridge (pénalité L_2) définit une région en forme de cercle (ou hypersphère) centrée sur l'origine. Les estimations Ridge sont données par le premier point de contact entre les ellipses d'isovaleurs du RSS (centrées sur $\hat{\beta}^{LS}$) et cette région de contrainte ronde. En raison de l'absence de "coins", les ellipses touchent presque toujours la frontière du cercle sans intercepter exactement un axe. De ce fait, les coefficients Ridge contournent le zéro (ils rétrécissent asymptotiquement) sans jamais s'y annuler formellement.

2.2.5 Lien entre Moindres Carrés et Ridge (Opérateur Linéaire)

En posant l'opérateur linéaire matriciel $W = (X^T X + \lambda I_p)^{-1} X^T X$, on trouve une relation analytique fondamentale liant l'estimateur Ridge à celui des moindres carrés (OLS) via une simple transformation géométrique : (★ EXAMEN)

$$\hat{\beta}^{Ridge} = W \hat{\beta}^{LS} \quad (2.1)$$

De ce fait, la variance de l'estimateur Ridge se formule formellement en fonction de la matrice de covariance originelle $(X^T X)^{-1}$: (★ EXAMEN)

$$\mathbb{V}[\hat{\beta}^{Ridge}] = \sigma^2 W (X^T X)^{-1} W^T \quad (2.2)$$

On a toujours $\mathbb{V}(x^T \hat{\beta}^{LS}) \geq \mathbb{V}(x^T \hat{\beta}^{Ridge})$.

(★ EXAMEN) **Cas particulier Orthonormal ($X^T X = I_p$) :** Si les variables explicatives sont orthonormales, la relation se simplifie considérablement en $\hat{\beta}^{Ridge} = \frac{1}{1+\lambda} \hat{\beta}^{LS}$, ce qui nous permet de dériver directement l'Espérance et la Variance du nouvel estimateur :

$$\mathbb{E}[\hat{\beta}^{Ridge}] = \frac{1}{1+\lambda} \beta \quad (2.3)$$

$$\mathbb{V}[\hat{\beta}^{Ridge}] = \frac{\sigma^2}{(1+\lambda)^2} I_p \quad (2.4)$$

L'erreur quadratique moyenne de l'estimateur Ridge (somme intégrale de la variance et du biais scalaire au carré) devient alors explicitement :

$$MSE(\hat{\beta}^R) = (1+\lambda)^{-2} (p\sigma^2 + \lambda^2 \beta^T \beta) \quad (2.5)$$

Le biais augmente avec λ , tandis que la variance calculée sur les données de test va **diminuer de façon monotone** (*steadily decrease*). Un compromis est donc nécessaire pour optimiser le MSE.

(★ EXAMEN) **Raisonnement Type - Flexibilité et Biais-Variance** : Il est essentiel de formuler l'arbitrage ainsi : "Comparé aux moindres carrés, Ridge (ou tout estimateur régularisé) est **moins flexible** (il contraint les coefficients). Par conséquent, il **améliore la précision des prédictions** lorsque la baisse de sa **variance** excède largement la légère augmentation de son **biais**."

Sens de variation : Attention au sens du paramètre ! Si l'on écrit la contrainte de norme comme $\sum |\beta_j| \leq s$ (ou $\|\beta\|_2^2 \leq s$), alors **quand s augmente, la flexibilité augmente** (on "relâche" le corset vers la solution libre des moindres carrés). En conséquence, la variance augmente et le biais diminue, dessinant une courbe en "U" classique pour l'erreur de test globale.




Figure 2.3: Compromis Biais-Variance : Évolution de l'erreur quadratique moyenne (MSE) de l'estimateur Ridge en fonction du paramètre de pénalité λ . L'estimateur robuste permet de dépasser les moindres carrés.

2.3 Applications en Traitement d'Image : Pénalisation

2.3.1 Données Manquantes et Inpainting

Dans de nombreuses situations en traitement d'images, des pixels peuvent manquer (défaut de capteur, compression, altération). Restaurer ces parties manquantes est appelé "inpainting".

Le modèle de dégradation entre l'image parfaite x et l'image observée dégradée s s'écrit :

$$s = Hx$$

où H est une matrice diagonale valant 1 si le pixel est observé, et 0 sinon. Estimer x à partir de s est un problème inverse mal posé car il y a moins d'observations que d'inconnues.

2.3.2 Régularisation de Tikhonov (Ridge en image)

Pour stabiliser l'inversion, on impose que l'énergie des variations de l'image soit faible. On minimise la fonctionnelle suivante :

$$J(x) = \underbrace{\frac{1}{2} \|s - Hx\|^2}_{\text{Fidélité aux données}} + \underbrace{\frac{\lambda}{2} \|\Delta x\|^2}_{\text{Pénalité}}$$

La convexité de J implique l'existence d'un minimum global. La dérivée du terme d'attache aux données $\frac{1}{2} \|s - Hx\|^2$ est formellement $-H^T(s - Hx)$. Or, puisque H est un masque diagonal binaire ($H^T = H$ et $H^2 = H$) et que les observations manquantes dans s valent 0 ($HS = s$), on a $H^T(s - Hx) = s - Hx$. La solution peut donc être trouvée via une méthode de descente de gradient à pas fixe très optimisée :

$$x^{(t+1)} = x^{(t)} + \mu(s - Hx^{(t)} - \lambda \Delta^* \Delta x^{(t)})$$

La condition de convergence pour le pas μ est $0 < \mu < \frac{2}{1+4\lambda}$.

2.4 Le LASSO (Least Absolute Selection and Shrinkage Operator)

La régression Ridge présente un désavantage évident : elle inclut toujours les p prédicteurs dans le modèle final (elle ne fait pas de sélection de variables). Le Lasso surmonte ce problème en utilisant une pénalité L_1 plutôt qu'une pénalité L_2 .

2.4.1 Formulation

Les coefficients du Lasso $\hat{\beta}_\lambda^L$ minimisent la quantité :

$$RSS + \lambda \sum_{j=1}^p |\beta_j|$$

La pénalité ℓ_1 a pour effet de forcer exactement à zéro certains coefficients lorsque λ est suffisamment grand. Par conséquent, le Lasso réalise une sélection de variables et produit des modèles dits *parcimonieux* (sparse).

2.4.2 Propriété de Sélection de Variables (Géométrie)

Le Lasso peut s'écrire sous forme contrainte :

$$\hat{\beta}^{Lasso} = \arg \min_{\beta \in \mathbb{R}^p} \|y - X\beta\|_2^2 \quad \text{s.c.} \quad \|\beta\|_1 \leq s$$

Contrairement à la géométrie circulaire et lisse de Ridge, la région de contrainte du Lasso a la forme d'un polytope, typiquement un losange (ou diamant en 2D) possédant des "coins" extrêmement anguleux et situés exactement sur les axes des coefficients. Lorsque les ellipses de contours du RSS s'étendent pour rencontrer cette région de contrainte, la probabilité est extrêmement forte que le premier point de contact "s'accroche" précisément sur l'un de ces coins tranchants (par exemple là où $\beta_1 = 0$). (★ **EXAMEN**) Cela explique la propriété fondamentale du Lasso : forcer strictement une fraction des coefficients à s'annuler, produisant ainsi des modèles rares (parcimonieux) et agissant mécaniquement comme un opérateur de sélection naturelle de variables.




Figure 2.4: Profils des coefficients Lasso en fonction du logarithme de λ . Contrairement à Ridge, les chemins s'annulent exactement à partir d'un certain seuil de pénalité.

2.4.3 Variantes du LASSO

Afin de contourner certaines limitations du Lasso standard (par exemple sa difficulté à sélectionner plus de n variables lorsque $p > n$, ou son caractère arbitraire lorsqu'il doit choisir une seule variable parmi un groupe de variables fortement corrélées), plusieurs extensions ont été développées :

- **(★ EXAMEN) Elastic Net** : Modèle très populaire qui combine les pénalités L_1 (Lasso) et L_2 (Ridge). Il minimise $RSS + \lambda_1 \sum |\beta_j| + \lambda_2 \sum \beta_j^2$. L'Elastic Net conserve l'effet de sélection (sparsité) du Lasso tout en bénéficiant de l'effet de groupe (grouping effect) du Ridge pour retenir ensemble des variables corrélées. Il est aussi applicable quand $p > n$.
- **Autres Variantes (Vocabulaire)** :
 - *Fused Lasso* : Pour les données ayant un ordre naturel (ex: séries temporelles), pénalise aussi la différence entre coefficients successifs.
 - *Grouped Lasso* : Sélectionne ou élimine des groupes entiers de variables (pratique pour les variables catégorielles encodées en multiples *dummies*).
 - *Adaptive Lasso* : Modifie les poids de pénalité selon l'importance de chaque variable pour garantir que l'estimateur soit un "oracle".

2.4.4 Implémentation R (glmnet)

Le package `glmnet` permet de fitter Ridge ($\alpha=0$) et Lasso ($\alpha=1$). La sélection de la valeur optimale de λ se fait via validation croisée avec la fonction `cv.glmnet`.

```
library(glmnet)
# x est la matrice des prédicteurs standardisés, y est la réponse
grid <- 10^seq(10, -2, length=100)
# Pour Ridge: alpha=0. (Pour Lasso ce serait alpha=1)
mod.ridge <- glmnet(x, y, alpha=0, lambda=grid)
cv.out <- cv.glmnet(x[train,], y[train], alpha=0)
lambda.cv <- cv.out$lambda.min
```




Figure 2.5: À gauche: Distribution typique des coefficients sparsifiés par Lasso. À droite: Décomposition du MSE équivalente à celle de Ridge.

2.4.5 Variantes du Lasso

Pour pallier certaines limites du Lasso (comme l'incapacité de sélectionner plus de n variables quand $p > n$, ou la sélection d'une seule variable au sein d'un groupe très corrélé), plusieurs variantes ont été développées:

- **Elastic Net** (Zou and Hastie, 2005) : combine les pénalités L_1 et L_2 .

$$\hat{\beta}^{elnet} = \arg \min_{\beta \in \mathbb{R}^p} \|y - X\beta\|_2^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2$$

- **Fused Lasso** (Tibshirani et al., 2005).
- **Adaptive Lasso** (Zou, 2006).
- **Grouped Lasso** (Yuan and Lin, 2007).

Chapter 3

Méthodes Non-Linéaires : Polynômes et Splines

3.1 Introduction et Motivation

Le modèle de régression standard repose sur l'hypothèse d'une relation linéaire entre les variables prédictives X et la variable cible Y :

$$Y = f(X) + \epsilon = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \epsilon \quad (3.1)$$

où f est une fonction inconnue et ϵ est un terme d'erreur indépendant de X .

Bien que les modèles linéaires soient simples à interpréter et à calculer, l'hypothèse de linéarité n'est souvent qu'une approximation. Pour améliorer la performance prédictive tout en conservant une certaine interprétabilité, nous pouvons explorer deux voies :

- **Réduction de la complexité** : Méthodes de régularisation (Ridge, Lasso) pour réduire la variance.
- **Flexibilité non-linéaire** : Utilisation de polynômes, de fonctions en escalier ou de splines.

3.2 Approche par Dictionnaires de Fonctions

L'idée centrale pour modéliser une fonction non-linéaire f est d'utiliser un développement sur un **dictionnaire** $\mathcal{D} = \{h_m\}_{m=1}^M$:

$$f(X) = \sum_{m=1}^M \beta_m h_m(X) \quad (3.2)$$

3.2.1 Exemples de dictionnaires

- **Modèle Linéaire** : $h_m(x) = x_m$.
- **Modèle Polynomial** : $h_m(x) = x^m$.
- **Transformations log/racine** : $h_m(x) = \log(x_m)$ ou $\sqrt{x_m}$.
- **Séries de Fourier** : Base de sinus et cosinus pour les données périodiques.
- **Splines et Ondelettes** : Pour une flexibilité locale.

3.2.2 Construction du dictionnaire

On peut construire ces ensembles par **restriction** (connaissance métier), par **sélection de modèle** (ne garder que les fonctions significatives) ou par **régularisation** (utiliser un grand dictionnaire avec des contraintes sur les coefficients).

3.3 Régression Polynomiale

3.3.1 Définition et Forme Matricielle

Le modèle polynomial d'ordre m s'écrit:

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \cdots + \beta_m x_i^m + \epsilon_i \quad (3.3)$$

Sous forme matricielle $Y = X_m \beta + \epsilon$, la matrice de design X_m est une **matrice de Vandermonde**:

$$X_m = \begin{pmatrix} 1 & x_1 & \cdots & x_1^m \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^m \end{pmatrix} \quad (3.4)$$

L'estimateur des moindres carrés est $\hat{\beta} = (X_m^T X_m)^{-1} X_m^T Y$.

3.3.2 Orthonormalisation (Gram-Schmidt)

L'utilisation directe des puissances x^k peut entraîner une forte colinéarité. On préfère souvent utiliser des **polynômes orthogonaux** $h_k(x)$ tels que $\langle h_k, h_l \rangle = \delta_{kl}$. En R, la fonction `poly(x, degree)` effectue cette transformation par défaut.

3.3.3 Risque et Compromis Biais-Variance

L'erreur quadratique moyenne (MSE) se décompose en:

$$MSE(\hat{f}) = \text{Biais}^2(\hat{f}) + \text{Var}(\hat{f}) \quad (3.5)$$

Augmenter le degré du polynôme réduit le biais mais augmente la variance. Un degré trop élevé conduit au **sur-apprentissage** (overfitting) ou "polynomial wiggle".

3.4 Sélection de Modèle

Le risque empirique (RSS) diminue toujours avec la complexité. Pour choisir le degré optimal m , on utilise des critères pénalisés ou la validation croisée:

- **Statistique C_p de Mallows / AIC** : $R_n(\hat{f}_m) + 2 \frac{\sigma^2(m+1)}{n}$.
- **ANOVA** : Pour tester si un modèle $\mathcal{M}_{m+1}$ apporte une amélioration significative par rapport à $\mathcal{M}_m$ (modèles emboîtés).

3.5 Splines de Régression

3.5.1 Fonctions constantes par morceaux

Au lieu d'imposer une structure globale, on divise le support de X en segments via des **nœuds** (knots) $\xi_1, \dots, \xi_K$. Dans chaque intervalle, on ajuste une constante. Le dictionnaire est alors composé de fonctions indicatrices $h_m(x) = I(\xi_m \leq x < \xi_{m+1})$.

3.5.2 Splines Polynomiales et Continuité

- **Polynômes par morceaux** : On ajuste un polynôme (ex: cubique) dans chaque segment. Sans contraintes, la fonction est discontinue aux nœuds.
- **Splines de degré d** : Ce sont des polynômes par morceaux de degré d possédant des dérivées continues aux nœuds. La régression spline est donc une régression polynomiale par morceaux (**★ EXAMEN**) **avec des contraintes (de continuité) aux nœuds** (*with constraints at nodes*).
- **Splines Cubiques ($d = 3$)** : Les plus utilisées. Elles assurent la continuité de la fonction, de la pente (1ère dérivée) et de la courbure (2ème dérivée).

3.5.3 Représentation par Base de Puissances Tronquées

Pour une spline cubique avec K nœuds, la base est composée de $\{1, x, x^2, x^3\}$ et des fonctions de puissances tronquées:

$$h(x, \xi) = (x - \xi)_+^3 = \begin{cases} 0 & \text{si } x < \xi \\ (x - \xi)^3 & \text{si } x \geq \xi \end{cases} \quad (3.6)$$

(**★ EXAMEN**) Le nombre total de degrés de liberté (DF) d'une spline cubique est exactement de $K + 4$ (en incluant l'intercept, 3 pour les parties polynomiales de base, et K pour chaque nœud). Par exemple, pour une spline paramétrée avec 3 nœuds locaux, il y aura $3 + 4 = 7$ degrés de liberté au total.

3.5.4 Splines Naturelles


Les splines ont tendance à être instables aux bords (forte variance). Les **splines naturelles** imposent une contrainte de linéarité au-delà des nœuds extrêmes, ce qui stabilise les estimations aux frontières.

(**★ EXAMEN**) **Raisonnement Type - Modèles Non-Linéaires** : Comparé à l'estimateur standard des moindres carrés, un estimateur non-linéaire (comme une spline) est **plus flexible**. Il **améliore la précision des prédictions** lorsque la baisse importante de son **biais** excède l'augmentation de sa **variance** (*its increase in variance is less than its decrease in bias*).


3.6 Mise en pratique avec R

- **Régression Polynomiale** : `lm(y ~poly(x, degree))`.
- **Découpage en classes** : `cut(x, breaks)` pour les fonctions en escalier.
- **B-Splines** : `library(splines); lm(y ~bs(x, knots=...))`.
- **Splines Naturelles** : `lm(y ~ns(x, df=...))`.

Note sur le choix des nœuds : On peut placer les nœuds uniformément ou aux quantiles des données (ex: 25ème, 50ème, 75ème percentiles) pour avoir plus de flexibilité là où les données sont denses.

Example 1: Polynomial ($h_m = x^m$)

Example 2: Fourier



Example 3: Wavelets




Figure 3.1: Exemples de fonctions de base (Polynômes, Splines, Ondelettes, Fourier, Fonctions en escalier).




Figure 3.2: Exemple de modèle polynomial de degré 5. Un degré trop élevé peut conduire à des oscillations importantes aux bornes ("polynomial wiggle").




Figure 3.3: Régression polynomiale et fonctions en escalier sur le jeu de données Wage.




Figure 3.4: Régression logistique polynomiale sur le jeu de données Wage.




Figure 3.5: Comparaison des modèles par splines: constantes par morceaux, continues, cubiques continues, et splines linéaires.




Figure 3.6: Comparaison entre une spline cubique naturelle et une spline cubique standard. Les intervalles de confiance montrent que la spline naturelle est plus stable aux frontières.




Figure 3.7: Instabilité énorme de la régression polynomiale de haut degré aux frontières par rapport à la spline naturelle.




Figure 3.8: Erreur quadratique moyenne (MSE) en fonction des degrés de liberté pour les splines naturelles et cubiques.




Figure 3.9: Utilisation des splines naturelles pour la régression logistique (classification).

Chapter 4

Lissage Avancé, Ondelettes et Modèles Additifs

4.1 Smoothing Splines (Splines de Lissage)

4.1.1 Problématique et Motivation

L'approche des splines de régression nécessite de choisir le nombre et la position des nœuds. Une alternative consiste à chercher une fonction f qui ajuste bien les données tout en étant "lisse". Si nous minimisons simplement le RSS sans contraintes, nous obtenons une fonction qui interpole tous les points de données, conduisant à un sur-apprentissage massif.

Example: Temperature in Montreal in the year 2014




Figure 4.1: Exemple de lissage de la température à Montréal en fonction du temps. Une spline de lissage permet de capturer la tendance non-linéaire mieux qu'un modèle linéaire ou polynomial simple.

4.1.2 Critère de Minimisation

La spline de lissage est la fonction f qui minimise le critère suivant:

$$\sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int f''(t)^2 dt \quad (4.1)$$

- Terme de fidélité aux données : $\sum (y_i - f(x_i))^2$ (RSS).

- **Pénalité de rugosité** : $\lambda \int f''(t)^2 dt$ pénalise la variabilité de f (sa courbure).
- **Paramètre de réglage λ** : Contrôle le compromis. Si $\lambda = 0$, f interpole les données ; si $\lambda \rightarrow \infty$, f devient une droite (moindres carrés linéaires).




Figure 4.2: L'effet du paramètre de réglage λ sur une spline de lissage. De gauche à droite: λ trop petit (sur-apprentissage), λ optimal, λ trop grand (sous-apprentissage).

4.1.3 Propriétés et Solution

Il est remarquable que pour tout $\lambda > 0$, la solution unique est une **spline cubique naturelle** possédant des nœuds en chaque point d'observation $x_1, \dots, x_n$. Cependant, il s'agit d'une version "réduite" (shrunk) par rapport à une spline de régression classique sur ces mêmes nœuds.

La solution s'écrit sous forme matricielle:

$$\hat{\beta} = (N^T N + \lambda \Omega_N)^{-1} N^T Y \quad (4.2)$$

où N est la matrice de base des splines et Ω_N la matrice de pénalité.

4.1.4 Degrés de liberté effectifs

Contrairement aux splines de régression, le nombre de nœuds n'est plus le paramètre de complexité. On utilise les **degrés de liberté effectifs** df_λ , définis par la trace de la matrice de lissage S_λ :

$$df_\lambda = \text{tr}(S_\lambda) \quad (4.3)$$

Le choix de λ (ou de df_λ) est crucial et s'effectue généralement par validation croisée (LOOCV). Plus λ est grand, plus la pénalité est forte, ce qui réduit les degrés de liberté effectifs df_λ et force la courbe à s'aplatir vers une droite linéaire ($df \rightarrow 2$). À l'inverse, un $\lambda \rightarrow 0$ donne $df_\lambda \rightarrow n$ (interpolation parfaite).

4.2 Régression par Ondelettes (Wavelet Regression)

4.2.1 Représentations Temps-Fréquence

La motivation des ondelettes vient de l'incapacité de la transformée de Fourier à localiser les changements de régime dans le temps.

- **Fourier** : Excellente résolution fréquentielle, aucune localisation temporelle.
- **Fenêtrage (Gabor)** : Utilise une fenêtre fixe, limitée par le principe d'incertitude de Heisenberg.

- **Ondelettes** : Utilise des fenêtres de tailles variables (dilatations), permettant une analyse multi-échelle.




Figure 4.3: Pavage temps-fréquence d'une analyse par ondelettes. Les hautes fréquences ont une bonne résolution temporelle, tandis que les basses fréquences ont une bonne résolution fréquentielle.

4.2.2 Définition d'une Ondelette

Une ondelette ψ est une fonction de moyenne nulle, centrée en 0. On génère une famille de fonctions par translation (u) et dilatation (s):

$$\psi_{u,s}(t) = \frac{1}{\sqrt{s}} \psi\left(\frac{t-u}{s}\right) \quad (4.4)$$

4.2.3 Décomposition et Sparsité

L'idée est de décomposer une fonction sur une base orthonormée d'ondelettes. L'exemple le plus simple est la base de **Haar**. Les ondelettes sont particulièrement efficaces car elles induisent de la **sparsité** : un petit nombre de coefficients suffit à représenter l'essentiel de l'information d'un signal ou d'une image (principe utilisé dans le format JPEG2000).

4.2.4 Débruitage par Seuillage (Thresholding)

Dans un contexte de régression $Y_i = f(x_i) + \epsilon_i$, on estime f en trois étapes:

1. Calculer les coefficients d'ondelettes $\hat{\theta} = WY$ via une transformée rapide (DWT).
2. Appliquer un **seuillage** sur les coefficients pour éliminer le bruit:
 - **Seuillage dur** (Hard) : On annule les coefficients inférieurs à un seuil λ .
 - **Seuillage doux** (Soft) : On réduit l'amplitude des coefficients conservés.




Figure 4.4: En haut, un signal non-stationnaire composé d'une onde sinusoïdale de basse fréquence, de deux sauts brusques, et d'un chirp. En bas, le scalogramme (CWT) illustrant la localisation temps-fréquence. À droite, les ondelettes (ex: Hat/Ricker).

3. Appliquer la transformée inverse pour reconstruire le signal estimé $\hat{f}$.

(★ **EXAMEN**) C'est précisément cette étape de seuillage qui confère aux ondelettes leur pouvoir de **sparsité** (parcimonie). En forçant la majorité des petits coefficients de détail (souvent assimilables au bruit) à zéro pur, on obtient une représentation extrêmement compacte et lisse du signal original, tout en préservant intactes les caractéristiques locales majeures (comme les sauts ou les discontinuités fortes).

4.3 Modèles Additifs Généralisés (GAM)

4.3.1 Définition

Les GAM étendent la régression linéaire multiple en remplaçant chaque composante linéaire $\beta_j x_{ij}$ par une fonction non-linéaire lisse $f_j(x_{ij})$:

$$y_i = \beta_0 + \sum_{j=1}^p f_j(x_{ij}) + \epsilon_i \quad (4.5)$$

Le modèle reste **additif** car nous calculons une contribution séparée pour chaque variable avant de les sommer.

4.3.2 Avantages et Limites

- **Avantages** : Modélisation automatique des relations non-linéaires, meilleure précision prédictive, et maintien de l'interprétabilité (on peut visualiser l'effet de chaque variable individuellement).
- **Limites** : L'additivité empêche de capturer les interactions complexes entre variables, à moins de les ajouter manuellement.




Figure 4.5: Fonction d'échelle $\phi(x)$ et ondelette de Haar $\psi(x)$, avec leurs premières versions translatées/dilatées.




Figure 4.6: Exemples de l'échelonnement et la translation pour la base de Haar.

4.3.3 (★ EXAMEN) GAM pour la Classification (Régression Logistique)

Contrairement à une idée répandue, les Modèles Additifs Généralisés ne se limitent absolument pas à la régression continue. Ils étendent directement la régression logistique à des relations non-linéaires lisses. Pour une variable cible qualitative, on modélise la probabilité $p(X)$ d'appartenir à une classe via la fonction de lien logit classique :

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + f_1(X_1) + \cdots + f_p(X_p) \quad (4.6)$$

Cela permet de bénéficier d'avantages non-linéaires en classification discrète tout en préservant l'interprétabilité marginale de la régression logistique "vanilla".

4.3.4 Mise en œuvre en R

On utilise principalement les packages `gam` ou `mgcv`:






Figure 4.7: Décomposition en ondelettes : Projection sur l'espace d'approximation V_0 .

- Avec splines naturelles : `lm(y ~ns(x1, df) + ns(x2, df), data)`.
- Avec splines de lissage : `gam(y ~s(x1, df) + s(x2, df), data)`.

L'ajustement peut se faire par moindres carrés si les bases sont fixées, ou par l'algorithme de **backfitting** pour les splines de lissage.

Wavelet decomposition in the Haar basis
ExampleFigure 4.8: Décomposition en ondelettes : Projection sur $V_1 = V_0 \oplus W_0$.

$$\forall j_0 \in \mathbb{Z}, \quad f = P_{V_{j_0}} f + \sum_{j \geq j_0} P_{W_j} f = \sum_{k=0}^{2^{j_0}-1} \alpha_{j_0,k} \phi_{j_0,k} + \sum_{j \geq j_0} \sum_{k=0}^{2^j-1} \beta_{j,k} \psi_{j,k}$$

Figure 4.9: Projection d'un signal (à gauche) et son équivalent dans le domaine des ondelettes (à droite), avec approximations et espaces de détails.

Chapter 5

Machines à Vecteurs de Support (SVM)

5.1 Introduction et Contexte Historique

Les Support Vector Machines (SVM) ont été développées par **Vladimir Vapnik**. Bien que l'idée remonte aux années 60, Vapnik a fait face à des rejets initiaux (notamment 3 papiers refusés à NIPS en 1992) avant de connaître le succès aux Bell Labs grâce à l'introduction du premier noyau non-linéaire (polynomial d'ordre 2) pour la reconnaissance de chiffres manuscrits.

5.1.1 Objectif de la Classification Supervisée

La classification consiste à construire une fonction $C(X)$ à partir de prédicteurs X pour prédire une réponse qualitative Y appartenant à un ensemble de classes $\mathcal{C}$.

- **Variables Qualitatives** : Valeurs dans un ensemble non ordonné (ex: couleur des yeux, fraude ou non).
- **Probabilités** : Dans certains domaines (assurance), l'estimation de la probabilité d'appartenance à une classe est plus utile qu'une classification brute.
- **Spécificité SVM** : Ils sont nativement conçus pour la prédiction de classe, bien qu'adaptables pour l'estimation de probabilités.

5.2 Classification et Hyperplan Séparateur

5.2.1 Définition Mathématique

Un hyperplan H dans un espace vectoriel de dimension p est défini par l'équation:

$$\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p = 0 \quad (5.1)$$

- Si $p = 2$, l'hyperplan est une simple **droite**.
- Si $\beta_0 = 0$, l'hyperplan passe par l'origine.
- Le vecteur $\vec{\beta} = (\beta_1, \dots, \beta_p)^T$ est normal à l'hyperplan.

L'hyperplan divise l'espace en deux **demi-espaces**. Le signe de la fonction $f(x) = \beta_0 + \sum \beta_j x_j$ indique de quel côté de l'hyperplan se trouve un point x .




Figure 5.1: Exemple d'hyperplan $x_2 = 4 - 0.8x_1$ avec son vecteur normal $\vec{\beta}$

5.2.2 Règle de Décision

Soit n observations d'entraînement $\vec{x}_1, \dots, \vec{x}_n$ associées à des classes $y_i \in \{-1, +1\}$. Si un hyperplan séparateur parfait existe, il vérifie:

$$y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) > 0, \quad \forall i = 1, \dots, n \quad (5.2)$$

Pour une nouvelle observation x^* , on prédit la classe selon le signe de $f(x^*)$:

- $f(x^*) > 0 \implies$ Classe $+1$.
- $f(x^*) < 0 \implies$ Classe -1 .

5.3 Le Classifieur à Marge Maximale

5.3.1 Principe

Parmi l'infinité d'hyperplans séparateurs possibles, on cherche celui qui maximise la **marge** (le gap) entre les deux classes. C'est l'approche de la "rue la plus large".

5.3.2 Optimisation

Maximiser la largeur globale de la marge (**★ EXAMEN**) $L = \frac{2}{\|\vec{\beta}\|} = \frac{2}{\sqrt{\beta^T \beta}}$ revient à minimiser $\|\vec{\beta}\|$ sous contraintes. Le problème quadratique (QP) s'écrit:

$$\min_{\beta_0, \beta} \frac{1}{2} \|\vec{\beta}\|^2 \quad \text{s.t.} \quad y_i(\beta_0 + \vec{\beta}^T \vec{x}_i) \geq 1, \quad i = 1, \dots, n \quad (5.3)$$

5.3.3 Vecteurs Supports et Dualité

On utilise le **Lagrangien** pour résoudre ce problème sous contraintes:

$$L = \frac{1}{2} \|\vec{\beta}\|^2 - \sum_{i=1}^N \alpha_i [y_i(\vec{\beta} \cdot \vec{x}_i + \beta_0) - 1] \quad (5.4)$$



Figure 5.2: Géométrie de la marge maximale entre deux vecteurs supports $\vec{x}_+$ et $\vec{x}_-$ 

Figure 5.3: Les équations définissant l'hyperplan séparateur (0) et les frontières de marge (+1 et -1)

En annulant les dérivées partielles, on trouve que $\vec{\beta}$ est une combinaison linéaire des échantillons:

$$\vec{\beta} = \sum_{i=1}^N \alpha_i y_i \vec{x}_i \quad (5.5)$$

Points clés :

- Seuls les points sur la marge (**Vecteurs Supports**) ont un multiplicateur de Lagrange $\alpha_i > 0$.
- L'optimisation et la décision ne dépendent que des **produits scalaires** entre les paires d'échantillons.

5.4 Support Vector Classifier (Cas Non-Séparable)

Dans la réalité, les données sont souvent bruitées ou non linéairement séparables.

5.4.1 Variables d'Écart (Slack Variables)

On introduit $\xi_i \geq 0$ pour autoriser certaines observations à se trouver du mauvais côté de la marge ou de l'hyperplan:

- $\xi_i = 0$: Point bien classé, hors de la marge.
- $\xi_i > 0$: Point ayant dépassé la marge.
- $\xi_i > 1$: Point mal classé (mauvais côté de l'hyperplan).

Le paramètre de coût C

On minimise $\frac{1}{2}\|\beta\|^2 + C \sum \xi_i$. (★ EXAMEN)

- **C petit** : On est très tolérant aux erreurs (somme des ξ_i peu pénalisée). La marge s'élargit et autorise davantage d'observations à la violer, conduisant à un modèle plus souple (biais plus fort, variance plus faible).
- **C grand** : On est très sévère quant aux erreurs. La marge se resserre considérablement pour classer correctement le maximum de points d'entraînement, ce qui rapproche le modèle du classifieur à marge maximale (faible biais, variance très forte risquant le sur-apprentissage).




Figure 5.4: Effet de la flexibilité du classifieur (paramètre de coût C) sur des données bruitées

5.4.2 Formulation Duale (Soft Margin) et Résolution Mathématique

Le passage du problème d'optimisation **primal** (minimisation avec contraintes) au problème **duale** (maximisation) repose sur le **Lagrangien**. Voici le détail de la méthode :

1. Le problème primal et le Lagrangien

Le problème d'optimisation *Soft Margin* primal est le suivant :

$$\min_{\beta_0, \beta, \xi} \frac{1}{2} \|\vec{\beta}\|^2 + C \sum_{i=1}^n \xi_i \quad (5.6)$$

Sous les contraintes :

$$y_i(\beta_0 + \vec{\beta}^T \vec{x}_i) \geq 1 - \xi_i, \quad \forall i \quad (5.7)$$

$$\xi_i \geq 0, \quad \forall i \quad (5.8)$$

Pour intégrer ces contraintes, on introduit des **multiplicateurs de Lagrange** $\alpha_i \geq 0$ (pour la première contrainte) et $\mu_i \geq 0$ (pour la positivité des "slack variables" ξ_i). Le Lagrangien s'écrit :

$$L(\beta, \beta_0, \xi, \alpha, \mu) = \frac{1}{2} \|\vec{\beta}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i [y_i(\beta_0 + \vec{\beta}^T \vec{x}_i) - 1 + \xi_i] - \sum_{i=1}^n \mu_i \xi_i \quad (5.9)$$

2. Conditions d'optimalité (KKT)

Pour minimiser ce Lagrangien par rapport aux variables primales (β, β_0, ξ) , on annule les dérivées partielles :

$$\frac{\partial L}{\partial \vec{\beta}} = 0 \implies \vec{\beta} = \sum_{i=1}^n \alpha_i y_i \vec{x}_i \quad (5.10)$$

$$\frac{\partial L}{\partial \beta_0} = 0 \implies \sum_{i=1}^n \alpha_i y_i = 0 \quad (5.11)$$

$$\frac{\partial L}{\partial \xi_i} = 0 \implies \alpha_i + \mu_i = C \quad (5.12)$$

3. Le problème Dual

En substituant les résultats (5.10), (5.11) et (5.12) dans le Lagrangien, les termes dépendant de β_0 et de ξ_i s'annulent. La fonction (dual) à **maximiser** ne dépend plus que des multiplicateurs α_i :

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j \quad (5.13)$$

(★ EXAMEN) Contraintes finales sur α_i (Box-Constraint) :

- La condition (5.11) nous donne : $\sum_{i=1}^n \alpha_i y_i = 0$.
- Puisque $\alpha_i \geq 0$ et $\mu_i \geq 0$, l'équation (5.12) ($\alpha_i + \mu_i = C$) implique nécessairement la contrainte dite de "boîte" (*Box-Constraint*) sur chaque multiplicateur :

$$0 \leq \alpha_i \leq C, \quad \forall i = 1, \dots, n \quad (5.14)$$

4. (★ EXAMEN) Variante de Pénalité : Le Soft Margin L_2

Notez que le problème primal présenté précédemment ajoute une pénalité linéaire (Norme L_1) sur les erreurs $C \sum \xi_i$. Il existe une variante mathématique classique où l'on utilise une norme L_2 sur ces variables d'écart :

$$\min_{\beta_0, \beta, \xi} \frac{1}{2} \|\vec{\beta}\|^2 + \frac{C}{2} \sum_{i=1}^n \xi_i^2 \quad (5.15)$$

Cette variante modifie drastiquement le Lagrangien. Comme $\xi_i^2 \geq 0$, la variable ξ_i porte déjà la positivité, et on omet souvent le terme $-\sum \mu_i \xi_i$. La dérivée par rapport à ξ_i n'est plus $C - \alpha_i - \mu_i = 0$, mais devient une relation proportionnelle $C\xi_i - \alpha_i = 0$, soit $\xi_i = \alpha_i/C$.

(★ EXAMEN) **Formulation Duale exacte de la variante L_2** : En réinjectant ξ_i , la fonction objectif (A_1) à maximiser et ses contraintes (A_2) deviennent formellement :

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \vec{x}_i^T \vec{x}_j - \frac{1}{2C} \sum_{i=1}^n \alpha_i^2 \quad (5.16)$$

$$\text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0 \quad \text{et} \quad A_2 : 0 \leq \alpha_i \quad (5.17)$$

La matrice noyau subit un ajout sur sa diagonale et la contrainte de "boîte" supérieure disparaît (l'écrasement C est absorbé géométriquement par la pénalisation quadratique $-\frac{1}{2C}\alpha_i^2$). Il est essentiel de ne pas confondre les formulations lors de l'examen.

4. Interprétation des Multiplicateurs (Vecteurs Supports)

Les conditions de Karush-Kuhn-Tucker (KKT) imposent que le produit multiplicateur $\times$ contrainte est nul à l'optimum (*complementary slackness*) :

$$\alpha_i \left[y_i(\beta_0 + \vec{\beta}^T \vec{x}_i) - 1 + \xi_i \right] = 0 \quad (5.18)$$

$$\mu_i \xi_i = 0 \quad (5.19)$$

Cela permet de classer les observations d'entraînement :

- **Points bien classés (hors de la marge)** : $\xi_i = 0 \implies \mu_i > 0 \implies \alpha_i = 0$. Ces points n'influencent pas l'hyperplan.
- **Vecteurs supports sur la frontière de la marge** : $0 < \alpha_i < C$. Par l'équation (5.12), $\mu_i > 0 \implies \xi_i = 0$. Le point est exactement sur la marge, bien classé.
- **Vecteurs supports mal placés (dans la marge ou du mauvais côté)** : $\alpha_i = C$. Alors $\mu_i = 0$, et donc ξ_i peut être strictement positif ($\xi_i > 0$).

5.5 Support Vector Machines et Noyaux

5.5.1 Le "Kernel Trick"

Si les données ne sont pas séparables linéairement dans l'espace d'origine $\mathbb{R}^p$, on les projette dans un espace de dimension supérieure $\mathbb{R}^P$ via une transformation ϕ où elles deviennent séparables.

Grâce à la dualité, on n'a pas besoin de connaître explicitement ϕ , mais seulement la **fonction noyau** $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$. C'est le cœur du **Kernel Trick** (l'astuce du noyau) : (★ EXAMEN) toute la mécanique du SVM (optimisation et décision) ne repose que sur les produits scalaires entre les observations. En substituant le produit scalaire standard par une fonction noyau K adéquate (qui correspond mathématiquement à un produit scalaire dans $\mathbb{R}^P$), l'algorithme se comporte exactement *comme s'il* projetait les points dans ce vaste espace, puis cherchait un hyperplan linéaire, le tout **sans jamais avoir à calculer explicitement les coordonnées** transformées $\phi(x)$, évitant ainsi un coût computationnel rédhibitoire ou infini.




Figure 5.5: Échantillon initial nécessitant une frontière de décision non-linéaire (ex: noyau radial)

5.5.2 Noyaux Usuels

- **Polynomial** : $K(u, v) = (u^T v + 1)^\beta$.
- **Radial (RBF/Gaussien)** : $K(u, v) = e^{-\gamma \|u-v\|^2}$.

Un noyau doit satisfaire le **Théorème de Mercer** pour garantir qu'il définit un produit scalaire dans un espace de Hilbert.

5.6 Extensions et Pratique

5.6.1 Multi-classes

Comme le concept d'hyperplan est binaire ($K = 2$), on utilise deux approches pour $K > 2$:

1. **One-Versus-One (OVO)** : On entraîne $\frac{K(K-1)}{2}$ classifieurs pour chaque paire de classes. La classe gagnante est celle qui remporte le plus de duels.
2. **One-Versus-All (OVA)** : On entraîne K classifieurs (chaque classe contre toutes les autres). On choisit la classe avec le score le plus élevé.

5.6.2 Mise en œuvre avec R (package e1071)

La fonction principale est `svm()`. (★ EXAMEN) **Fait important pour la classification à plusieurs cibles** : cette fonction implémente par défaut l'approche **One-Versus-One (OVO)** pour la classification multi-classes.

- **Scaling** : Il est crucial de centrer-réduire les prédicteurs pour éviter que les variables à forte échelle ne dominent.
- **Tuning et Hypéramètres** :
 - Le coût C (`cost`) gère la tolérance aux violations de marge.
 - Pour le noyau **Radial (Gaussien)**, (★ EXAMEN) le paramètre `gamma` (γ) représente l'inverse de la taille de la fenêtre d'influence d'un vecteur support (la largeur du "creux" gaussien). Un γ *petit* signifie une large zone d'influence vis-à-vis du lissage (forte variance), tandis qu'un γ *fort* modélise un seuil très piqué conduisant le modèle à "épouser" chaque point (faible biais, très forte variance, sur-apprentissage probable).

La fonction `tune()` permet de sélectionner la meilleure combinaison de ces paramètres (C , γ) par validation croisée.

Listing 5.1: Exemple d'utilisation de e1071

```
library(e1071)
# Ajustement d'un modele radial
svmfit <- svm(y ~ ., data=dat, kernel="radial", cost=10, gamma=1)
# Recherche des meilleurs parametres
tune.out <- tune(svm, y ~ ., data=dat, kernel="radial",
                 ranges=list(cost=c(0.1,1,10,100), gamma=c(0.5,1,2)))
bestmod <- tune.out$best.model
```

Chapter 6

Fiche de Révision : Modélisation Statistique et Régression sous R (TP)

Synthèse des TP

Introduction : Prise en main de R

Ce qu'il faut savoir (Prérequis) :

- Connaître l'environnement de travail R et RStudio.
 - Savoir manipuler les types de base (vecteurs, matrices, dataframes).
 - Savoir installer et charger des packages (`install.packages()`, `library()`).
 - Comprendre l'aide intégrée (`?fonction`).
-

6.1 TP 1 : Méthodes de sélection de variables (Subset Selection)

6.1.1 Connaissances préalables

- **Régression linéaire multiple** : Comprendre le principe d'estimation par les moindres carrés (minimisation du RSS - *Residual Sum of Squares*).
- **Critères de sélection** : Savoir que le R^2 a tendance à augmenter avec le nombre de variables. Il faut donc utiliser des critères pénalisant la complexité du modèle :
 - Le C_p de Mallows et le critère d'information bayésien (BIC). Plus ils sont faibles, meilleur est le modèle.
 - Le R^2 ajusté (*Adjusted R^2*). Plus il est élevé, meilleur est le modèle.

6.1.2 Ce qu'il faut retenir (Théorie et Pratique)

- **Sélection du meilleur sous-ensemble (*Best Subset Selection*)** : Consiste à tester toutes les combinaisons possibles de variables. Cela garantit de trouver le meilleur modèle, mais devient impossible à calculer si le nombre de variables p est trop grand (complexité en 2^p).

- **Algorithmes gloutons (*Stepwise Selection*) :**
 - *Forward* : On part du modèle vide et on ajoute itérativement la variable qui améliore le plus le modèle.
 - *Backward* : On part du modèle complet et on retire itérativement la variable la moins utile.
 - Ces méthodes sont plus rapides mais ne garantissent pas de trouver le modèle global optimal.
- **L'approche par ensemble de validation (*Validation Set Approach*) :**
 - Consiste à diviser les données en un ensemble d'apprentissage (*Train*) et un ensemble de test (*Test / Validation*).
 - **Inconvénients majeurs** : L'estimation de l'erreur est très variable (dépendante de la séparation des données) et le modèle est entraîné sur moins de données, ce qui peut surestimer le taux d'erreur du modèle complet.
- **Code R essentiel** : L'utilisation de la fonction `regsubsets()` du package `leaps`.

```
# Exemple de selection forward
library(leaps)
regfit.best <- regsubsets(Y ~ ., data=PhyWeight, method="forward", nvmax=10)
summary_best <- summary(regfit.best)

# Trouver le modele minimisant le BIC
best_bic <- which.min(summary_best$bic)
coef(regfit.best, best_bic)
```

6.2 TP 2 : Régression Polynomiale et Sélection de Modèle

6.2.1 Connaissances préalables

- **Régression polynomiale** : Ajustement d'un modèle de la forme $f(x) = \beta_0 + \beta_1 x + \dots + \beta_m x^m$.
- **Risque quadratique** : L'erreur quadratique d'estimation peut se décomposer mathématiquement en trois composantes : le **Biais** au carré, la **Variance**, et une erreur incompressible due à la variance du bruit.

$$R(m) = \text{Biais}^2(\hat{f}_m) + \mathbb{V}(\hat{f}_m) + \text{Bruit irréductible}(\sigma^2)$$

6.2.2 Ce qu'il faut retenir (Théorie et Pratique)

- **Compromis Biais-Variance (*Bias-Variance Tradeoff*) :**
 - Lorsque le degré m du polynôme **augmente** (modèle plus complexe), le modèle s'ajuste de plus en plus aux données d'entraînement. Le **biais diminue**.
 - Cependant, un modèle trop complexe devient très sensible aux variations de l'échantillon d'entraînement. La **variance augmente**.
 - **L'objectif** : Trouver le degré optimal m^* qui minimise l'erreur totale $R(m)$, évitant ainsi le sous-apprentissage (*underfitting*, m trop petit) et le surapprentissage (*overfitting*, m trop grand).

- **Évaluation empirique** : L'erreur empirique des moindres carrés (calculée sur les mêmes données qui ont servi à entraîner le modèle) va toujours diminuer quand m augmente. C'est pourquoi on ne peut pas l'utiliser pour choisir m (le modèle "naïf" choisira toujours le polynôme de degré maximum).
- **Méthode d'estimation** : On utilise la technique de Monte-Carlo (simulation de S jeux de données) pour approximer numériquement le Biais au carré, la Variance, et le Risque total afin d'identifier visuellement (ou par le calcul) le minimum du risque $R(m)$.